Transcriptomics: single cell RNAseq

Bioinformatics & Omics

Dr. Tugce Bilgin Sonay, HSLU, 2026

Salut!



- Doktoraarbeit an der UZH
- Postdocs at UZH und UniL
- Dozentin an Columbia University New York, USA
- seit 2023 an der ZHAW

Computational Genomics Lab:

Prof Dr. Maria Anisimova



Research Centre for Bioinformatics

We develop practical solutions at the interface of biology, medicine and computational sciences.

Getting to know you

Was ist eure Studiengänge?

In welchem Jahr seid ihr?

In welchem Aspekt von Bioinformatik seid ihr interessiert?

Lernziele: beide Vorlesungen

- die Unterschiede zwischen Einzelzell-Sequnenzieren und Bulk-Sequenzieren beschreiben: Anwendung, Methode, Analyse
- Technologien zur Erfassung einzelner Zellen listen und die entsprechende Ansätze zueinander vergleichen
- Schritte in Einzelzelle-Analyse motivieren, diese in R ausführen und Ausgaben interpretiere
- Einzelzell-Transkriptomik-Matrix erstellen
- Differentielle Expressionsanalyse mit PCA ausführen
- Clusters mit UMAP und t-SNE bilden um die Katogorien zu identifizieren
- Gene und Pathway Enrichment Analyse durchführen
- Zwecke von räumlichen Einzelzell-Sequenzieren beschreiben

Ablauf: Heute

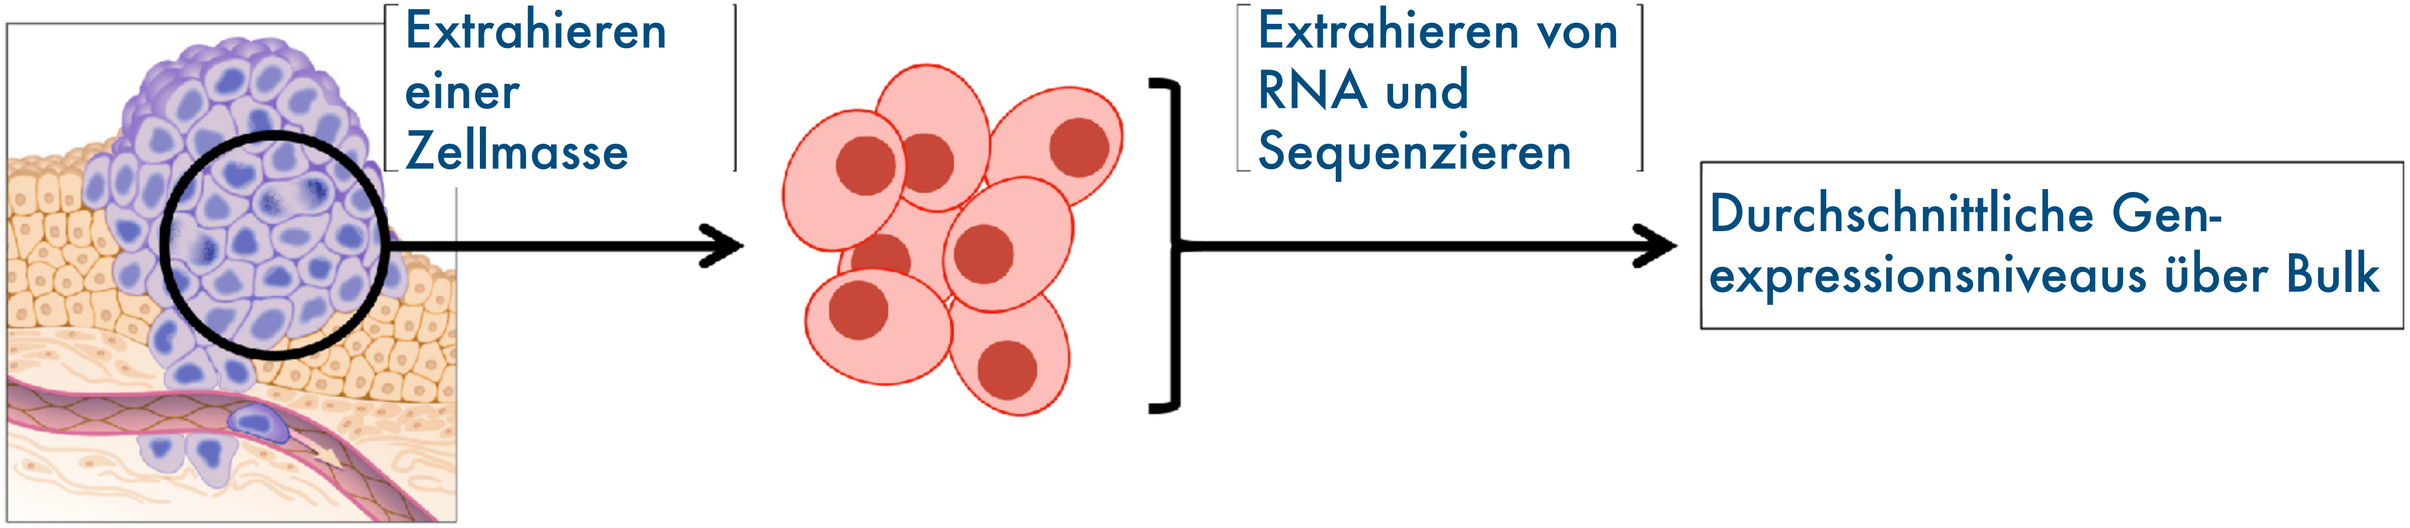
- Theorie von Einzelzell-Sequnenzieren (Technologien, Workflow)
- Theorie von Hauptkomponentenanalyse und Dimensioinsreduktion in Transkriptomik
- Praktikum in R mit einem 10X Tutorial: Single_Cell_RNA_Analysis

https://github.com/tbilgin/Einzelzelle-Transkriptomik

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Bulk-Transkriptomik

In den frühen Phasen der Next-Generation-Sequenzierung basierten alle Protokolle auf Bulk-Sequenzierungsansätzen. Bei der Bulk-Sequenzierung wird ein Teil des interessierenden Gewebes extrahiert, aus dem die DNA oder RNA isoliert und als einzelne Einheit analysiert wird. Das bedeutet, dass die Expressionsniveaus der Gene die durchschnittlichen Expressionswerte aller Zellen in der analysierten Probe widerspiegeln.



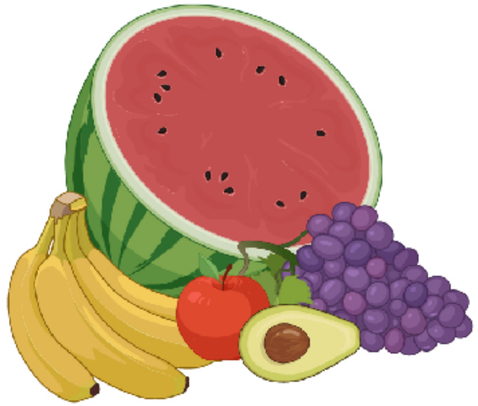
ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Bulk- vs. Einzelzell-Transkriptomik

- Bulk RNA-seq: Durchschnitt über viele Zellen
- Einzelzell-RNA-seq (scRNAseq): Jede Zelle einzeln analysiert



Bulk RNA-seq

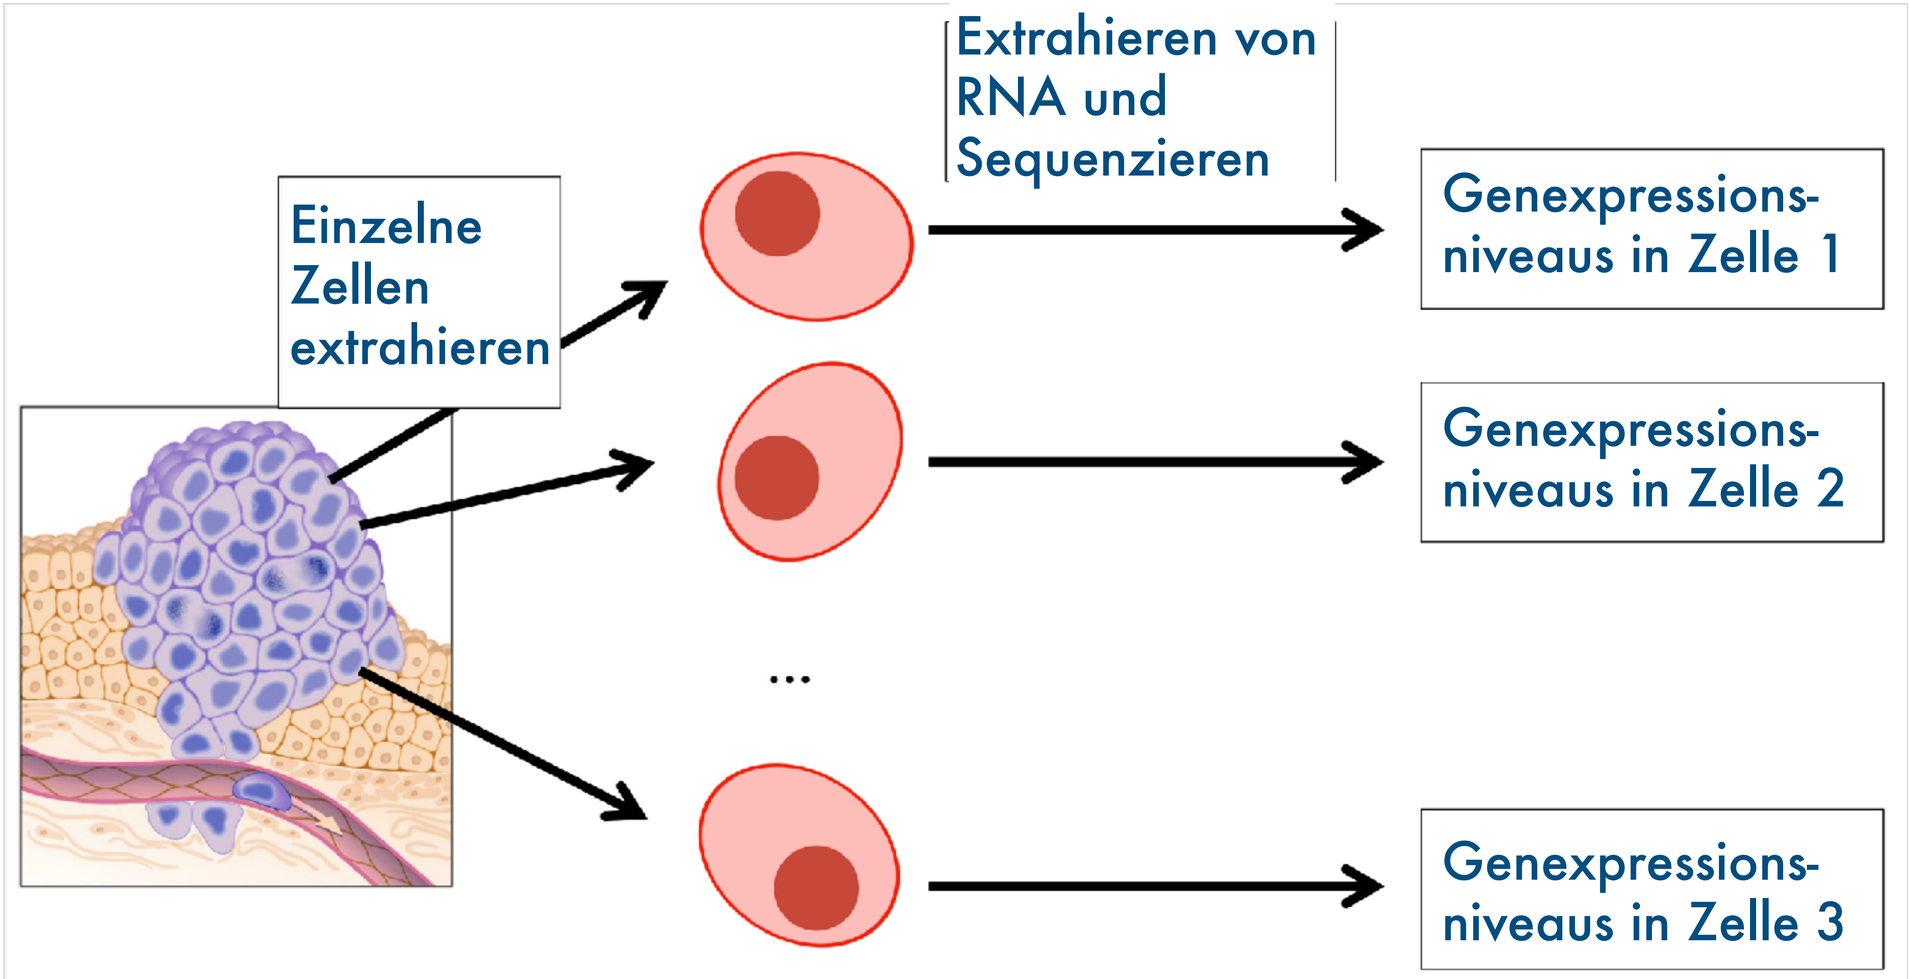


Einzelzell -RNA-seq

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Einzelzell-Transkriptomik

Bei scRNAseq werden einzelne Zellen aus einer Probe von Interesse extrahiert. Aus jeder dieser Zellen wird die RNA extrahiert und separat sequenziert. Der resultierende Datensatz enthält nun Informationen zu einzelnen Zellen.

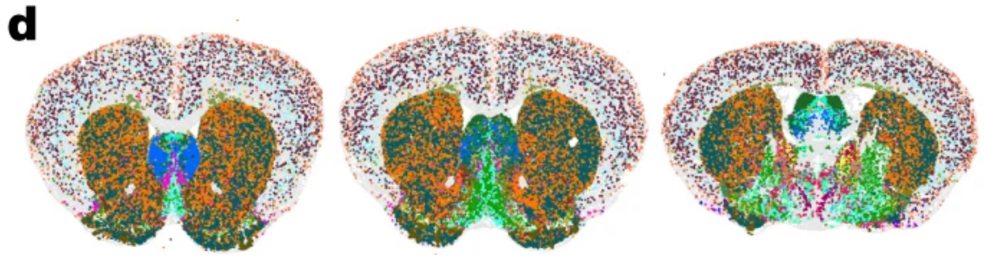


Warum Einzelzell?

Bulk RNA-seq ist für transkriptomische Analysen nicht ideal, da in jeder Probe in der Regel verschiedene Zelltypen mit unterschiedlichen Genexpressionsprofilen vorhanden sind.

Verschiedene Zelltypen in einem Organ

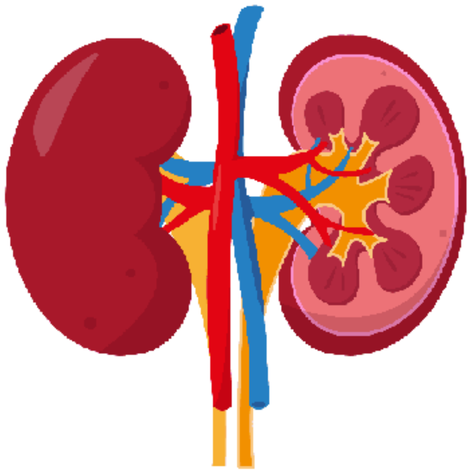
Nervenzellen und Nicht-Nervenzellen im Gehirn: zur Erforschung der Gehirnfunktion und neurologischer Störungen

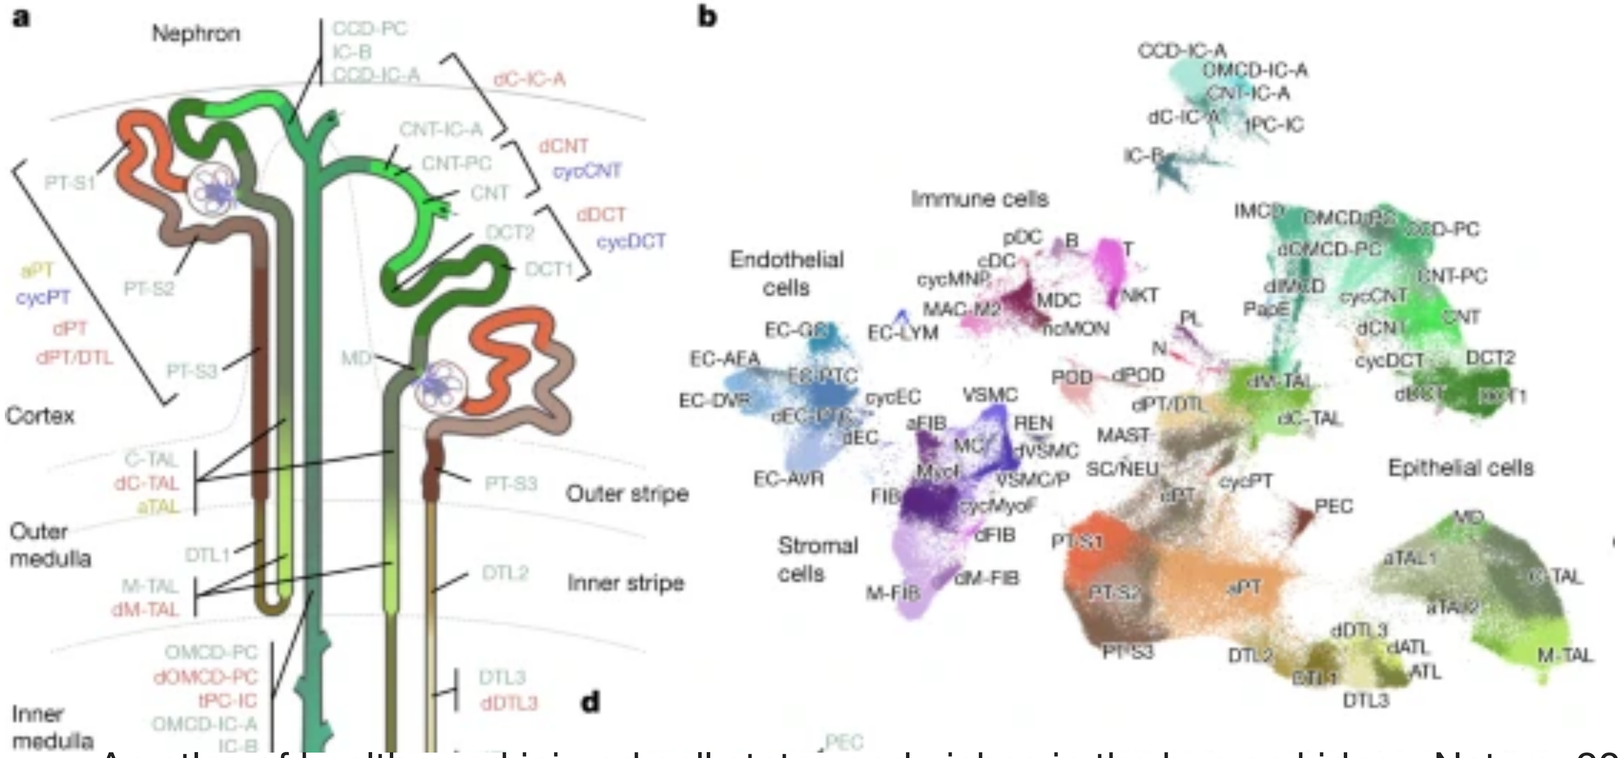


A high-resolution transcriptomic and spatial atlas of cell types in the whole mouse brain, Nature, 2023

Verschiedene Zelltypen in einem Organ

Kidney: Cortex, medulla, etc. all exhibit different cell types (epithelial cells, layered cells, immune cells, etc.) and different gene expressions.

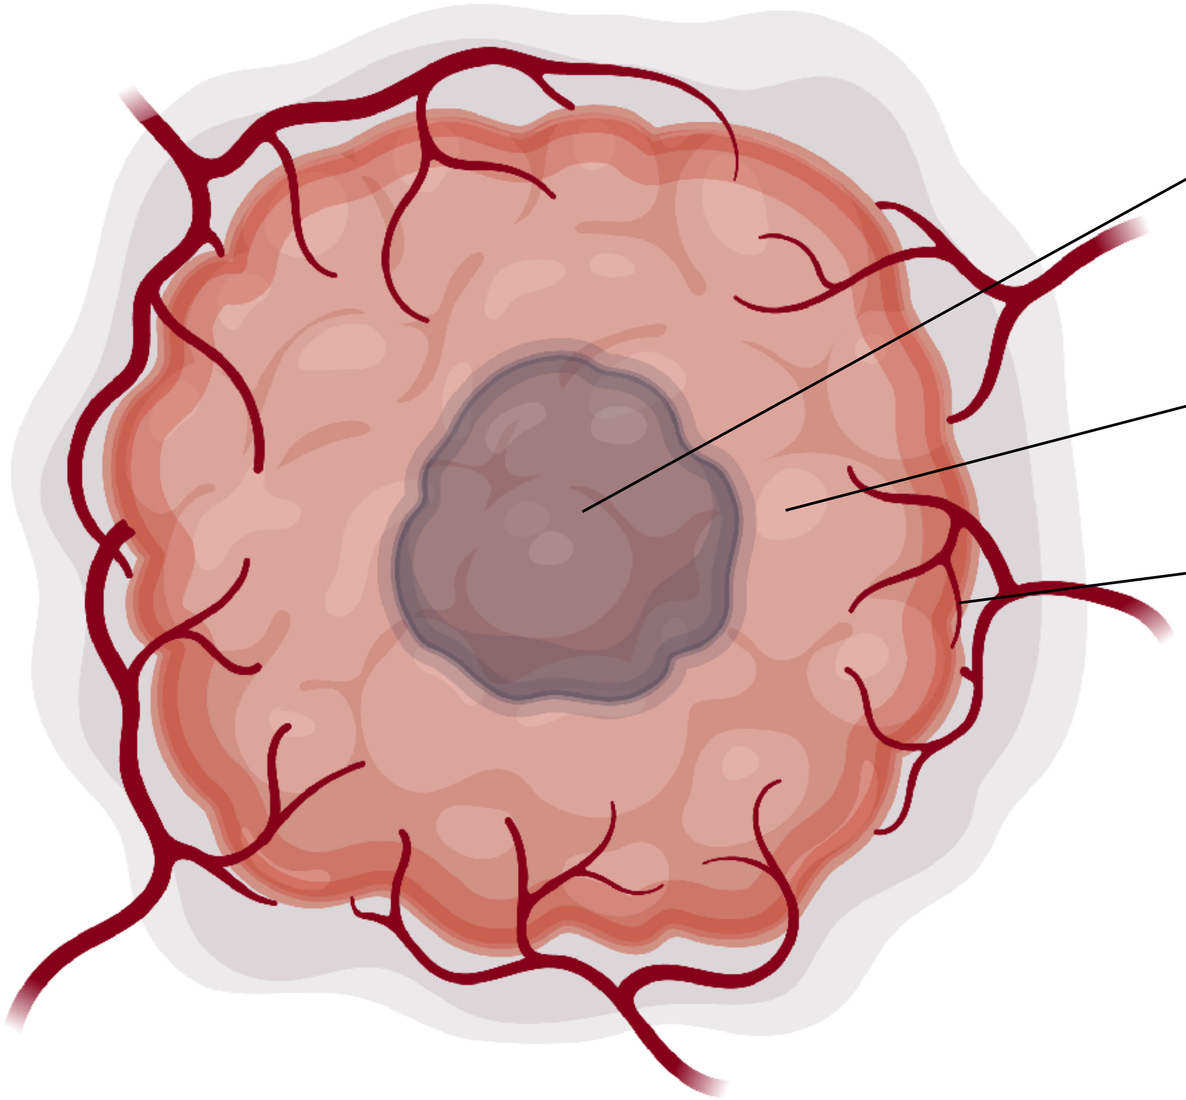




An atlas of healthy and injured cell states and niches in the human kidney, Nature, 2023

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Krebsforschung



Nekrotischer Kern
Mangel an Sauerstoff und Nährstoff

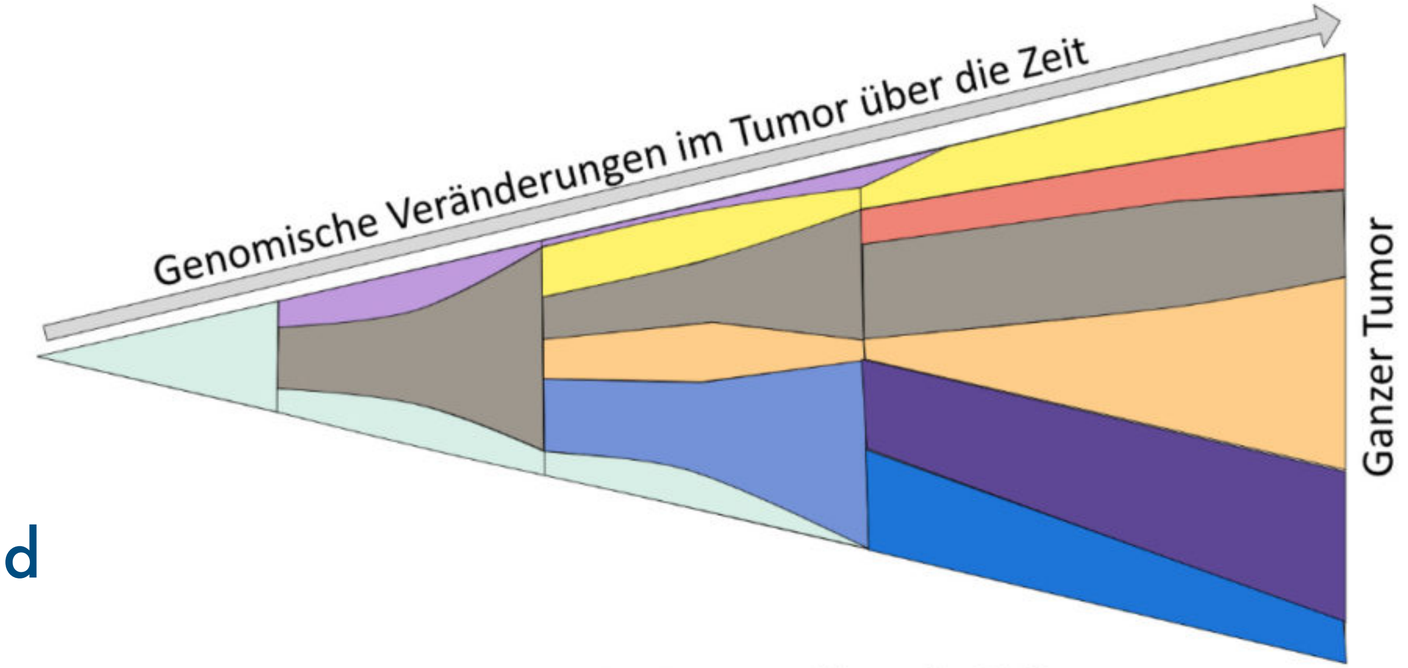
Hypoxischer Bereich
Niedriger Sauerstoffgehalt und
geringe Nährstoffversorgung

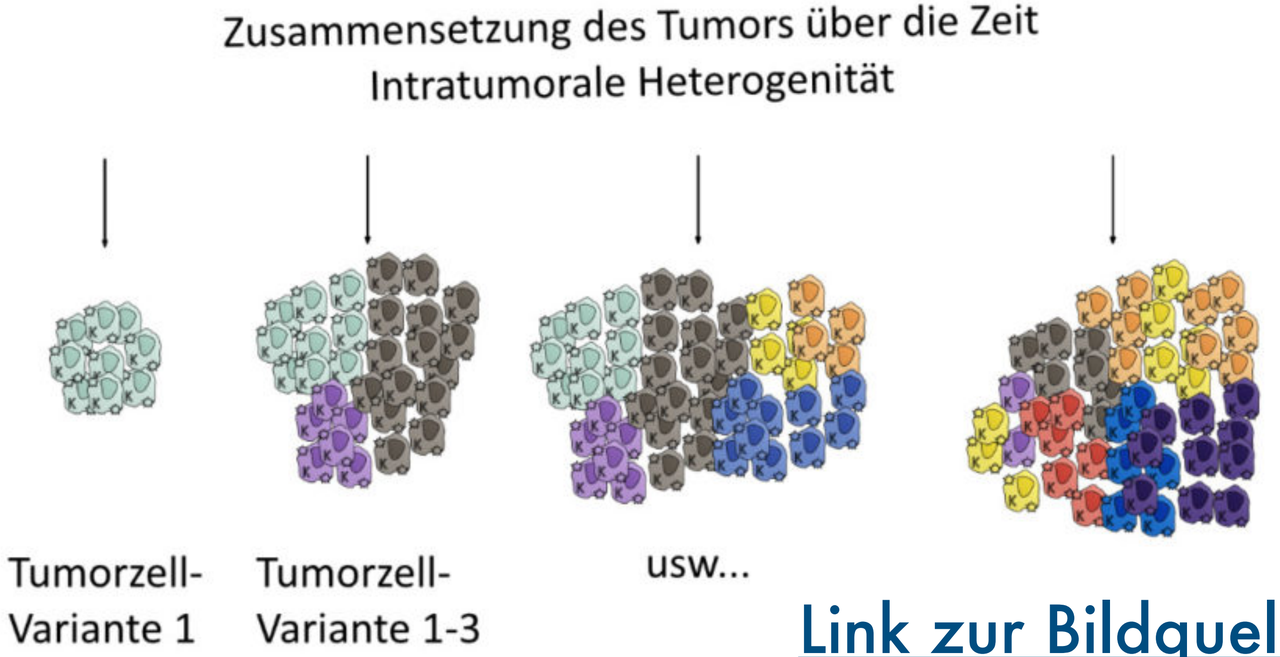
In der Nähe der Blutgefäße
Hoher Sauerstoff- und Nährstoffgehalt

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Krebsforschung

Tumorheterogenität:
Unterschiede zwischen Krebszellen innerhalb eines einzelnen Tumors. Entscheidend für die Diagnose und die Entwicklung und Bestimmung des Ansprechens auf die Therapie.





Link zur Bildquelle

Bulk- vs. Einzelzell-Transkriptomik

Bulk RNA-seq ist für transkriptomische Analysen nicht ideal, da in jeder Probe in der Regel verschiedene Zelltypen mit unterschiedlichen Genexpressionsprofilen vorhanden sind.

Bei der Einzelzell-RNA-Sequenzierung (scRNAseq) werden einzelne Zellen aus einem Gewebe oder einer Probe von Interesse extrahiert. Aus jeder dieser Zellen wird die RNA extrahiert und separat sequenziert. Der resultierende Datensatz enthält nun Informationen zu einzelnen Zellen.

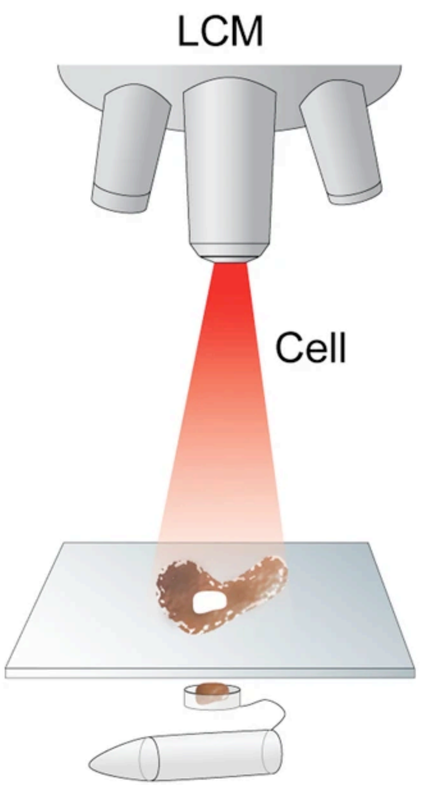
Herausforderungen bei der Einzelzell-Transkriptomik

Im Vergleich zu Bulk-RNA-Seq-Daten ist die Arbeit mit scRNA-Seq **besonders schwierig**.

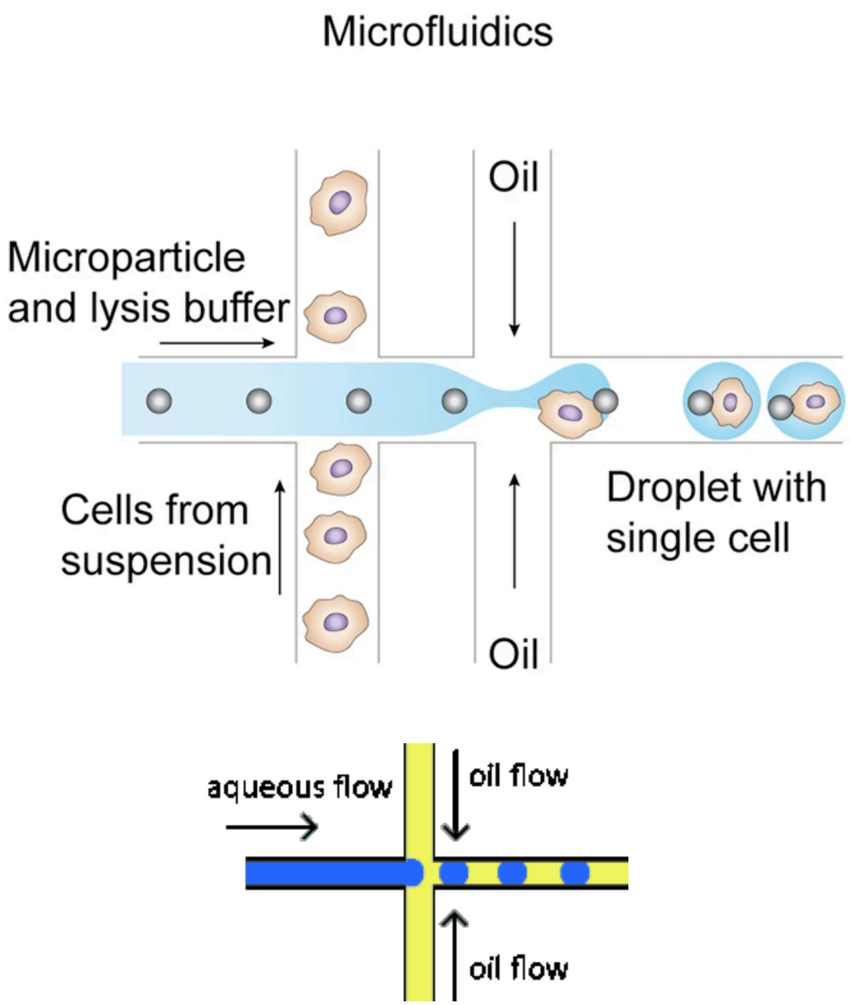
Bei scRNA-Seq sequenzieren Sie **sehr geringe Mengen an RNA-Ausgangsmaterial**, wodurch die Messungen anfälliger für **Artefakte** sind.

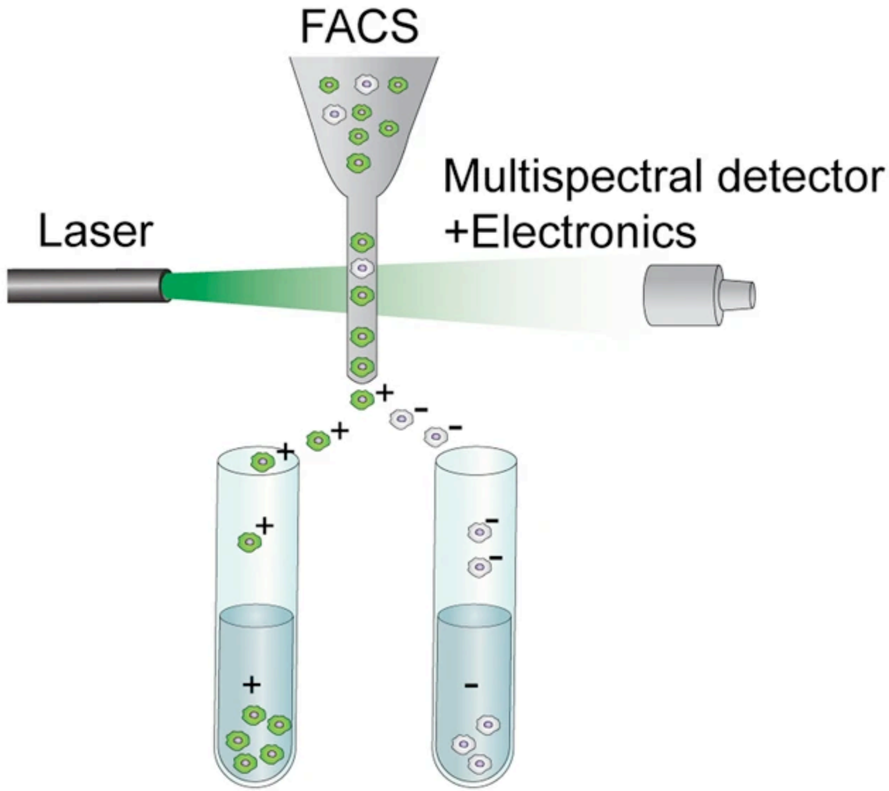
Darüber hinaus weisen einzelne Zellen eine natürliche **biologische Variabilität** in der Genexpression auf, was zu erheblichen Schwankungen in den aus Einzelzellanalysen abgeleiteten Schätzungen führt. Diese inhärente Heterogenität trägt zu einer erhöhten Unsicherheit bei der Beurteilung der Transkriptionszustände bei. Diese Unsicherheit kann jedoch durch die **Sequenzierung von mehr Zellen** gemindert werden, was ein umfassenderes Verständnis der gesamten Genexpressionslandschaft ermöglicht.

Technologien zur Erfassung einzelner Zellen



Laser Capture Microdissection





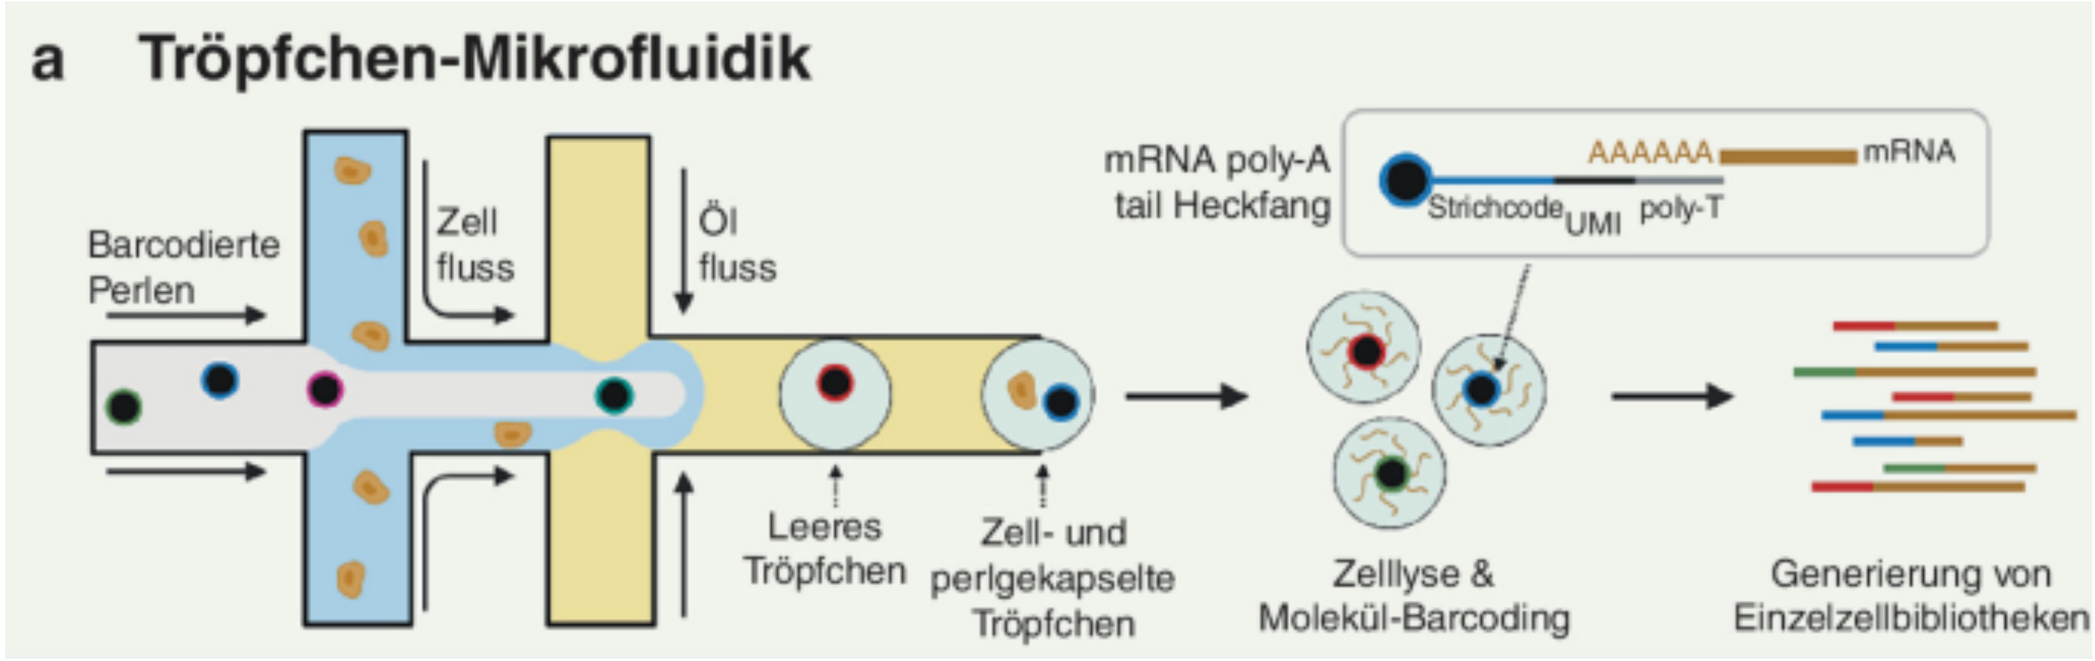
Fluorescence activated cell sorter

Hwang, B., et al.. *Exp Mol Med* 2018

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

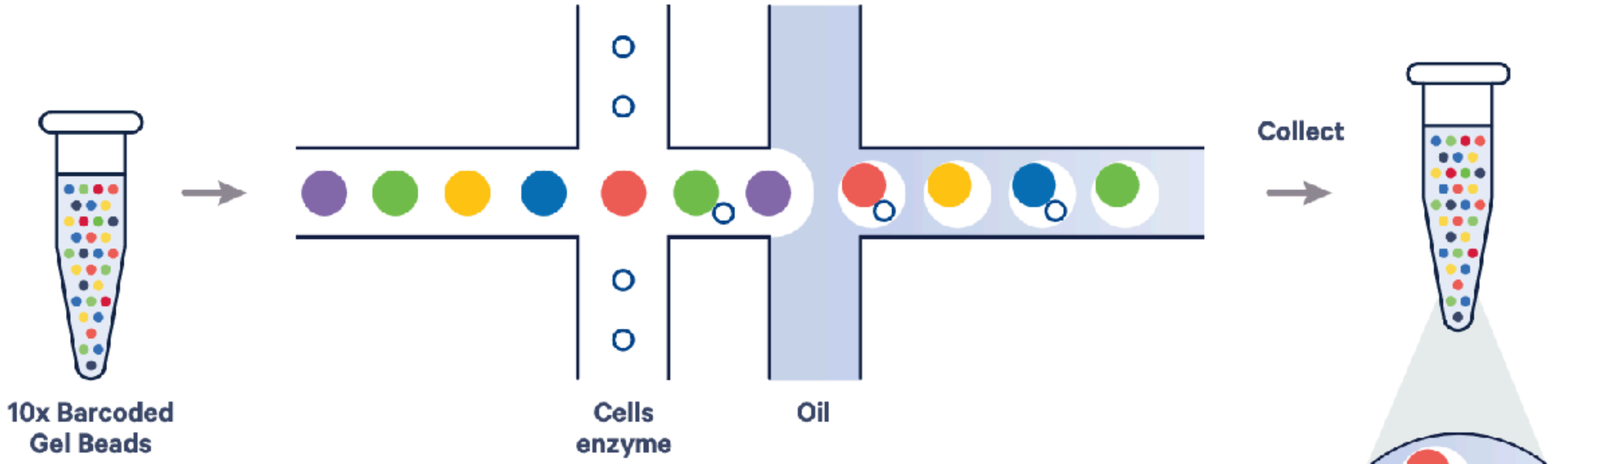
Mikrofluidik zur Erfassung einzelner Zellen

Bewegung winziger Flüssigkeitsmengen durch sehr enge Kanäle (mit einem Durchmesser von einigen zehn bis hundert Mikrometern)



Einzelzell-Transkriptomik, Springer 2024, Buch

10X Single Cell RNA Sequencing





Gel Beads in Emulsion

10X Genomics

10X Protokolle für die Einzelzell

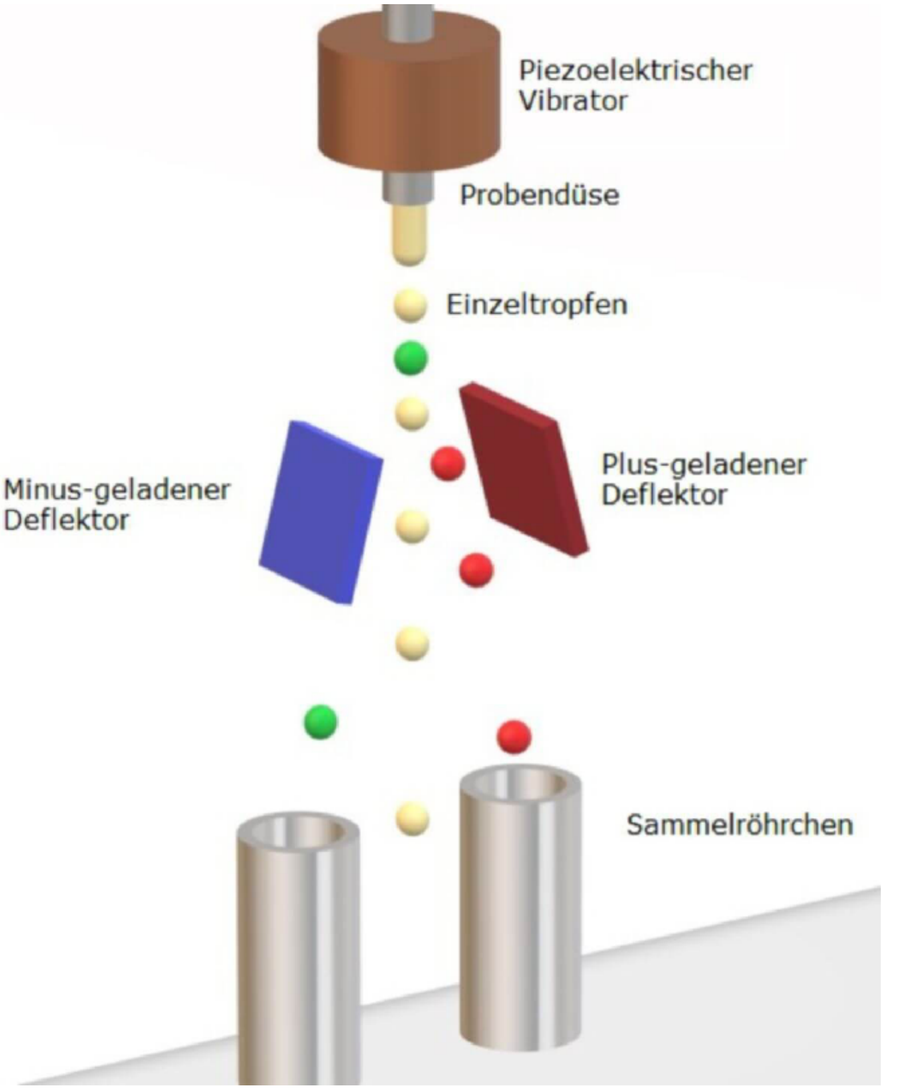
basieren auf Tröpfchen und verwenden eindeutige molekulare Identifikatoren (UMIs), um zu vermeiden, dass ein RNA-Fragment mehr als einmal gezählt wird.

10X hat den höchsten Durchsatz auf dem Markt.

Es liefert keine vollständigen Sequenzinformationen.

FACS zur Erfassung einzelner Zellen

FACS, kurz für fluorescence-activated cell sorting, ist eine Analysemethode, bei der fluoreszenz-markierte Zellen abhängig von bestimmten Eigenschaften in unterschiedliche Probengefässe sortiert werden.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

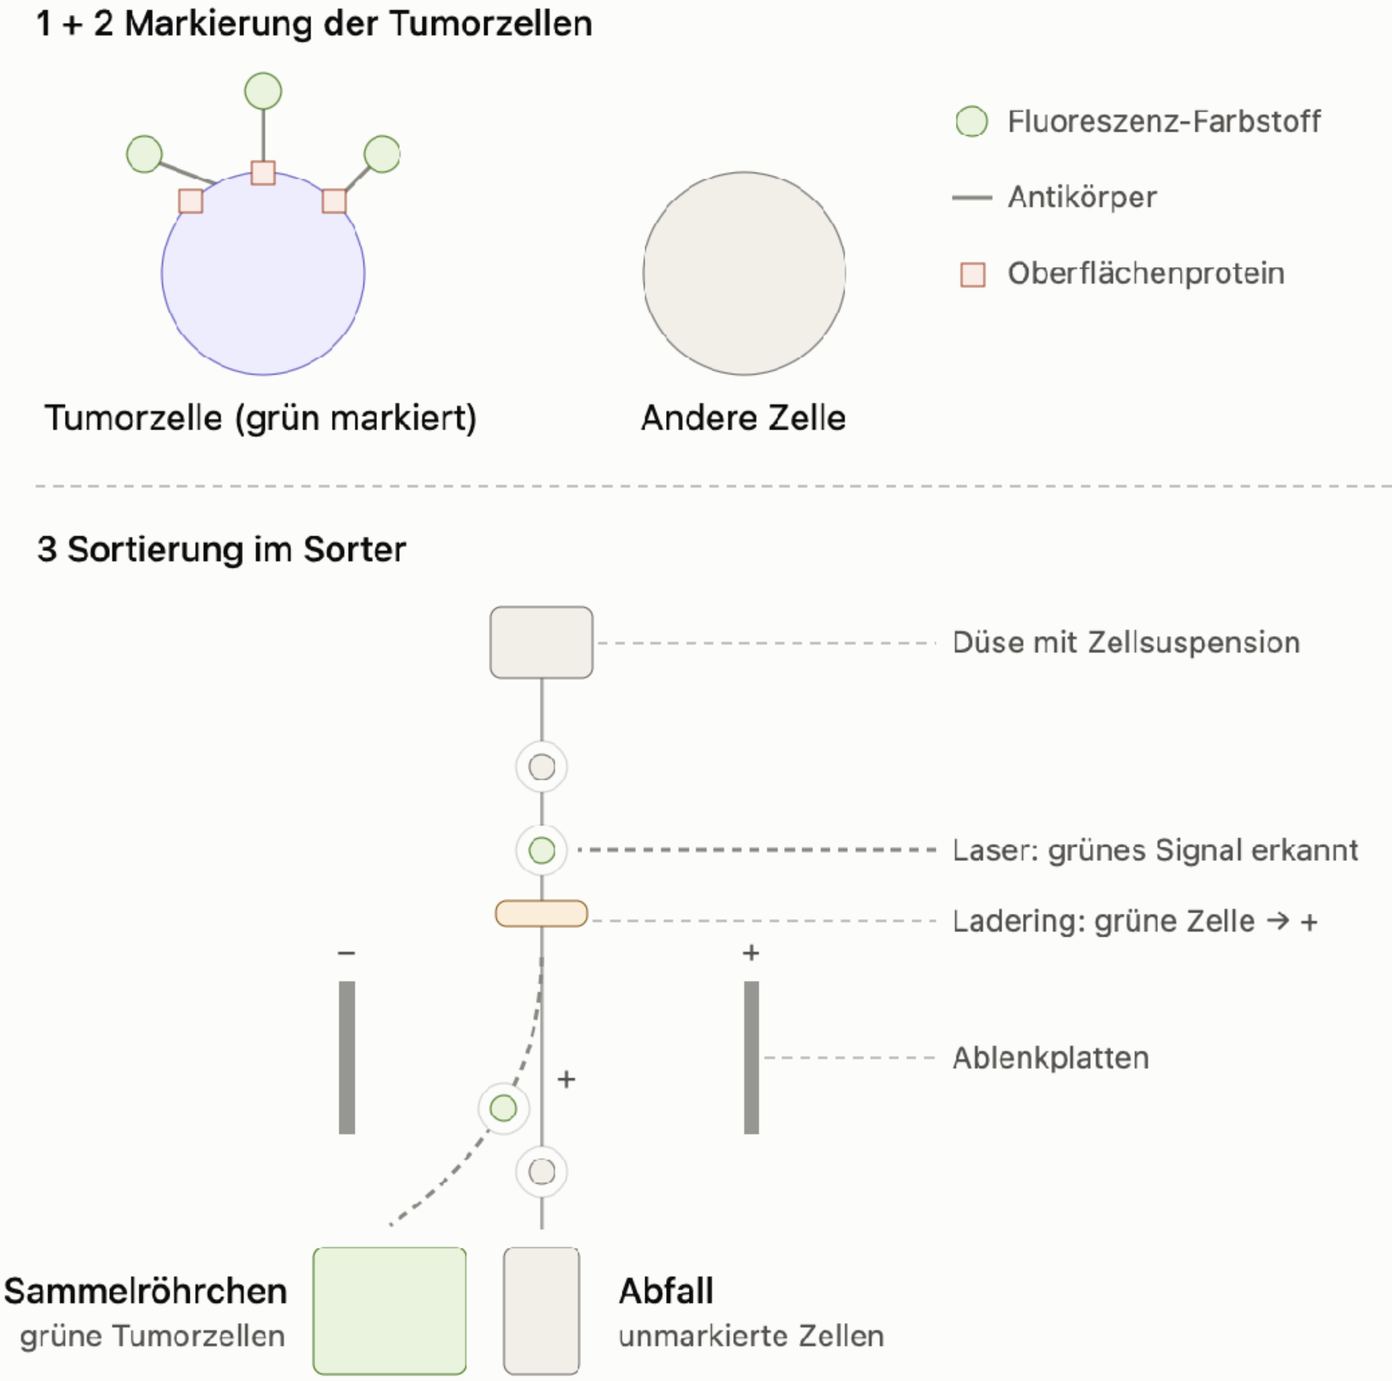
FACS: Beispiel

Falls wir kennen, welche Krebszellen welche Oberflächenproteine sich besitzen, dann können wir diese Zellen als folgende sortieren:

1. ein stark grün fluoreszierender Farbstoff ist mit dem Antikörper von diesen Oberflächenproteinen gekoppelt.

2. Oberflächenproteinen verbinden zum Antikörper damit die Tumorzellen grün markiert.

3. Der Sorter lädt alle Flüssigkeitströpfchen, die eine grün leuchtende Zelle enthalten, positiv auf. Sie werden aus dem senkrechten Flüssigkeitsstrom abgelenkt und landen in einem Sammelröhrchen, während die nicht markierten Zellen verworfen werden.



Smart-Seq pipeline

Smart-seq2 ist ein beliebtes FACS-basiertes Protokoll für die Einzelzell-RNA-Sequenzierung.

Der Durchsatz nicht besonders hoch.

Sie können jedoch auswählen, welche Zellen Sie sequenzieren möchten.

Mit diesen Protokollen erhalten Sie Informationen über das gesamte Transkriptom.

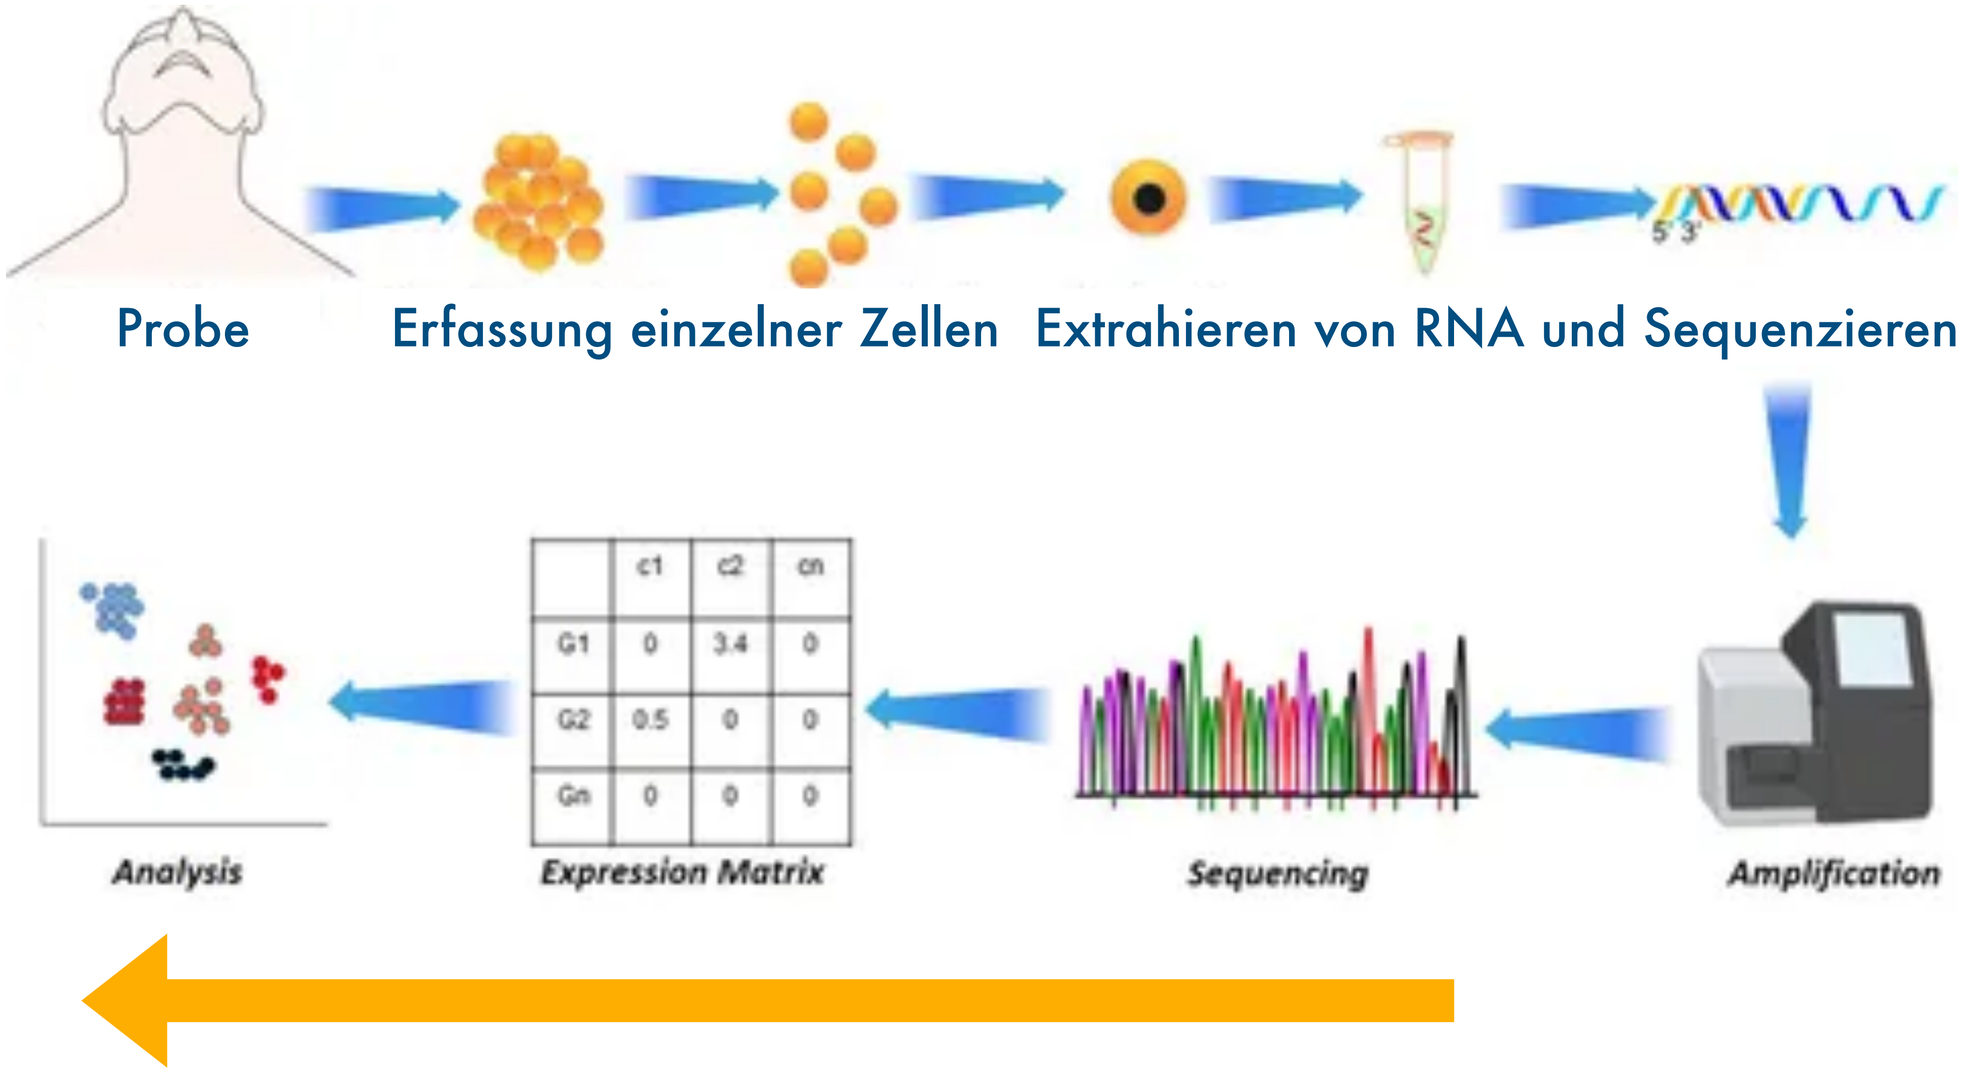
Comparative Analysis of Single-Cell RNA Sequencing Methods

Smart-Seq vs 10X

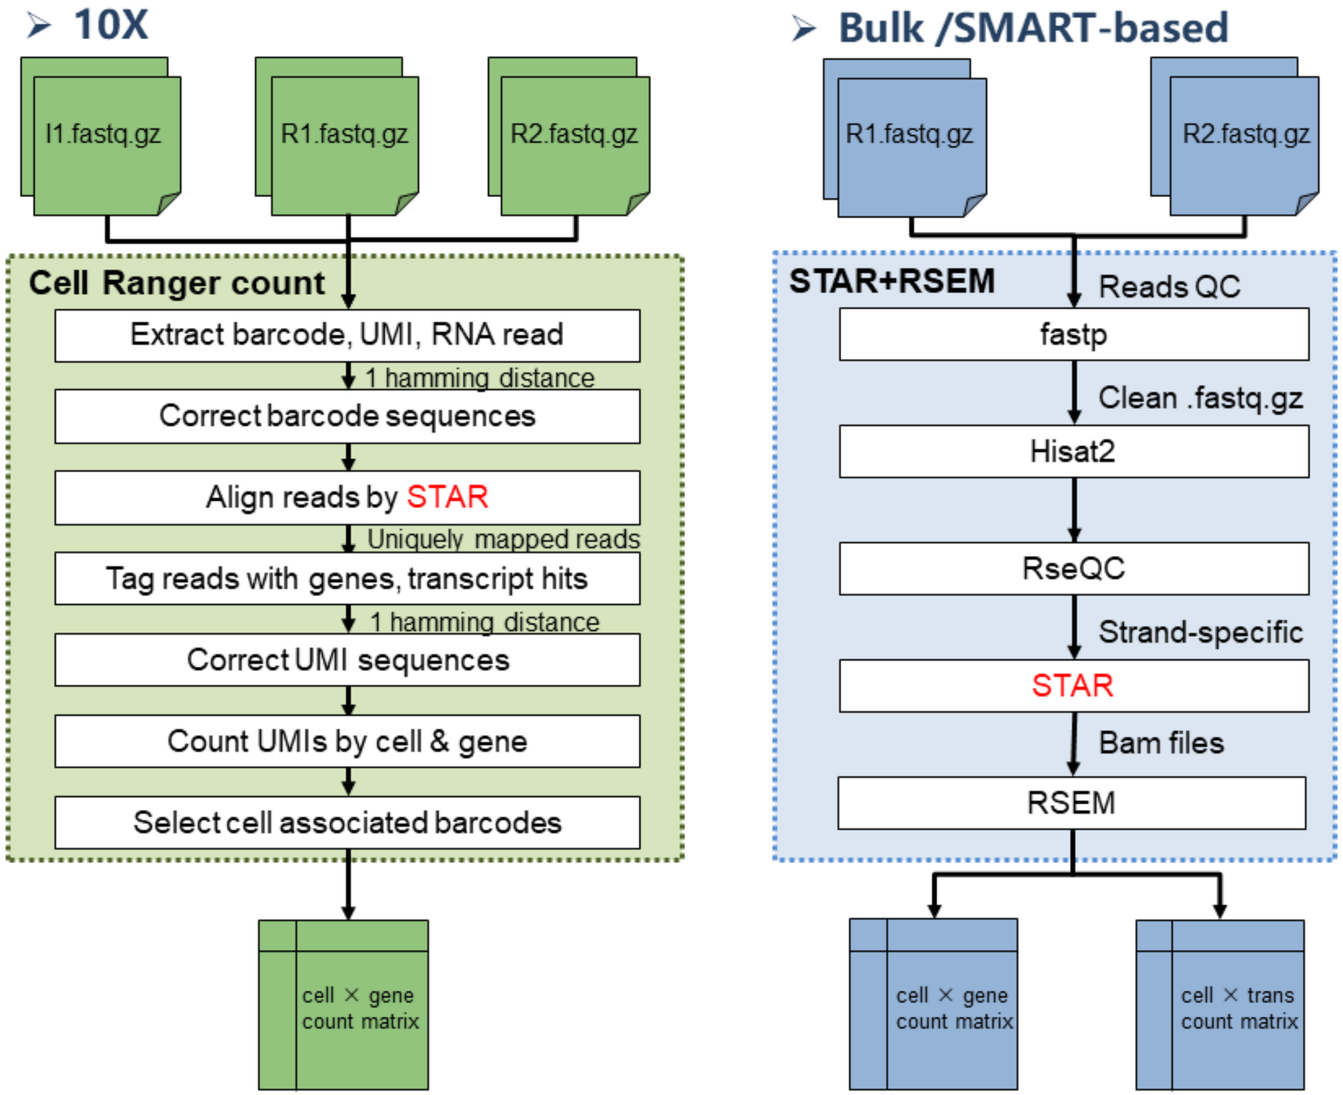
In der Regel enthalten 10x-Daten im Vergleich zu Smart-Seq deutlich mehr Zellen, die mit geringerer Tiefe sequenziert wurden.

Smart-Seq2 bietet im Vergleich zum droplet-basierten 10X die höchste Empfindlichkeit, und eine höhere Erfassungsfähigkeit aber auch höhere Kosten.

Einzelzell-Transkriptomik



Einzelzell-Transkriptomik Analyse: Erstellen der Matrix



menschliches Genom

ist ? Buchstaben lang,

davon kodieren ? % für ein Protein

und es hat über ? Gene.

Transkriptom

Obwohl im menschlichen Genom weniger als 22,000 proteinkodierende Gene bekannt sind, werden diese in über 140.000 verschiedene Transkripte transkribiert, von denen mehr als 65% Proteine kodieren.

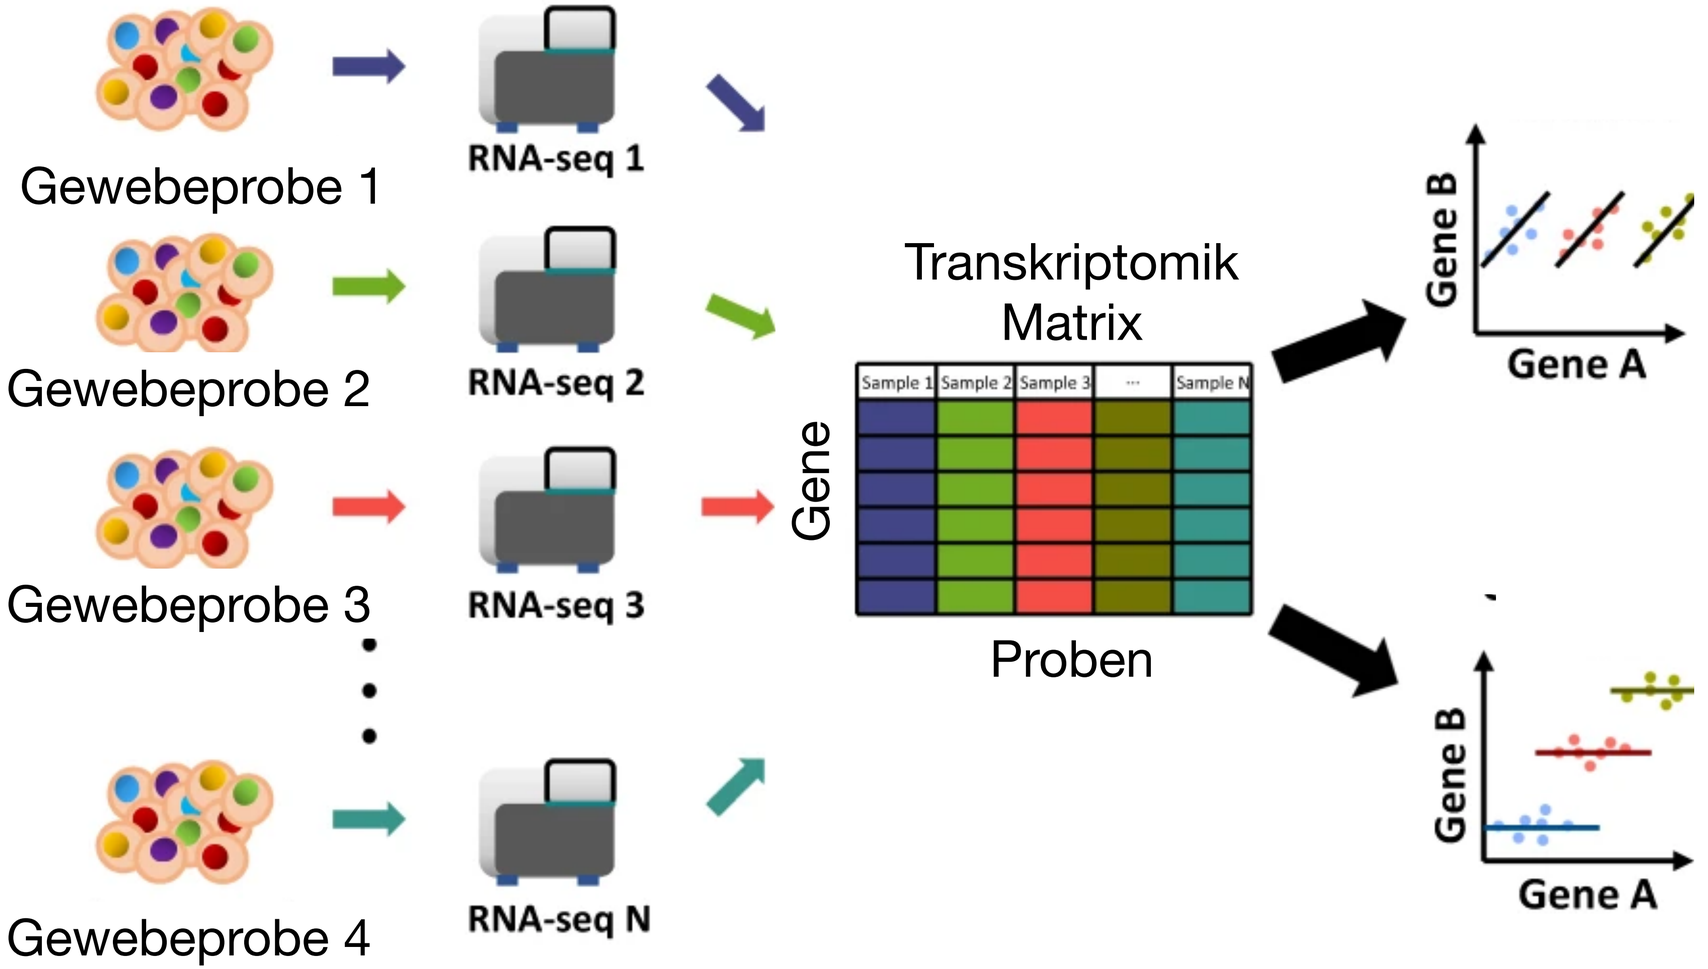
ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Einzelzell-Transkriptomik-Matrix

Tabelle, die die Genexpressionsdaten einzelner Zellen darstellt. Jede Zeile der Matrix entspricht einer bestimmten Zelle, und jede Spalte steht für ein Gen. Der Wert an jeder Schnittstelle oder Zelle gibt die Anzahl der für dieses Gen in dieser Zelle nachgewiesenen Transkripte an und liefert so einen Überblick über das molekulare Profil jeder Zelle.

	Cell1	Cell2	...	CellN
Gene1	3	2	.	13
Gene2	2	3	.	1
Gene3	1	14	.	18
...	.	.	.	.
...	.	.	.	.
...	.	.	.	.
GeneM	25	0	.	0

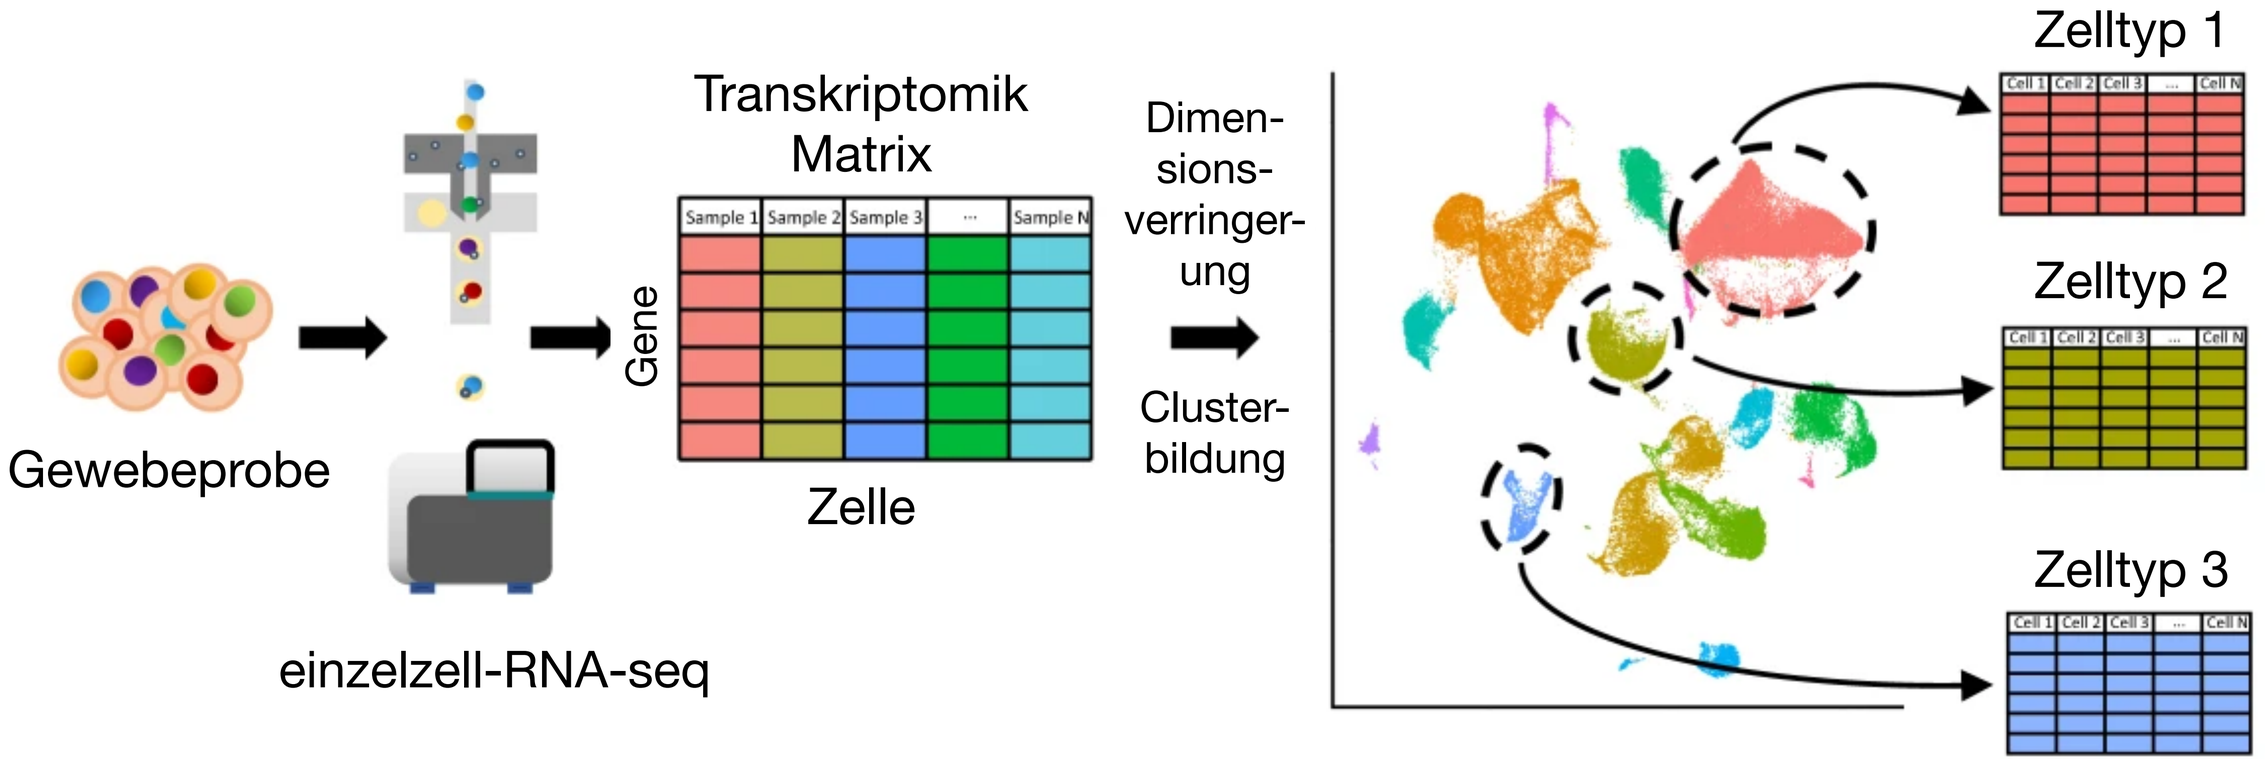
RNA-Sequenzierungsanalyse



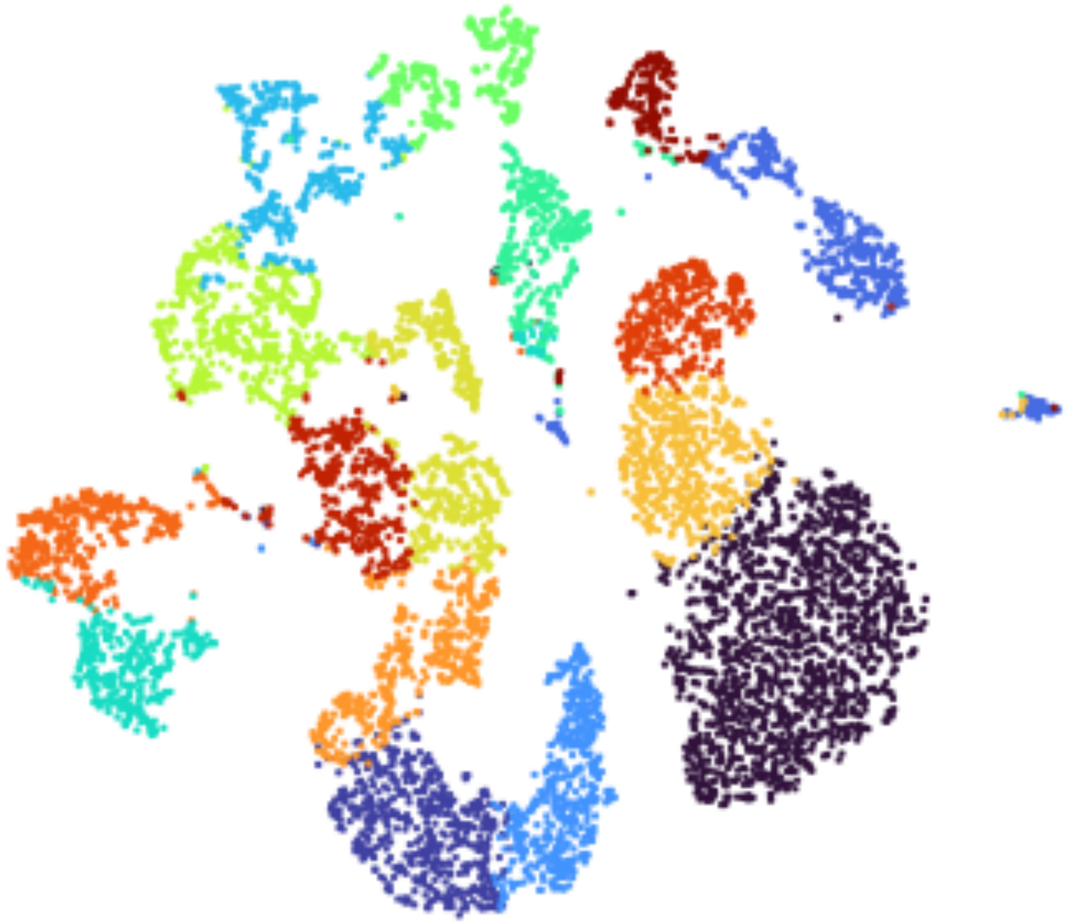
Single-cell network biology for resolving cellular heterogeneity in human diseases, Nature, 2020

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

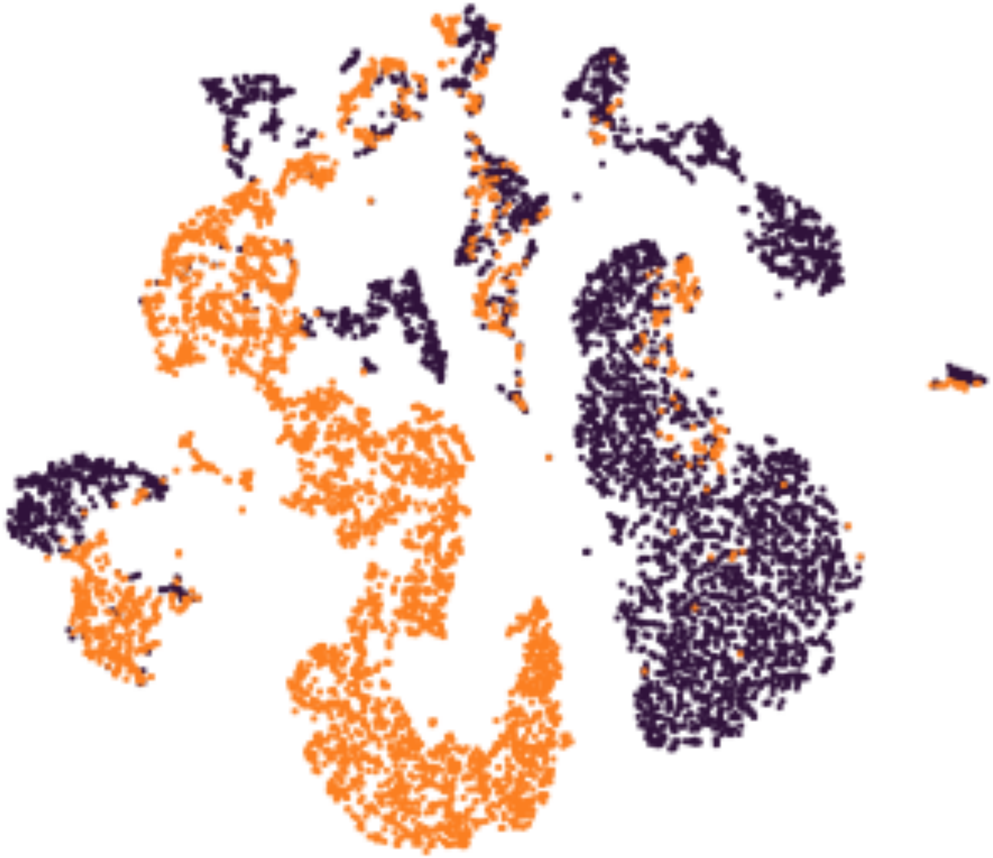
Einzelzell-RNA-Sequenzierungsanalyse



Einzelzell-RNA-Sequenzierungsanalyse Resultate



Zelltype



Leukemia Patient Gesund

10X Genomics

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Einzelzell-RNA-Sequenzierungsanalyse

R Analyse

-Seurat Paket
-Kann nur verarbeitete Daten lesen (zB 10X)

Phython Analyse

-Scvi und Scanpy
-Kombiniert mit maschinellem Lernen (scikit)

Cell-Ranger/Loupe Browser

-10X Omik Datensätze
-User Friendly
-Standard-Datenanalyse und -Visualisierung

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

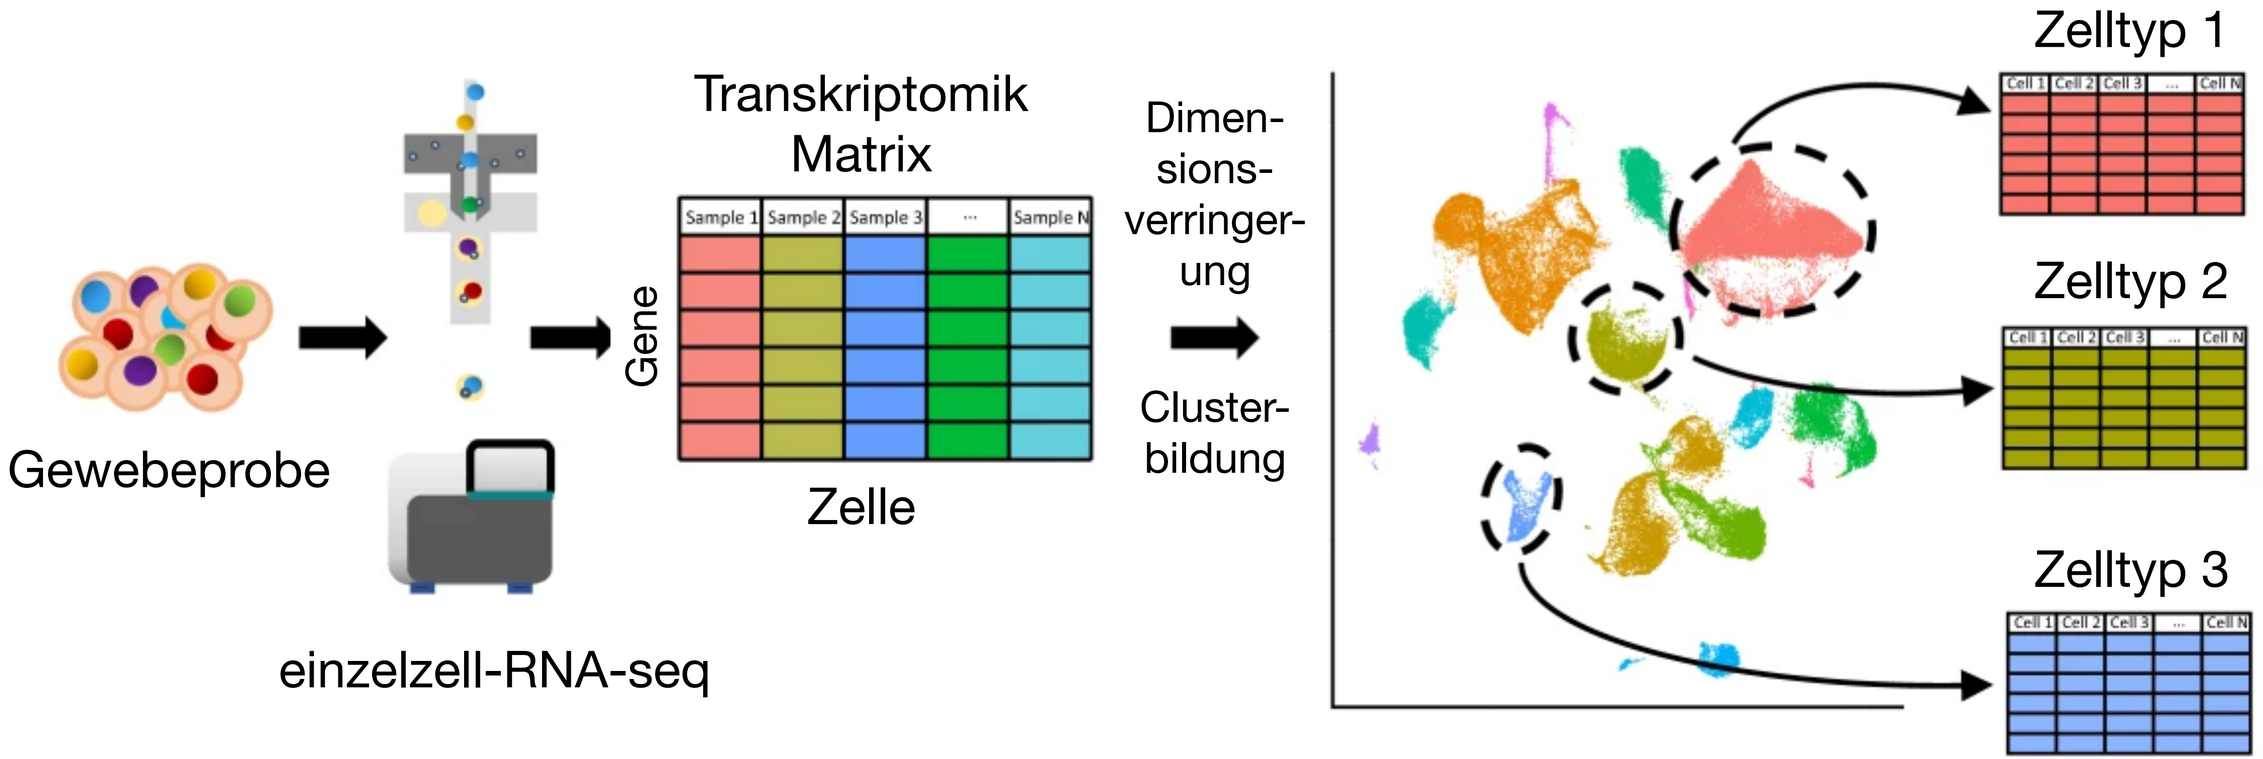
heutiges Training in R

Für dieses Tutorial analysieren wir einen Datensatz von peripheren mononukleären Blutzellen (PBMC), der von 10X Genomics frei verfügbar ist. Es handelt sich um 2.700 Einzelzellen, die auf dem Illumina NextSeq 500 sequenziert wurden. Die Rohdaten und R-Skript sind online.

```
## 3 x 30 sparse Matrix of class "dgCMatrix"
##
## CD3D  4 . 10 . . 1 2 3 1 . . 2 7 1 . . 1 3 . 2  3 . . . . . 3 4 1 5
## TCL1A . .  . . . . . . . 1 . . . . . . . . . . . . . . 1 . . . . . . . .
## MS4A1 . 6  . . . . . . . 1 1 1 . . . . . . . . . . 36 1 2 . . 2 . . . .
```

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Einzelzell-RNA-Sequenzierungsanalyse

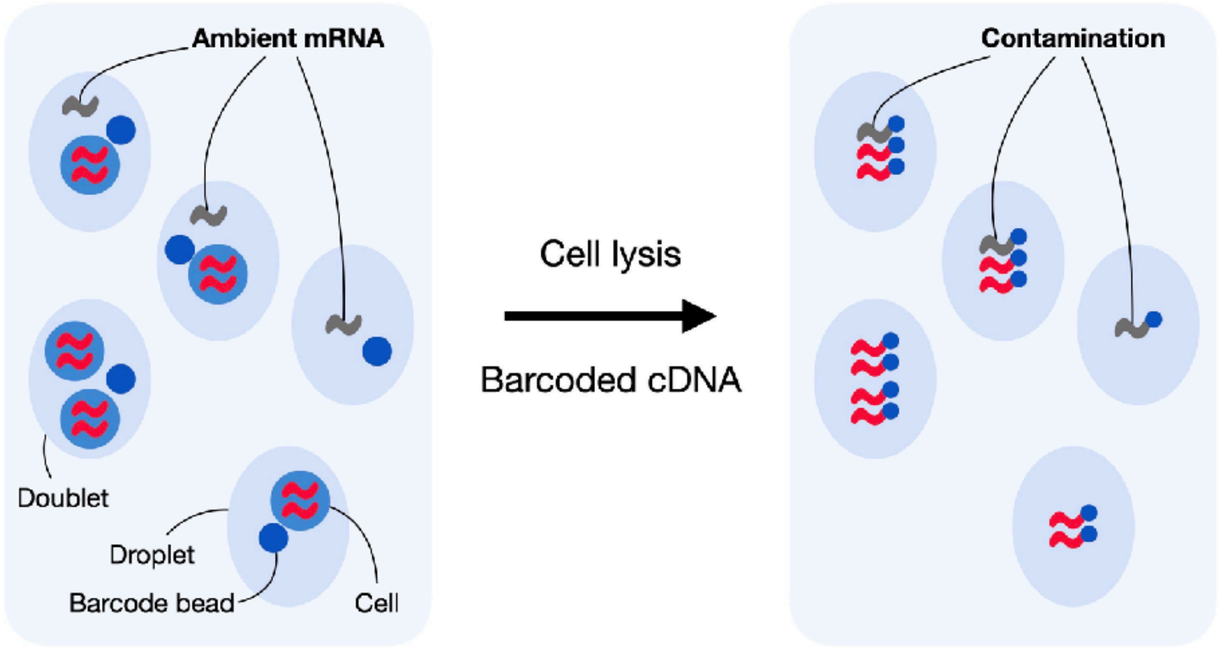


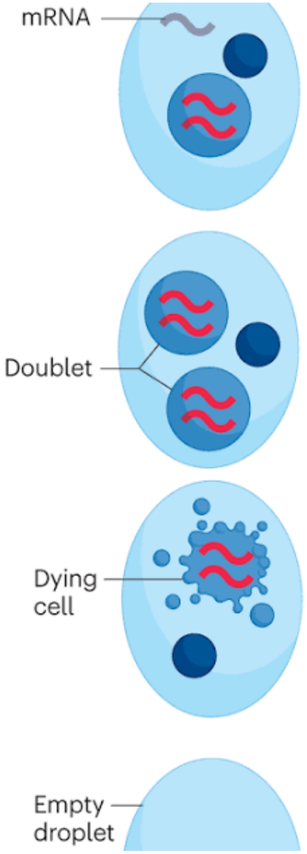
Datenvor-verarbeitung	Dimensions-verringerung	Clusterbildung
Zellen mit niedrigem Lesewert Leere Barcodes Doppelte Barcodes (Doublets)	PCA (Hauptkomponentenanalyse) t-SNE (t-verteilte stochastische Nachbar-Einbettung)	Leiden Clusterbildung Algorithm

1. Datenvorverarbeitung

Zellen von geringer Qualität oder leere Tröpfchen weisen oft nur sehr wenige Gene auf.

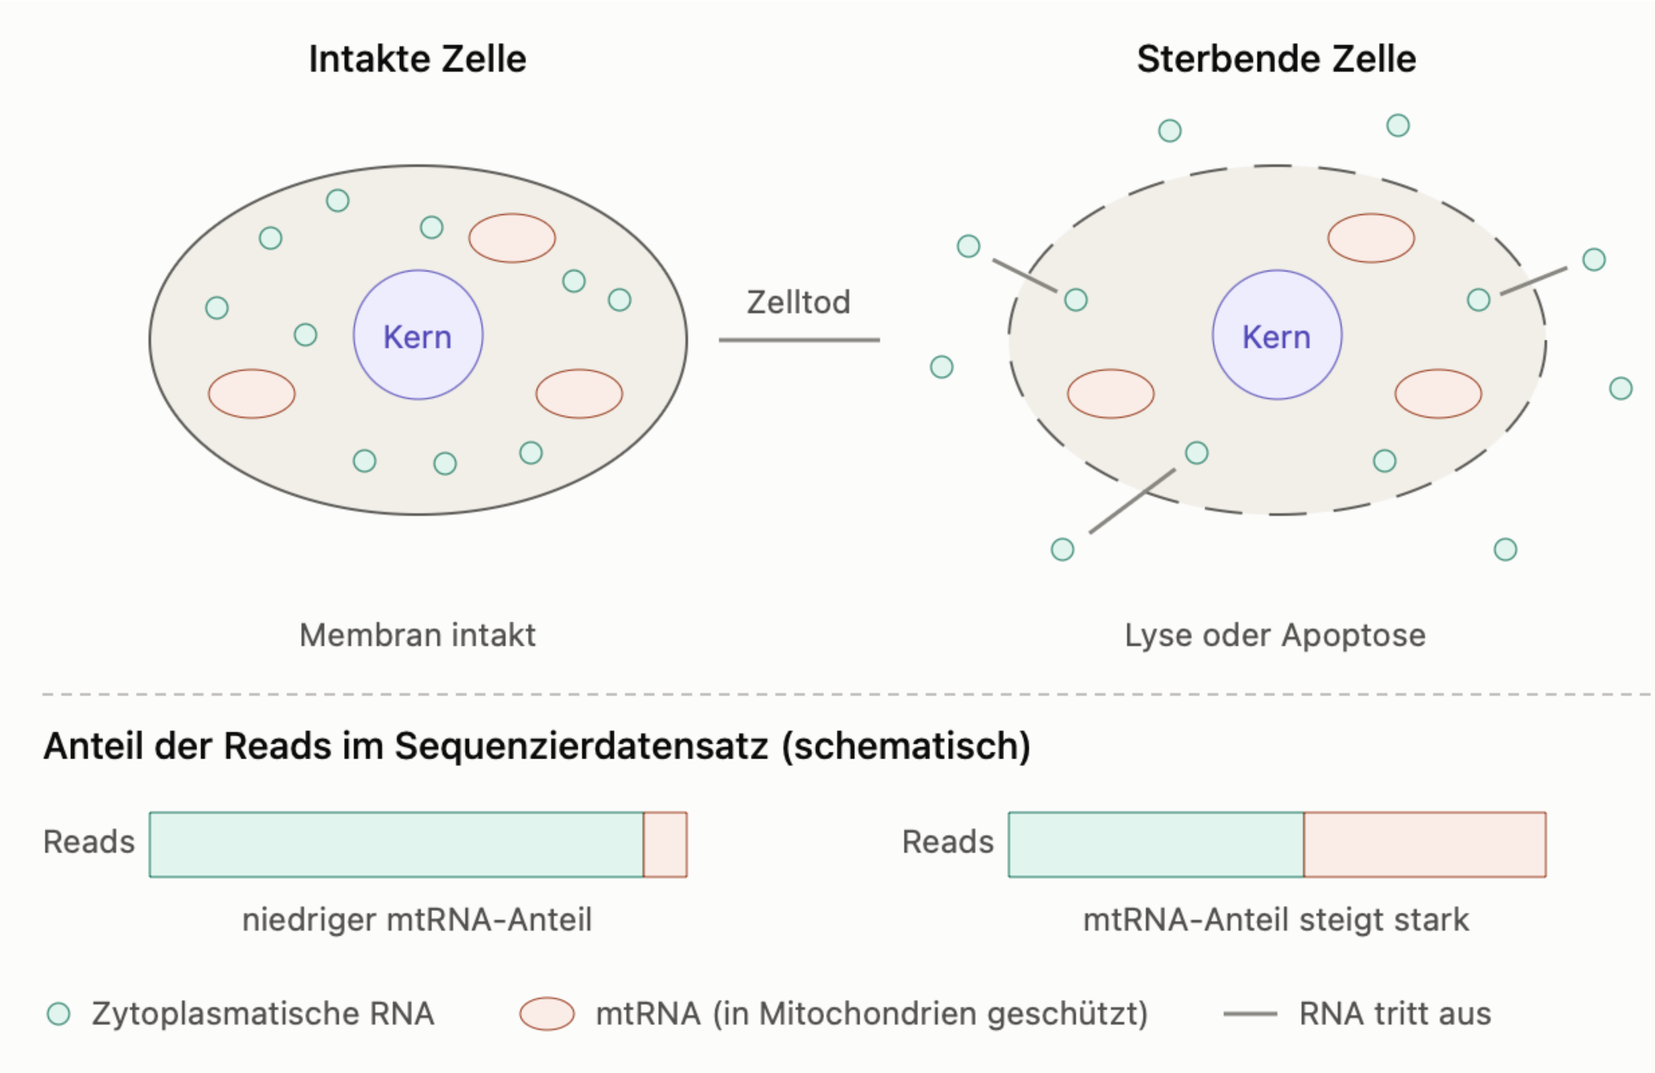
Zell-Doubletten oder -Multipletts können eine ungewöhnlich hohe Genanzahl aufweisen.





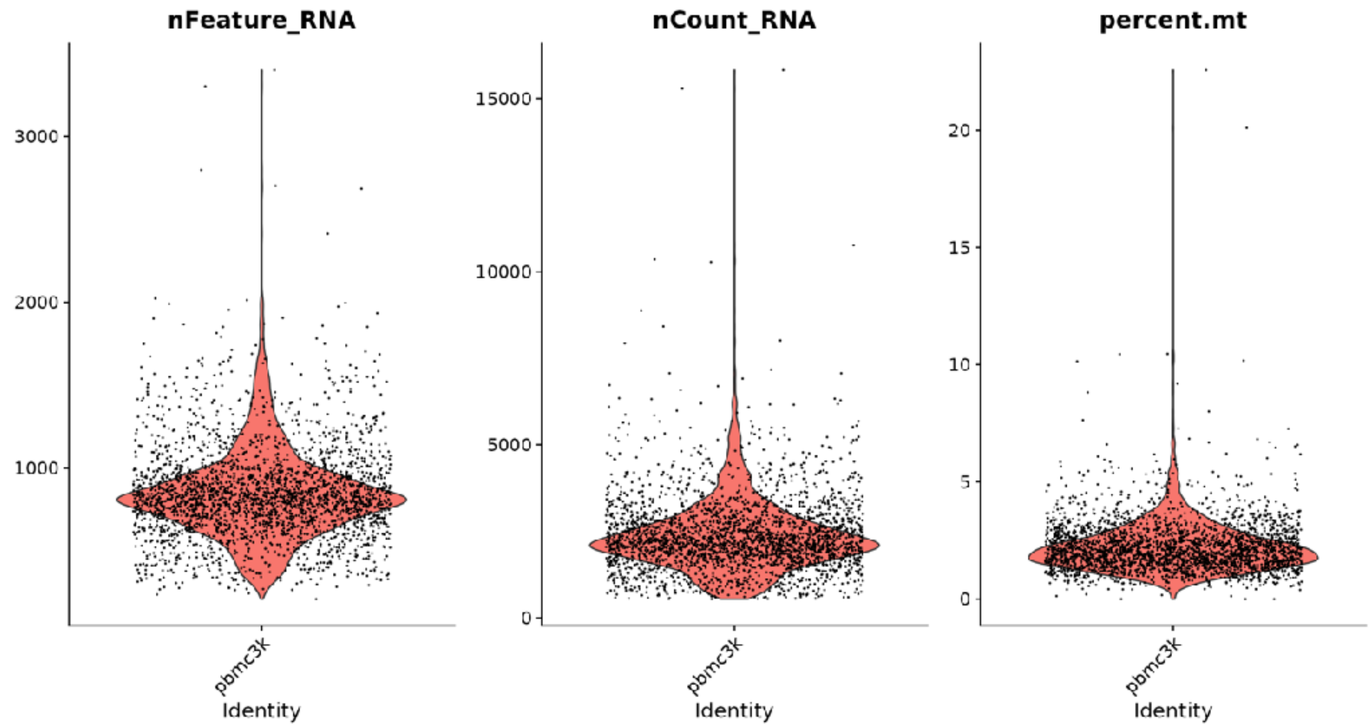
1. Datenvorverarbeitung

Zellen von geringer Qualität/sterbende Zellen weisen oft eine starke mitochondriale Kontamination auf.



1. Datenvorverarbeitung

Wir filtern Zellen, die mehr als 2.500 oder weniger als 200 einzigartige Merkmale aufweisen, sowie Zellen, die mehr als 5 % Mitochondrien enthalten.



2. Dimensionsverringerung

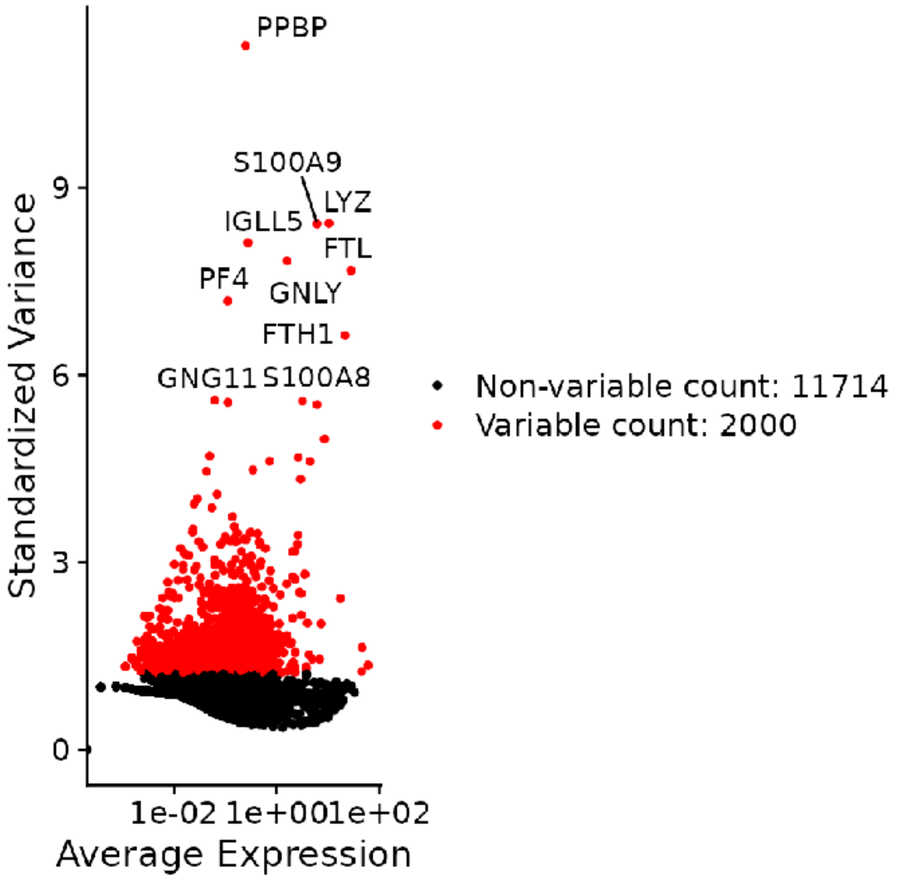
- Wenn Sie scRNA-seq-Daten messen, versuchen Sie, jede Zelle anhand der Expression ihrer Gene zu charakterisieren. Wenn ein Datensatz die Expression von 10.000 Genen misst, können Sie ihn als 10.000-dimensional beschreiben, was sehr viel ist.

- Obwohl diese Daten hochdimensional sind, kann ihre effektive Dimensionalität (d. h. die Anzahl der Dimensionen, die tatsächlich die Variation im Datensatz erfassen) viel geringer sein. Selbst wenn Sie beispielsweise über die Expressionsdaten für 10.000 Gene verfügen, können Sie die Unterschiede zwischen einer begrenzten Anzahl von Zelltypen möglicherweise mit nur wenigen Dimensionen quantifizieren.

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

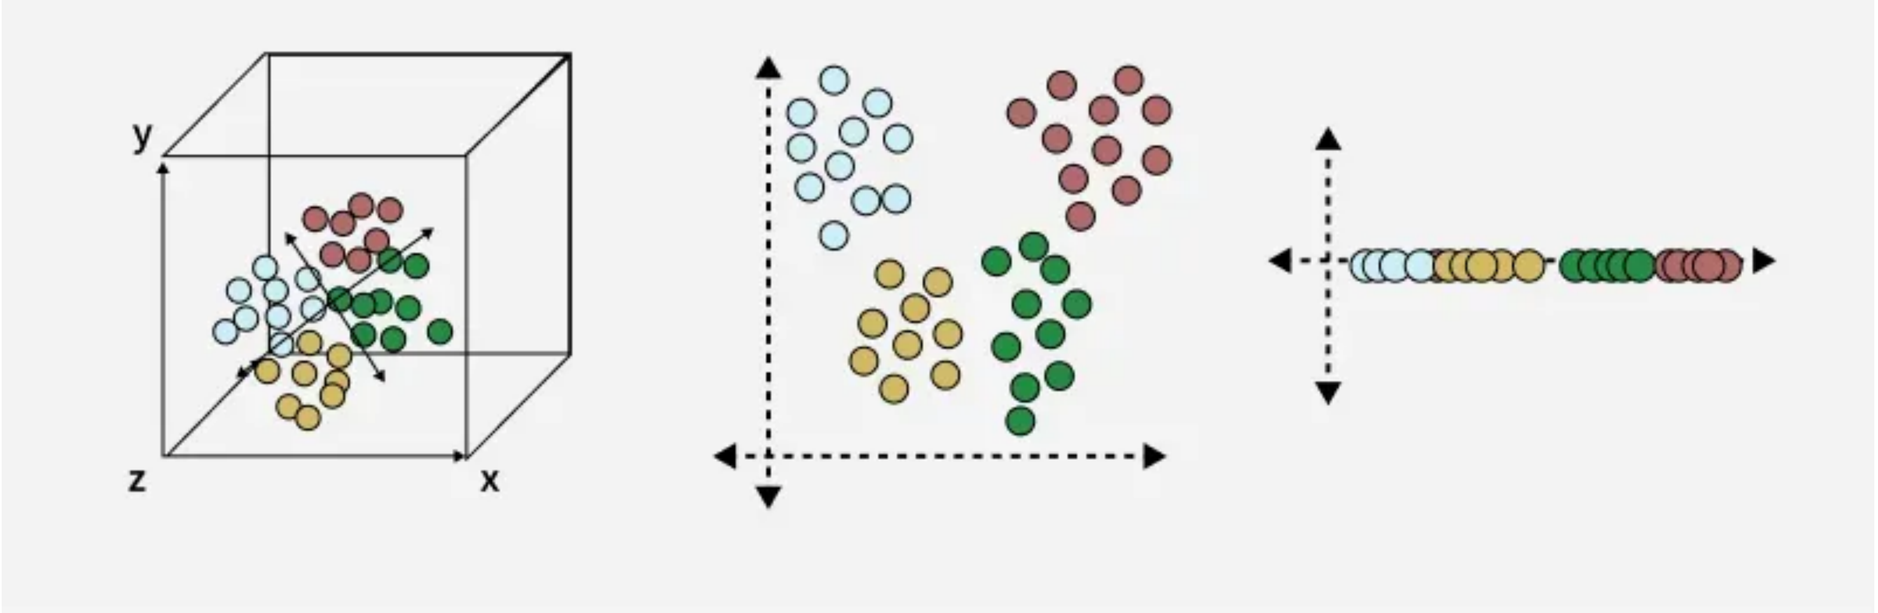
2. Dimensionsverringerung

Wir möchten Genexpressionen finden die die grösste Variation im Datensatz erfassen.



2. Dimensionsverringerung

Wir führen dann eine PCA durch. Diese Methode reduziert die Dimensionalität der Daten, indem sie sie in einen Raum mit geringerer Dimension transformiert und dabei so viel Variation wie möglich beibehält. Sie sucht nach einer Kombination von höchst variierende Genexpressionen, den sogenannten Hauptkomponenten.



Das Streben nach reduzierten Dimensionen: PCA

Das „Schülerleistungs“-Beispiel:

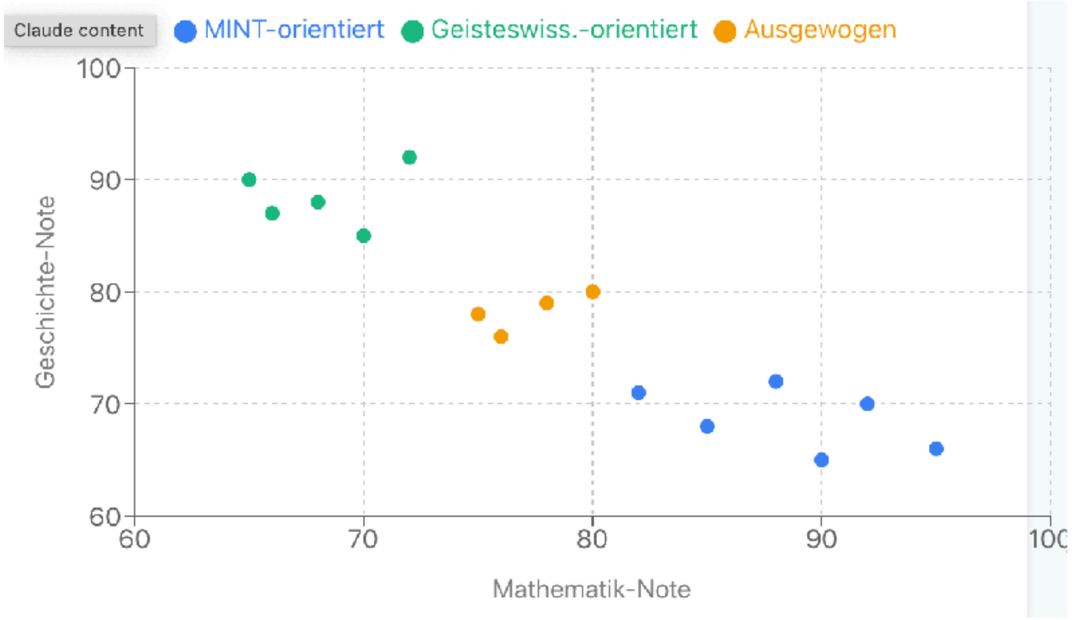
Stellt euch vor, ihr befragt 100 Schüler und erfasst ihre Noten in 6 Fächern: Mathematik, Physik, Chemie, Biologie, Geschichte und Englisch.

Wenn ihr die Daten betrachtet, bemerkt ihr etwas Interessantes:

Schüler, die gut in Mathe sind, tendieren auch dazu, gut in Physik, Bio und Chemie zu sein

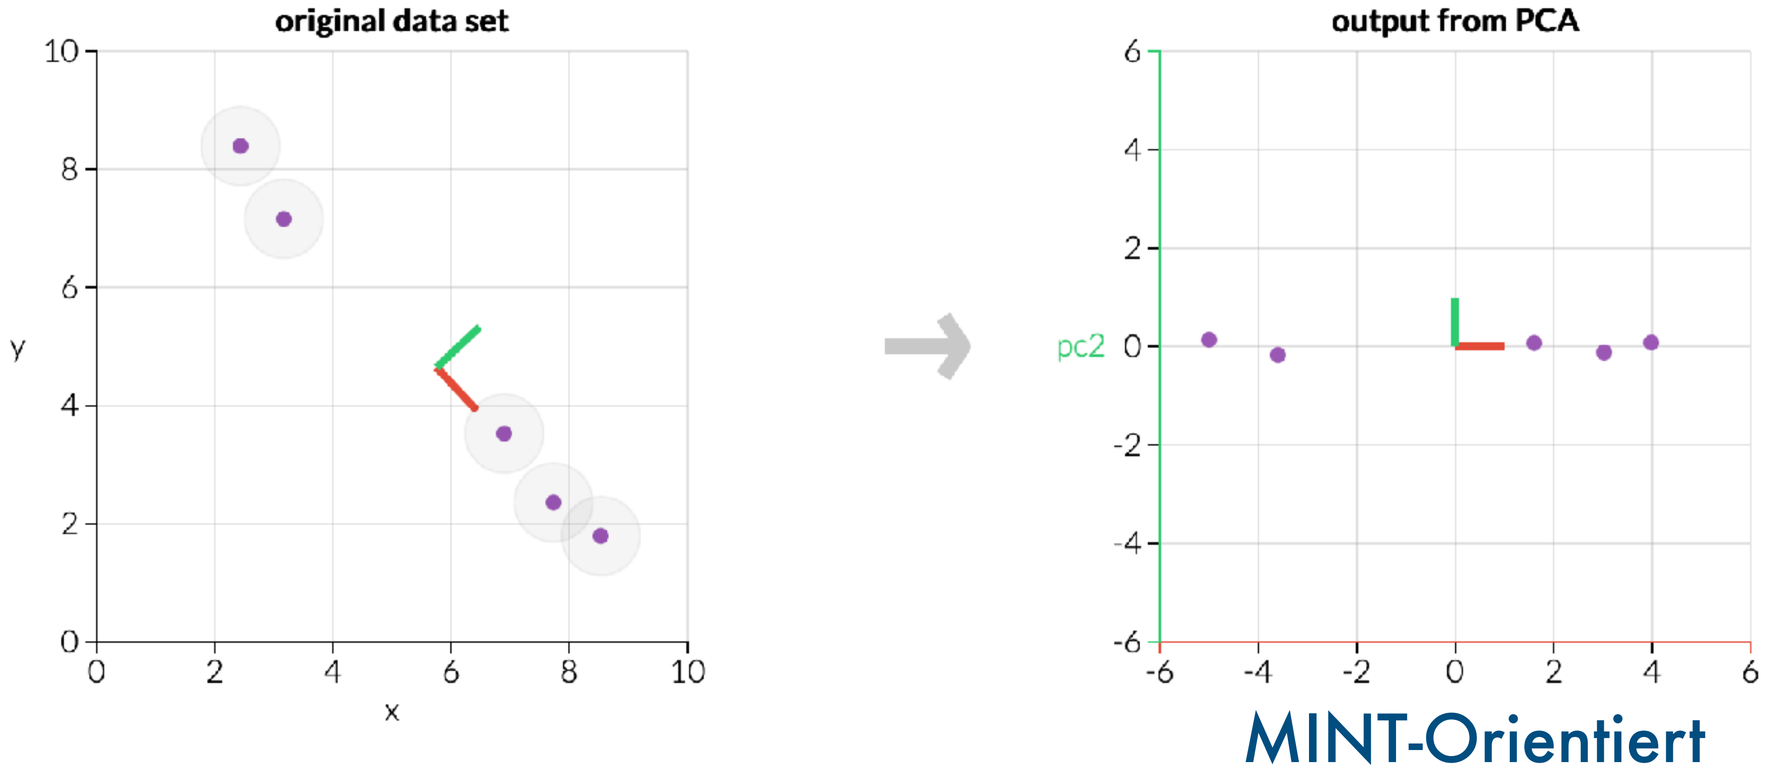
Schüler, die gut in Geschichte sind, tendieren dazu, gut in Englisch zu sein.

Hier kommt Dimensionsverringerung ins Spiel: Anstatt 5 separate Noten zu verfolgen, können wir eine „MINT-Orientiert“-Achse oder eine „Geisteswissenschaften"-Achse definieren.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Hauptkomponentenanalyse (PCA)

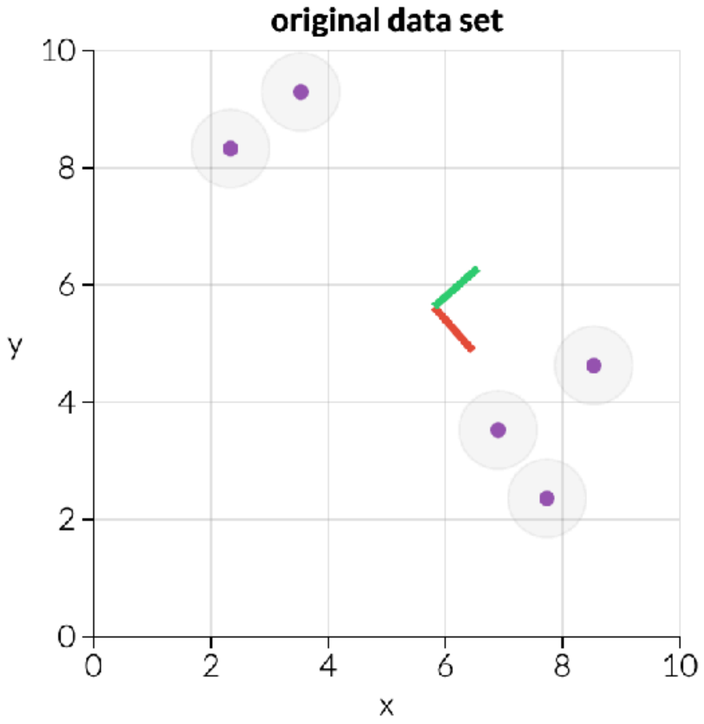


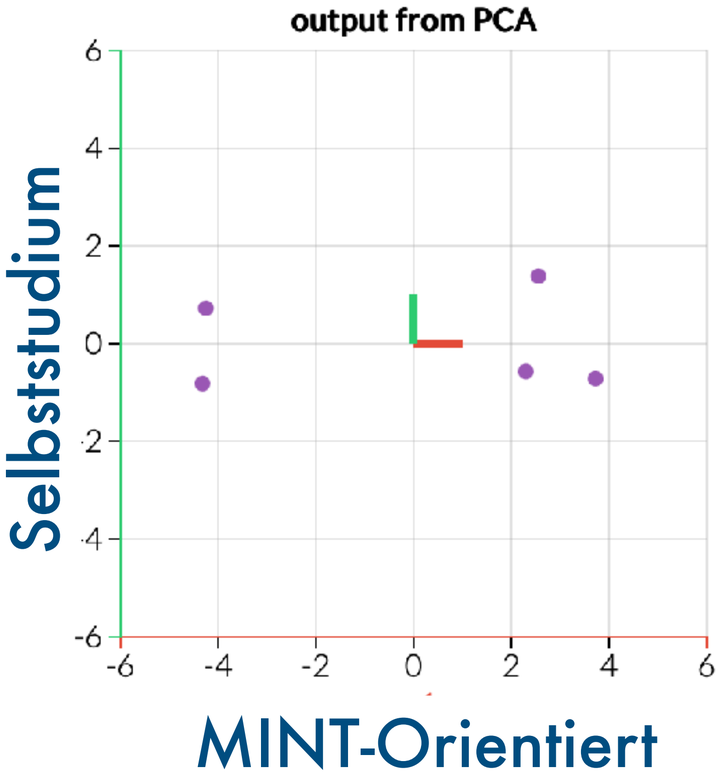
MINT-Orientiert

zur Simulation: https://setosa.io/ev/principal-component-analysis/

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Dimensionsverringerung durch PCA





zwei Dimensionen erklären die Daten: 2 Dimensionen statt 6 Fächer

Zusammenfassung: PCA

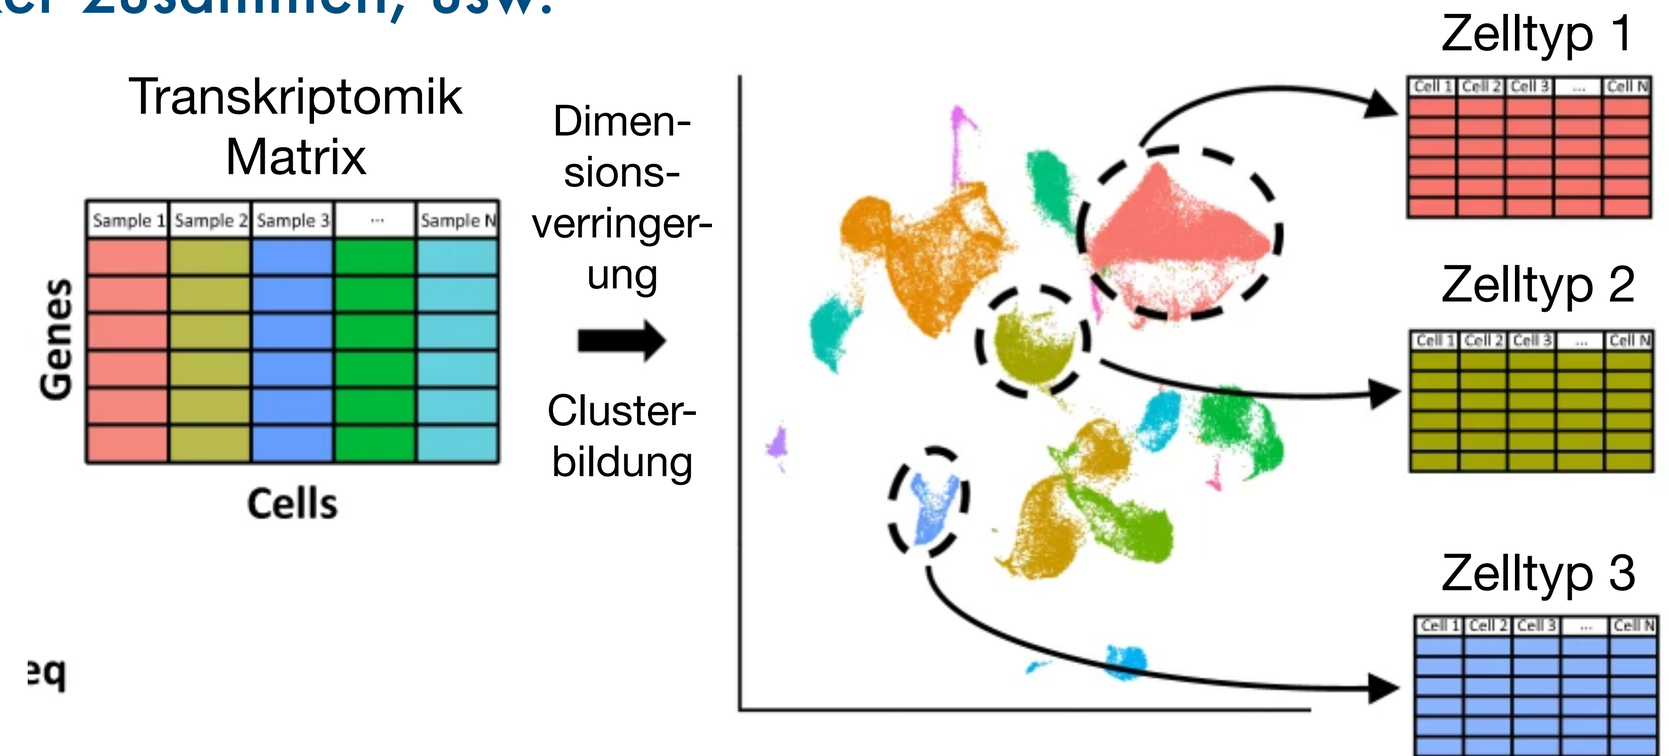
Das Verfahren ist der Idee nach:

- Finde Achse mit grösster Datenvarianz (grösste Varianz der Daten, wenn man auf Achse projiziert) => 1. Hauptkomponenten (PC1)
- Projiziere Daten auf Datenraum der orthogonal = senkrecht zu PC1 steht und wiederhole bis du im 2D Fall angelangt bist

- 2-dimensionale PCA-Plots erlauben einem eine erste explorative Datenanalyse von hochdimensionalen Daten.
- Man sieht (potentiell), welche Datenelemente ähnlich sind und ob es Gruppenstrukturen (Cluster) gibt.
- Man erhält einen Hinweis, wie schwierig es für Machine Learning Methoden ist, Klassen zu bilden

Warum PCA in Transkriptomik?

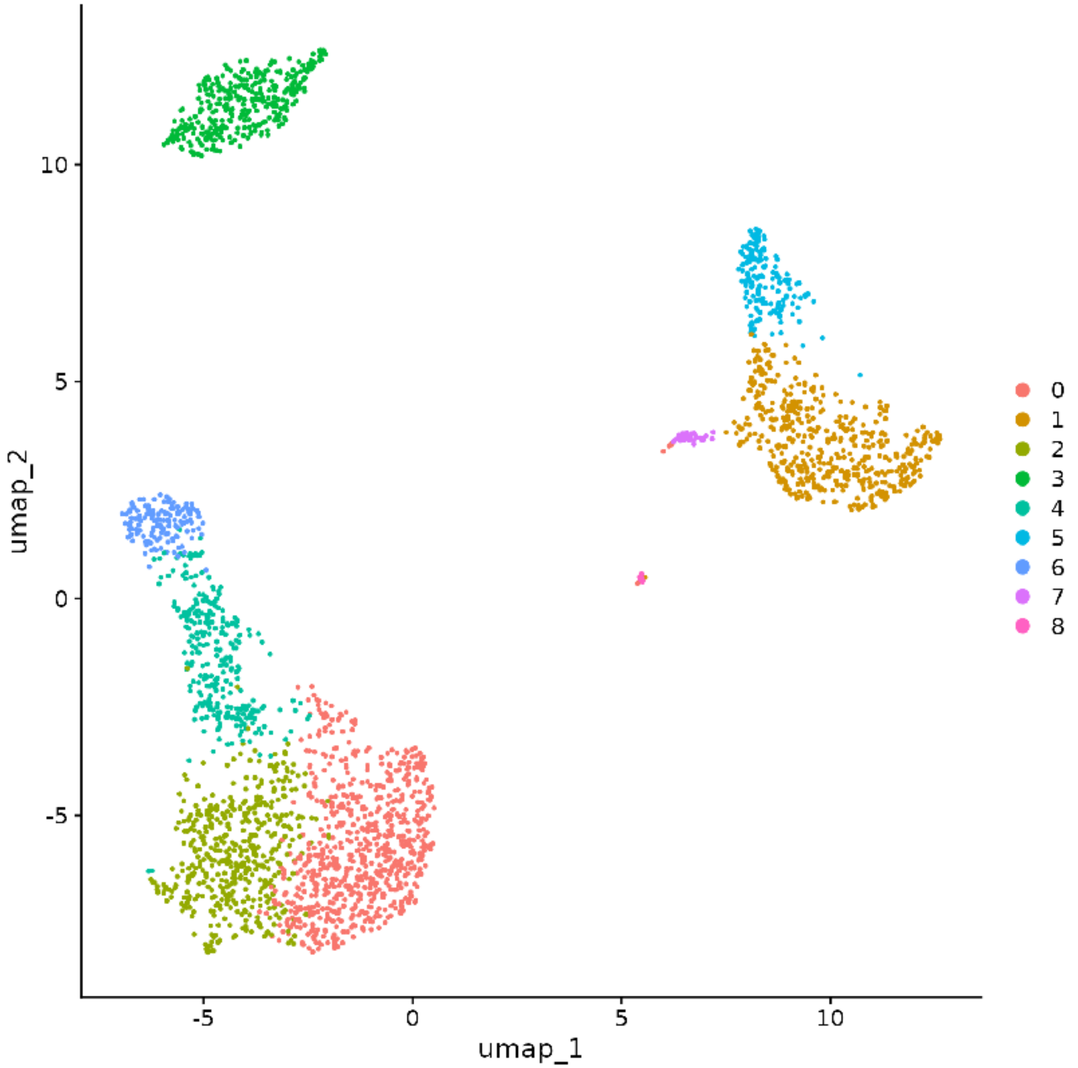
Bei der Genexpression haben wir statt 5 Fächern 20.000 Gene. Statt 100 Schülern haben wir Tausende von Zellen. Gene, die zusammen variieren (wie Zelltyp-Marker), werden zur gleichen Hauptkomponente beitragen. - z.B. alle Immunzell-Marker zusammen, alle Neuronen-Marker zusammen, usw.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

3. Clusterbildung von Zellen

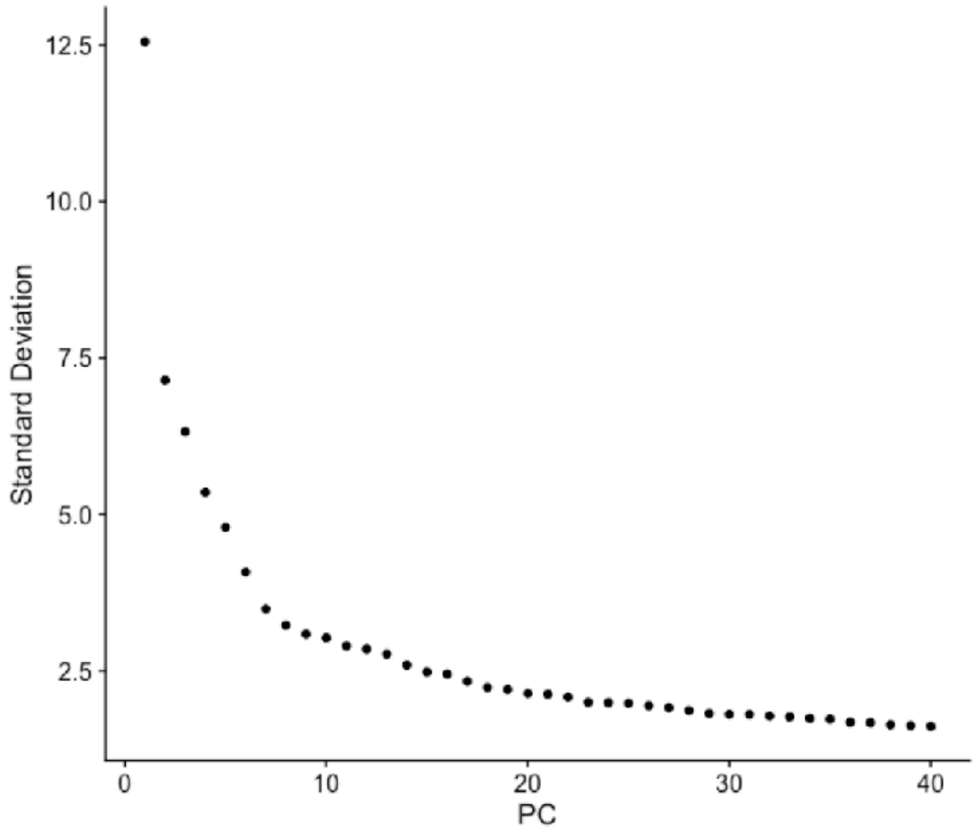
Seurat führt zunächst eine graphbasierte Clusterbildung durch und führt anschliessend eine nichtlineare Dimensionsreduktion (UMAP/tSNE) durch. Dadurch werden ähnliche Zellen anhand ihrer Genexpression gruppiert, um Gruppen von Zellen zu finden, die häufiger miteinander in Verbindung stehen als andere.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Wie viele Clusters?

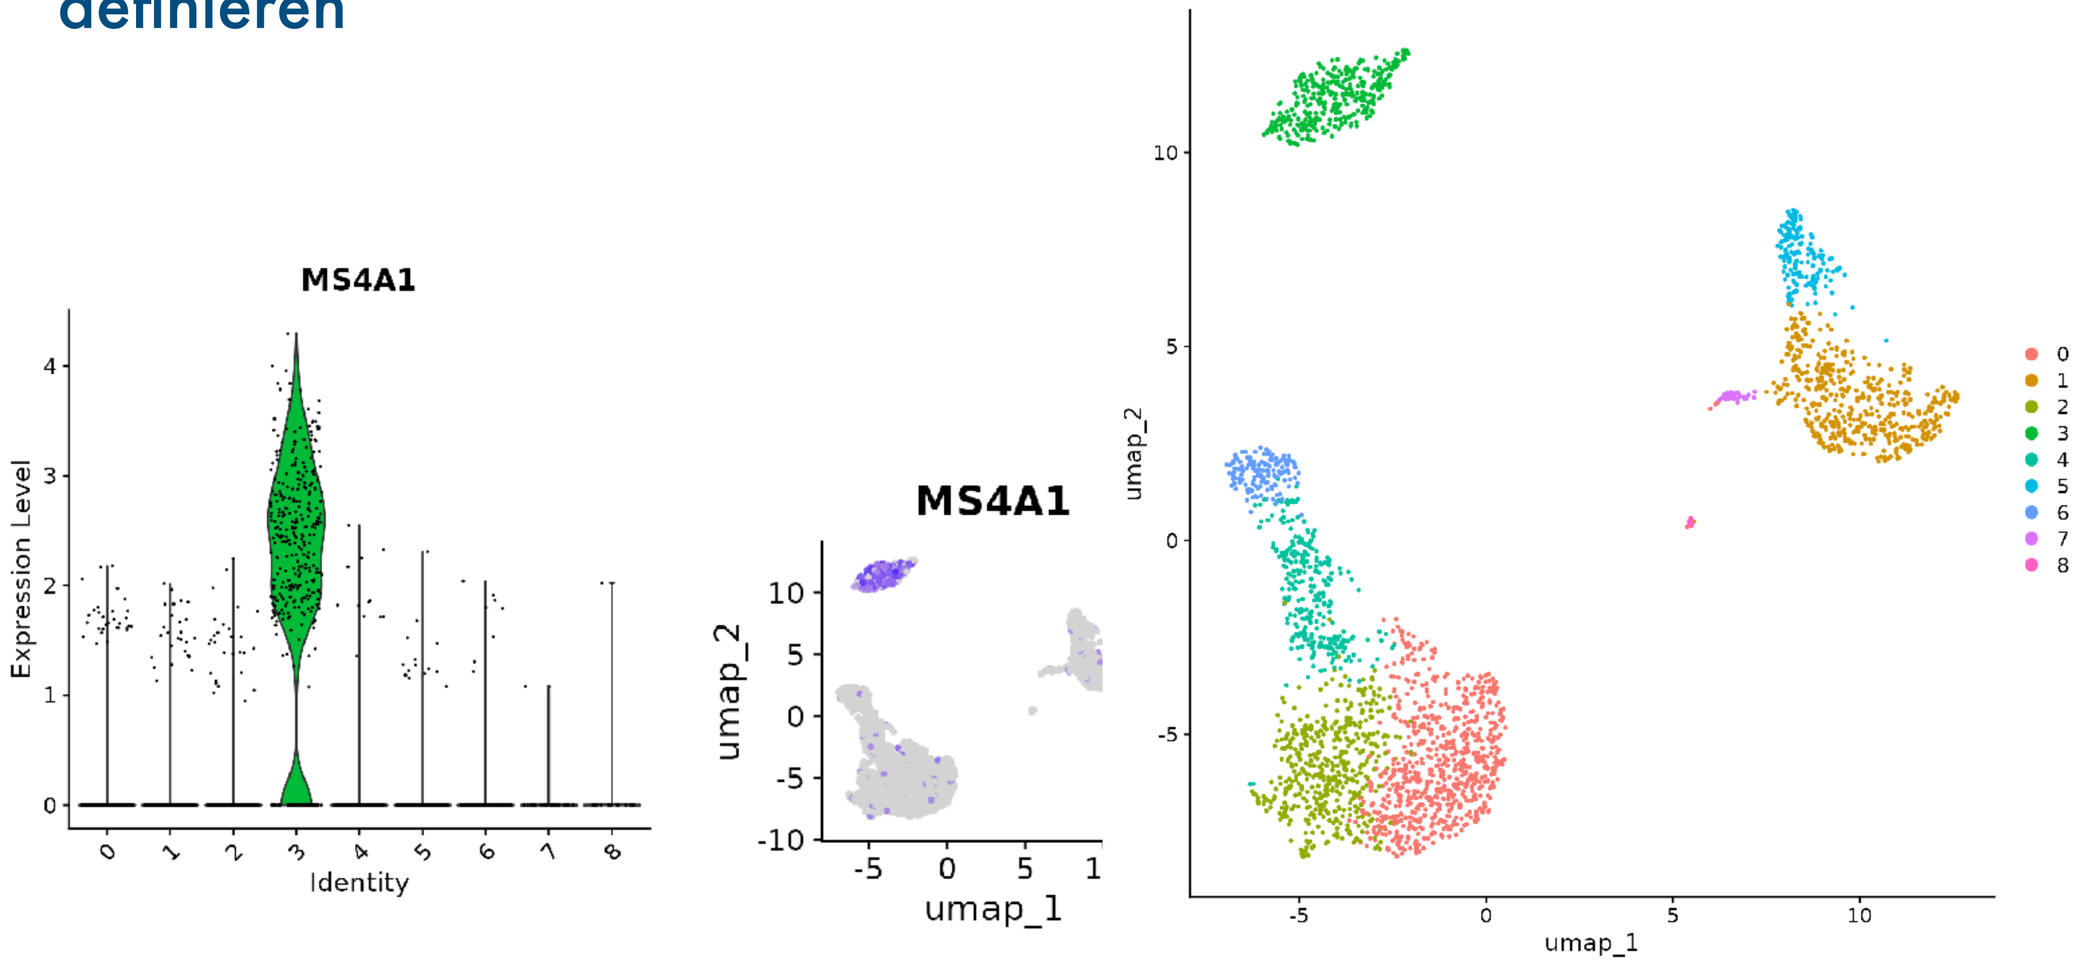
Dazu verwenden wir die Darstellung der Hauptkomponenten aus der PCA und deren jeweilige Erklärungskraft. Der Punkt, an dem wir den Knick sehen, ist der Cut-out-Wert. Es ist nicht notwendig, weitere Dimensionen zu berücksichtigen, da diese keinen wesentlichen Beitrag zur Erklärung der Daten mehr leisten.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

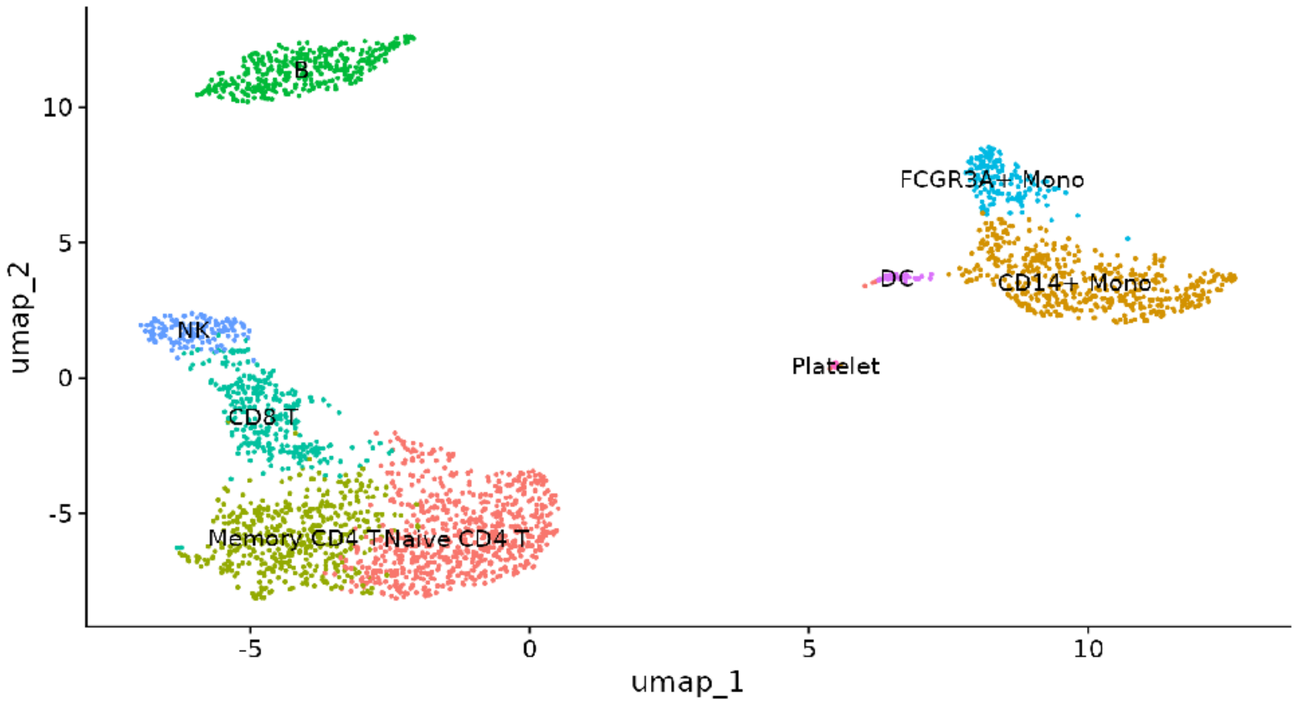
Downstream Analyse

Marker-Gene finden, die Cluster über differentielle Expression definieren



Downstream Analyse

Zuweisung der Zelltyp-Identität zu Clustern auf Grundlage der Literatur: Erstellung einer Expressions-Heatmap für bestimmte Zellen und Merkmale für die wichtigsten Marker.



Cluster ID	Markers	Cell Type
0	IL7R, CCR7	Naive CD4+ T
1	CD14, LYZ	CD14+ Mono
2	IL7R, S100A4	Memory CD4+
3	MS4A1	B
4	CD8A	CD8+ T
5	FCGR3A, MS4A7	FCGR3A+ Mono
6	GNLY, NKG7	NK
7	FCER1A, CST3	DC
8	PPBP	Platelet