Transcriptomics: single cell RNAseq

Bioinformatics & Omics

Dr. Tugce Bilgin Sonay, HSLU, 2026

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Lernziele

- Schritte in Einzelzelle-Analyse motivieren, diese in R ausführen und Ausgaben interpretiere
  - Einzelzell-Transkriptomik-Matrix erstellen
  - Differentielle Expressionsanalyse mit PCA ausführen
  - Clusters mit UMAP und t-SNE bilden um die Katogorien zu identifizieren
- Gene und Pathway Enrichment Analyse durchführen
- Zwecke von räumlichen Einzelzell-Sequenzieren beschreiben

Recap: Vor- und Nachteile der Einzelzell-Transkriptomik

Vorteile: Einzelzell–Seq-Daten haben viel tiefere Resolution, die besonders im Medizinbereich benötigt ist. Für Krebsforschung zB wird Einzelzell-Analyse zu einem Muss.

Nachteile:

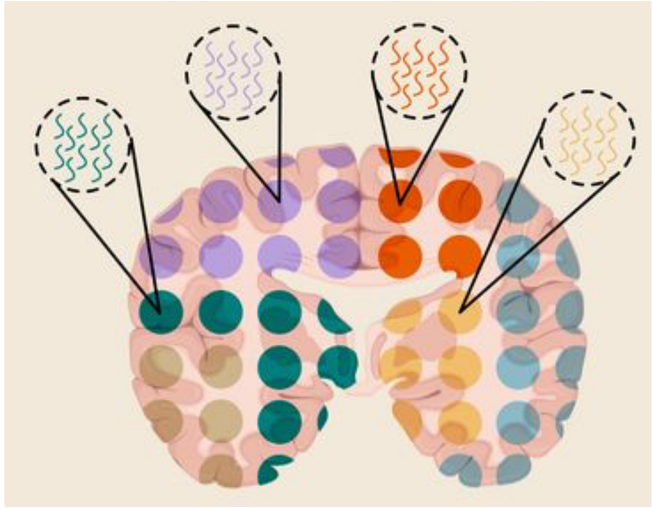
- sehr geringe Mengen an RNA-Ausgangsmaterial
- anfälliger für Artefakte
- erhebliche Variabilität in der Genexpression und deswegen erhöhte Unsicherheit bei der Beurteilung der Transkriptionszustände

Empfehlung: Sequenzierung von mehr Zellen

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

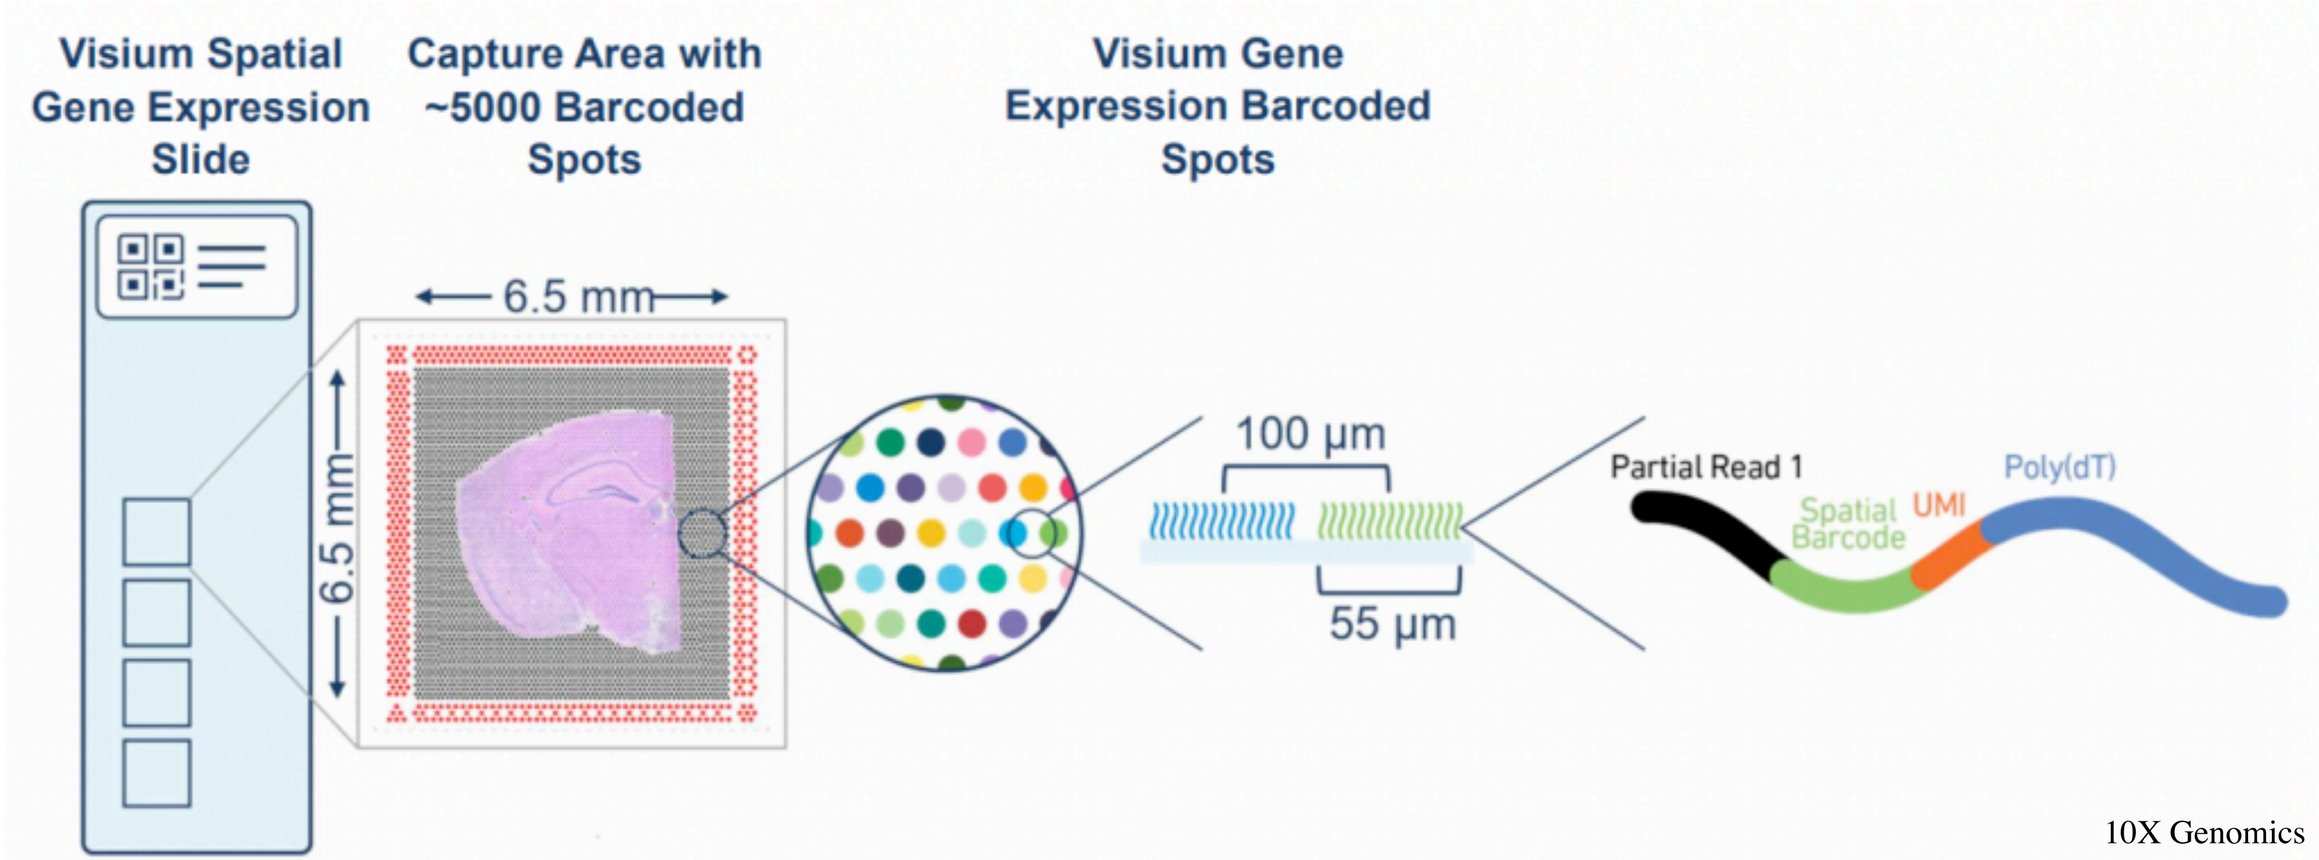
Räumliche Transkriptomik

- ermöglicht dass, die die Genexpression bestimmten Stellen innerhalb eines Gewebes zuordnet und so ein umfassenderes Verständnis der Organisation und Interaktion von Zellen.
- kombiniert die Hochdurchsatz-Genexpressionsprofilierung mit Positionsinformationen und ermöglicht es Forschern so, zu sehen, wie verschiedene Gene an bestimmten Stellen innerhalb eines Gewebes in seinem natürlichen Zustand exprimiert werden.
- ist ein leistungsstarkes Werkzeug für die Forschung in Bereichen wie Krebs und Entwicklungsbiologie.



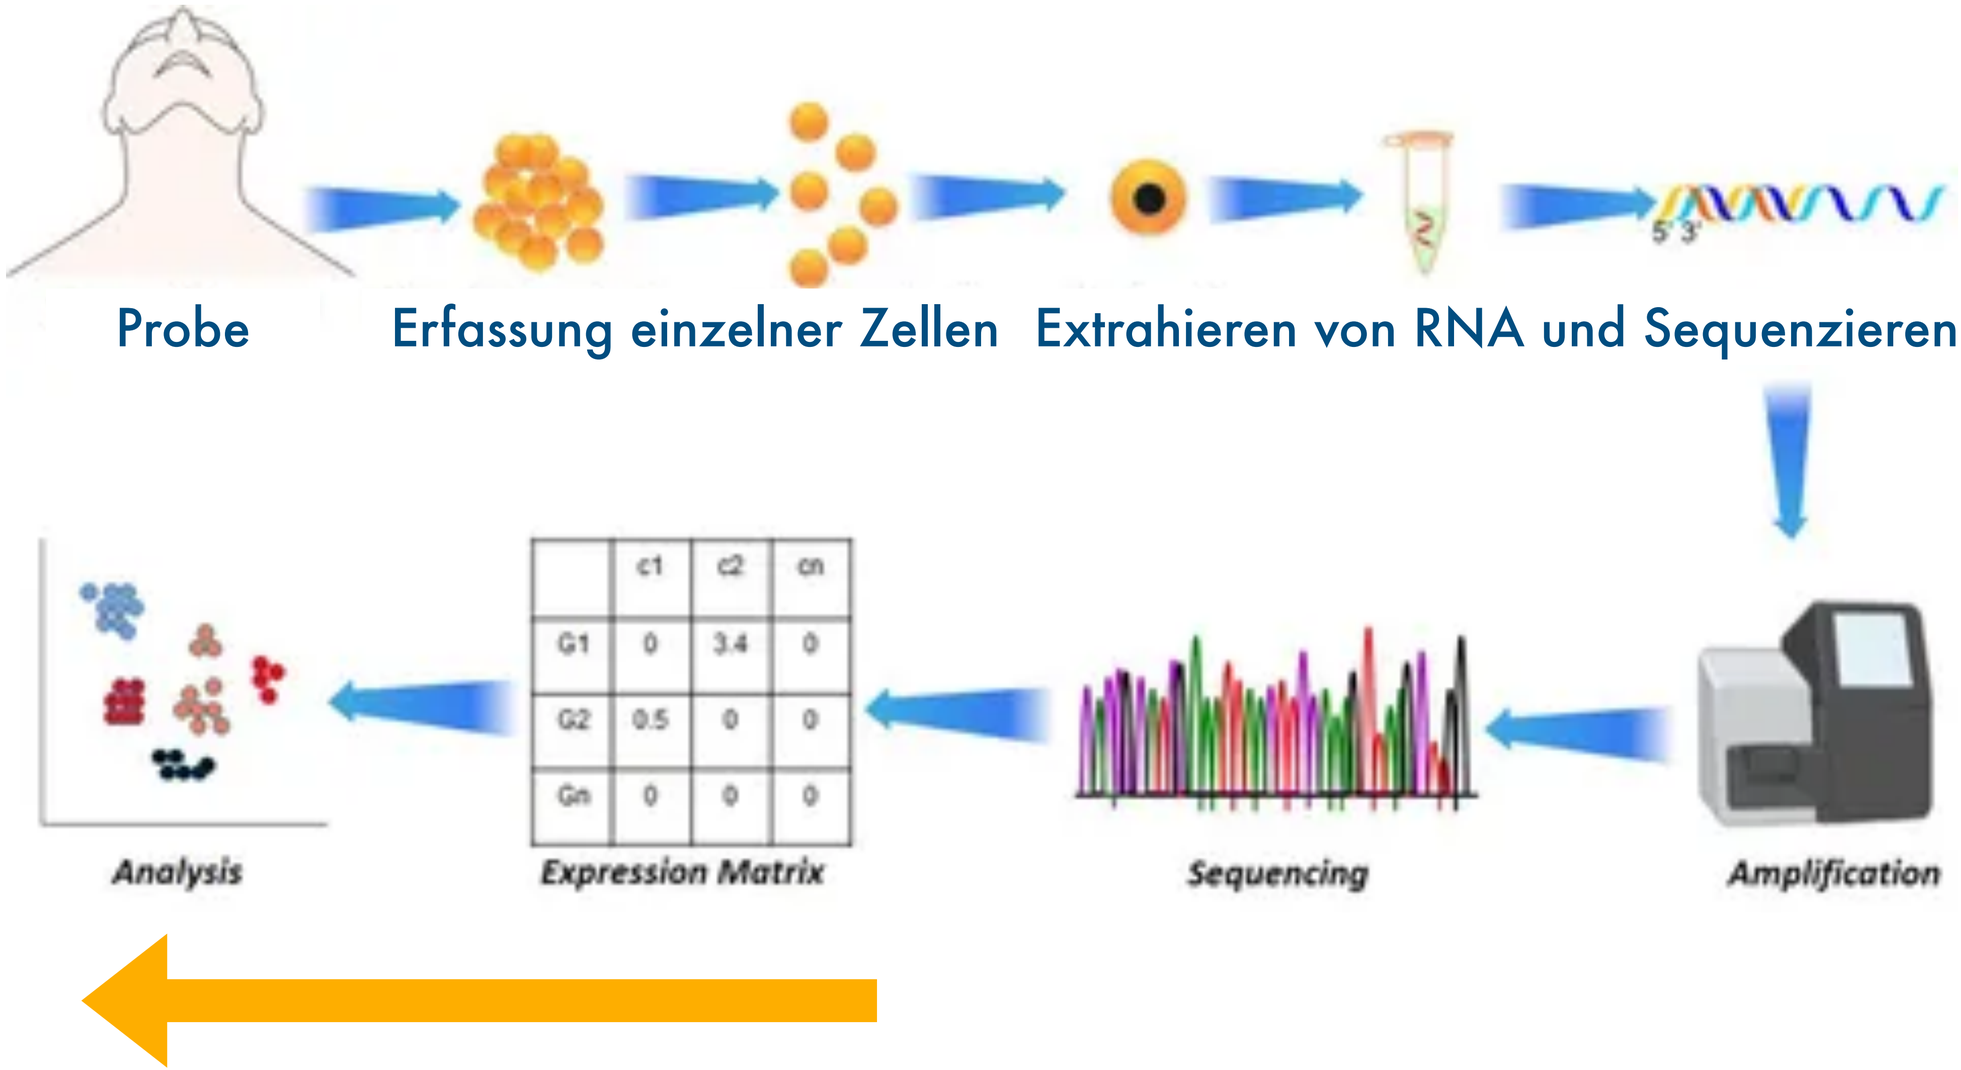
Kombiniere: Single Cell und Spatial Transcriptomics

Die erste weit verbreitete Methode wurde in einer bahnbrechenden Veröffentlichung im Jahr 2016 in Science beschrieben, in der der Begriff „räumliche Transkriptomik“ geprägt wurde. Im Jahr 2018 erwarb 10X Genomics Spatial Transcriptomics als Grundlage für die 10X Visium-Plattform.



10X Genomics

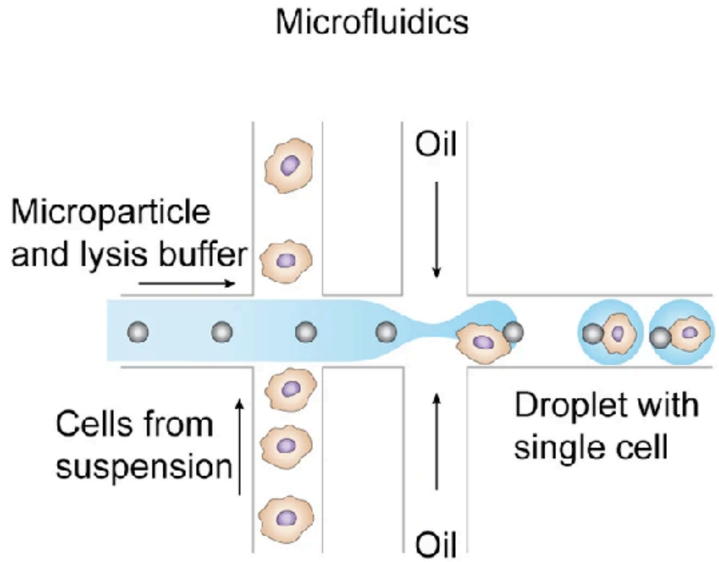
Recap: Einzelzell-Transkriptomik Pipeline



Recap: Technologien zur Erfassung einzelner Zellen

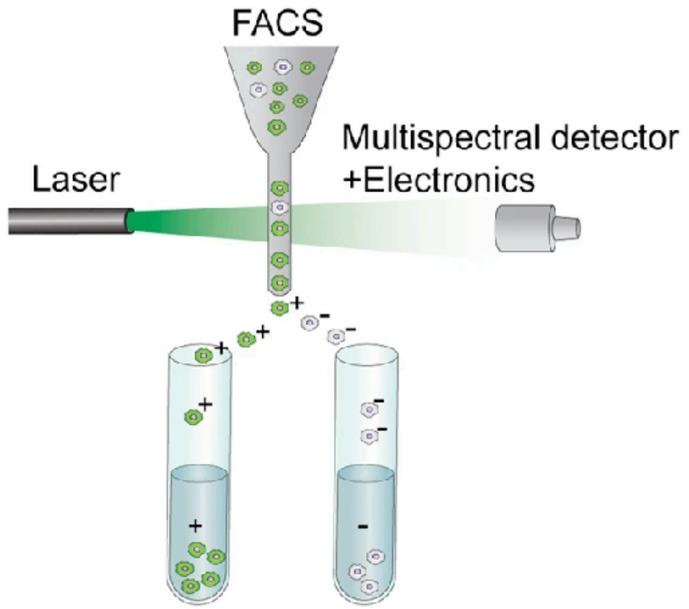
10X

- höchster Durchsatz auf dem Markt
- geringere Kosten
- keine vollständige Sequenzinformationen



SmartSeq

- die höchste Empfindlichkeit
- volle Sequenzinformationen
- teuer



Hwang, B., et al.. *Exp Mol Med* 2018

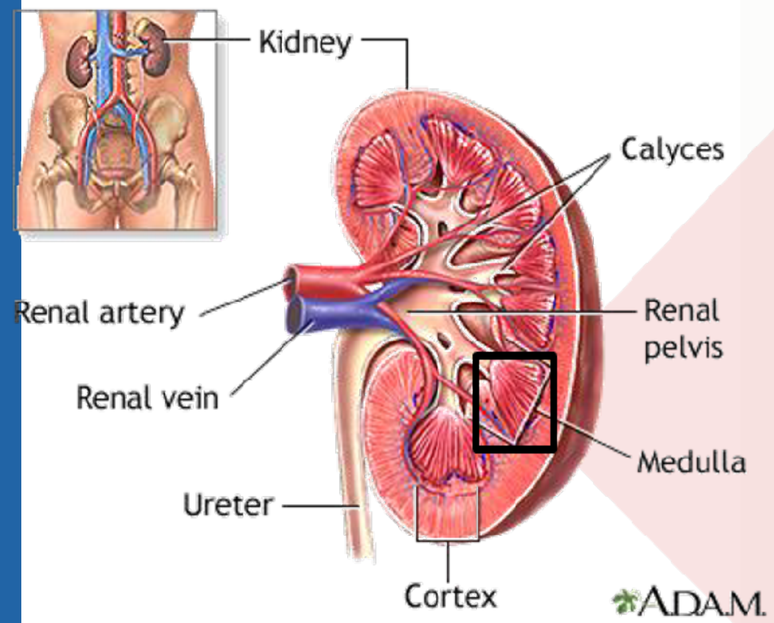
Letztes Mal: 10X Daten in R

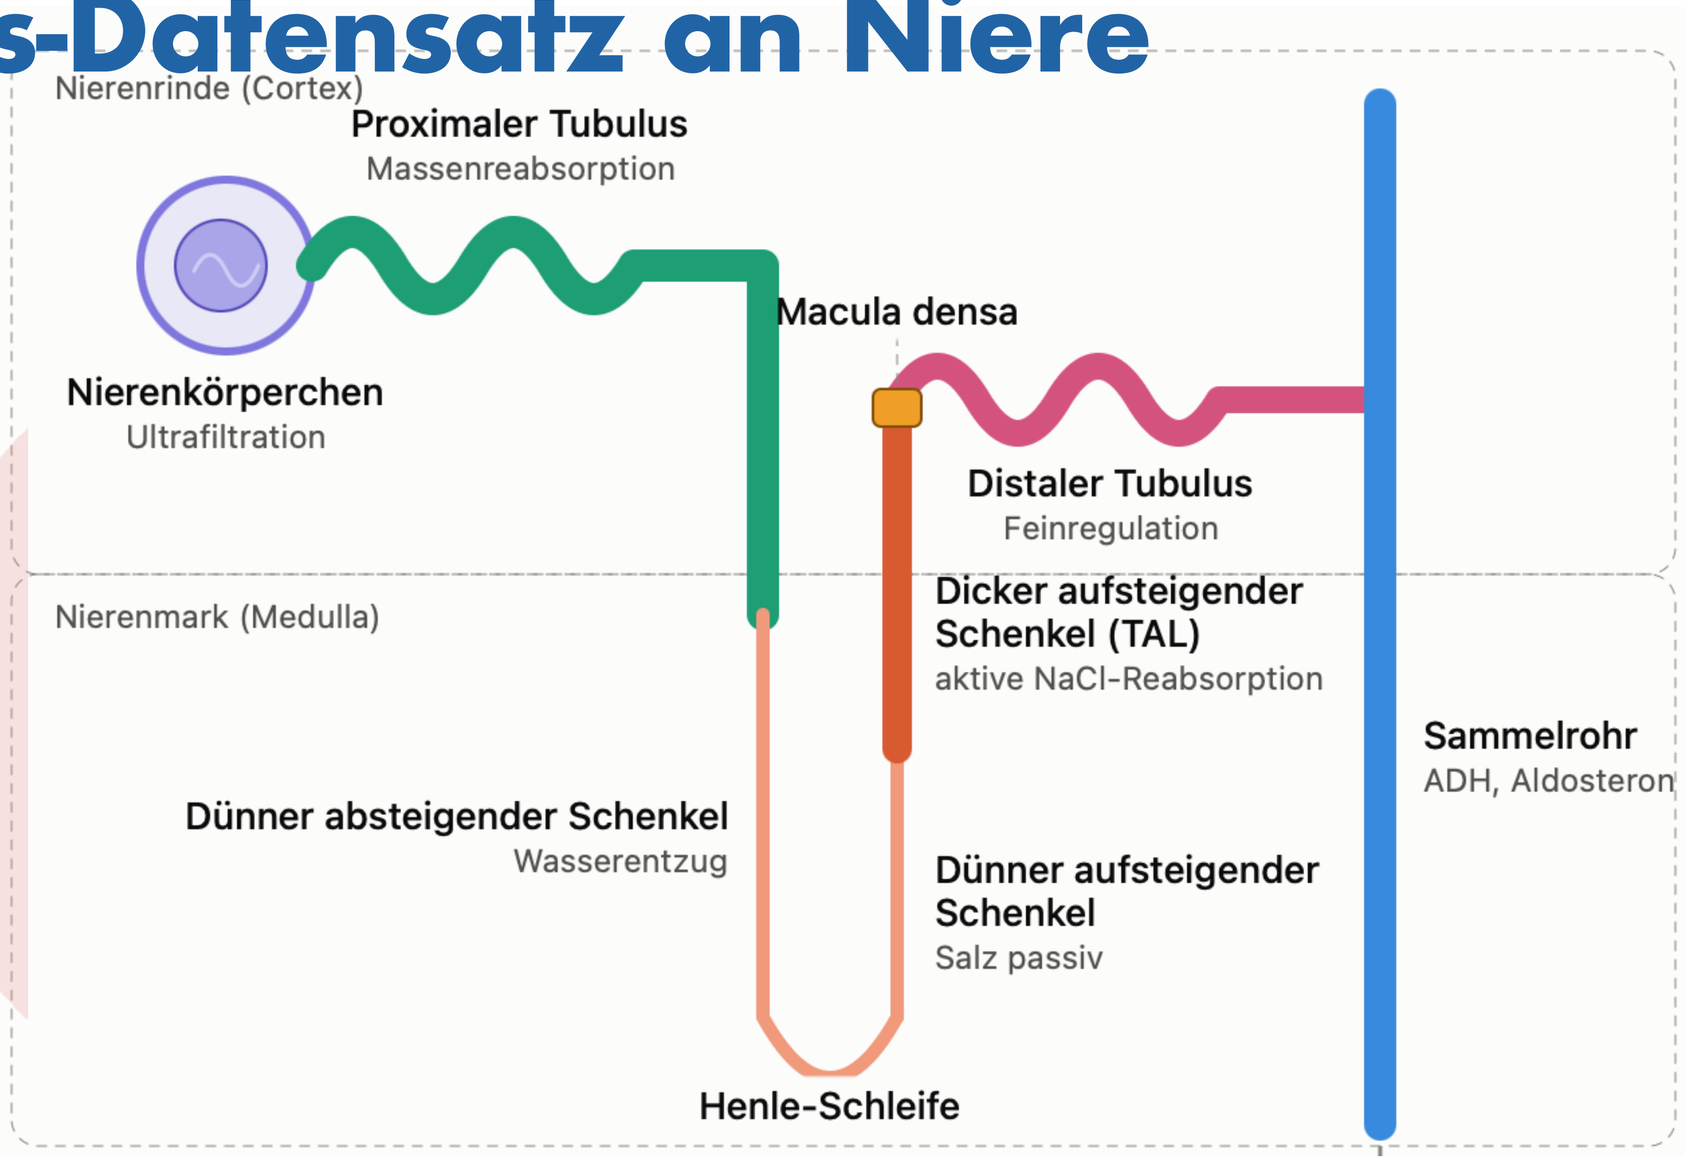
Datensatz von peripheren mononukleären Blutzellen, der von 10X Genomics frei verfügbar ist. Es handelt sich um 2.700 Einzelzellen, die auf dem Illumina NextSeq 500 sequenziert wurden. Die Rohdaten und R-Skript sind online.

```
## 3 x 30 sparse Matrix of class "dgCMatrix"
##
## CD3D  4 . 10 . . 1 2 3 1 . . 2 7 1 . . 1 3 . 2  3 . . . . . 3 4 1 5
## TCL1A . .  . . . . . . . 1 . . . . . . . . . . . . . . 1 . . . . . . . . .
## MS4A1 . 6  . . . . . . . 1 1 1 . . . . . . . . . . 36 1 2 . . 2 . . . .
```

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Heute: Haus-Datensatz an Niere

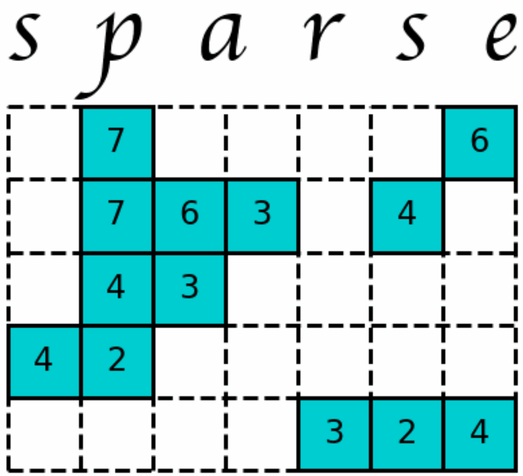




310 Zellen sequenziert mit Smart Seq

spärliche vs. dichte Matrix

Wenn es um viele Null-Werte in Daten gibt, dann speichert man die Daten als spärliche Matrix.



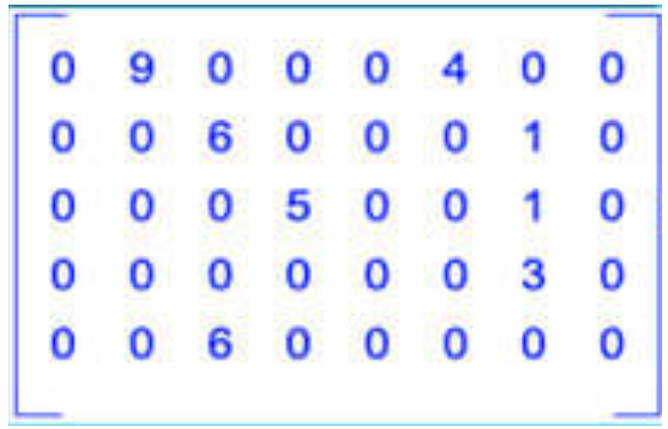
DENSE

0	7	0	0	0	0	6
0	7	6	3	0	4	0
0	4	3	0	0	0	0
4	2	0	0	0	0	0
0	0	0	0	3	2	4

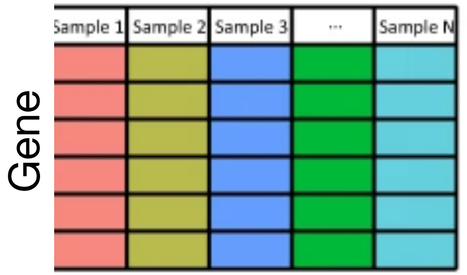
spärliche vs. dichte Matrix

Wir möchten zuerst unsre Daten in dichten Form umwechseln

ROW	COL	VALUE
0	1	9
0	5	4
1	2	6
1	6	1
2	3	5
2	6	1
3	6	3
4	2	6



Transkriptomik Matrix



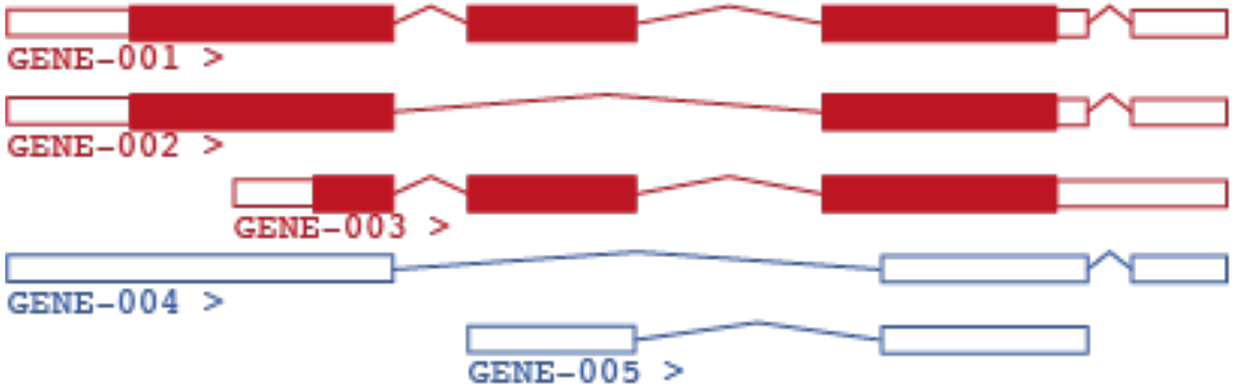
Ensemble IDs vs Gen Symbol

Ensemble ID unterscheidet sich zwischen gleichen Gene von Organismen, Transkripten vs Genen usw. zB:

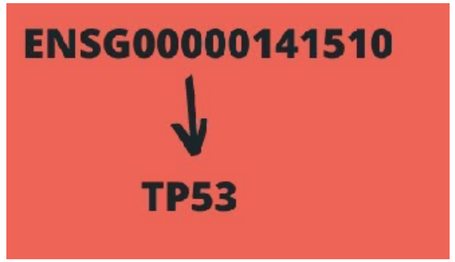
ENSG... : Gen ID

ENST...: Transkript ID

ENSMUSG: Maus Gen ID

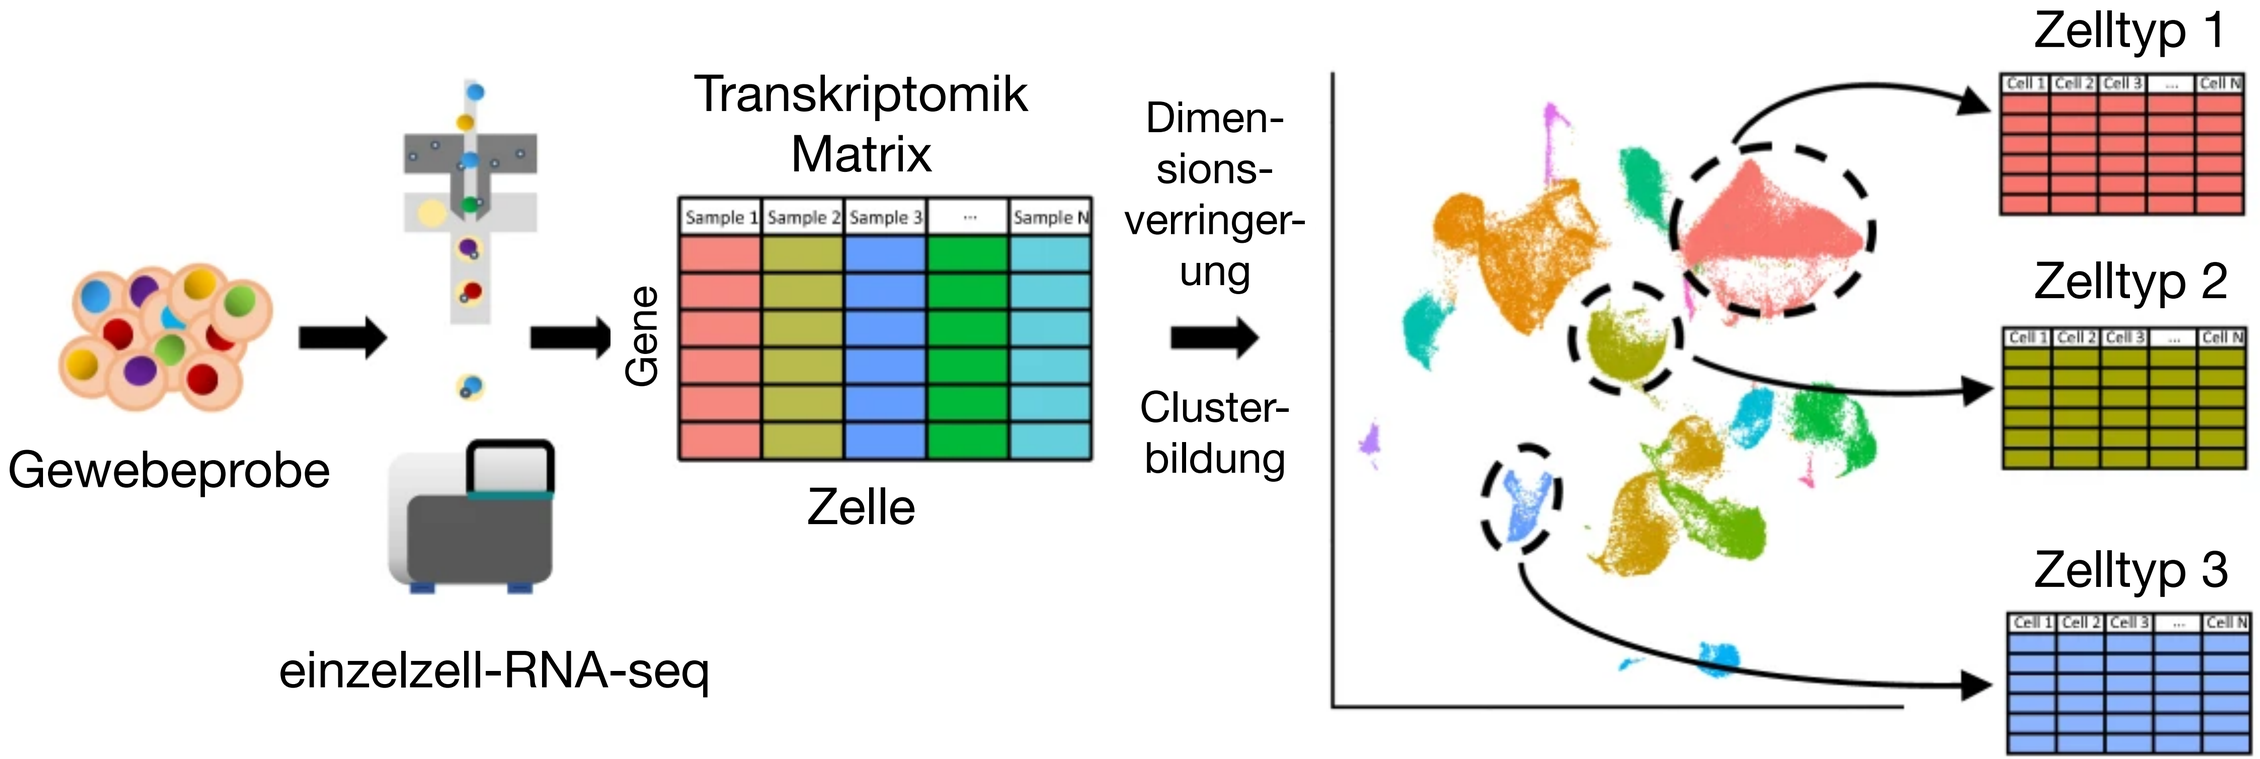


Gen Symbol ist ein einzigartiger Name für ein Gen, egal in welchem Organismus.



ENSMUSG00000064336	mt-Tf
ENSMUSG00000064337	mt-Rnr1
ENSMUSG00000064338	mt-Tv
ENSMUSG00000064339	mt-Rnr2

Recap: Einzelzell-RNA-Sequenzierungsanalyse



Datenvor-verarbeitung → **Dimensions-verringerung** → **Clusterbildung**

Zellen mit niedrigem Lesewert
Leere Barcodes
Doppelte Barcodes (Doublets)

PCA (Hauptkomponentenanalyse)
t-SNE (t-verteilte stochastische Nachbar-Einbettung)

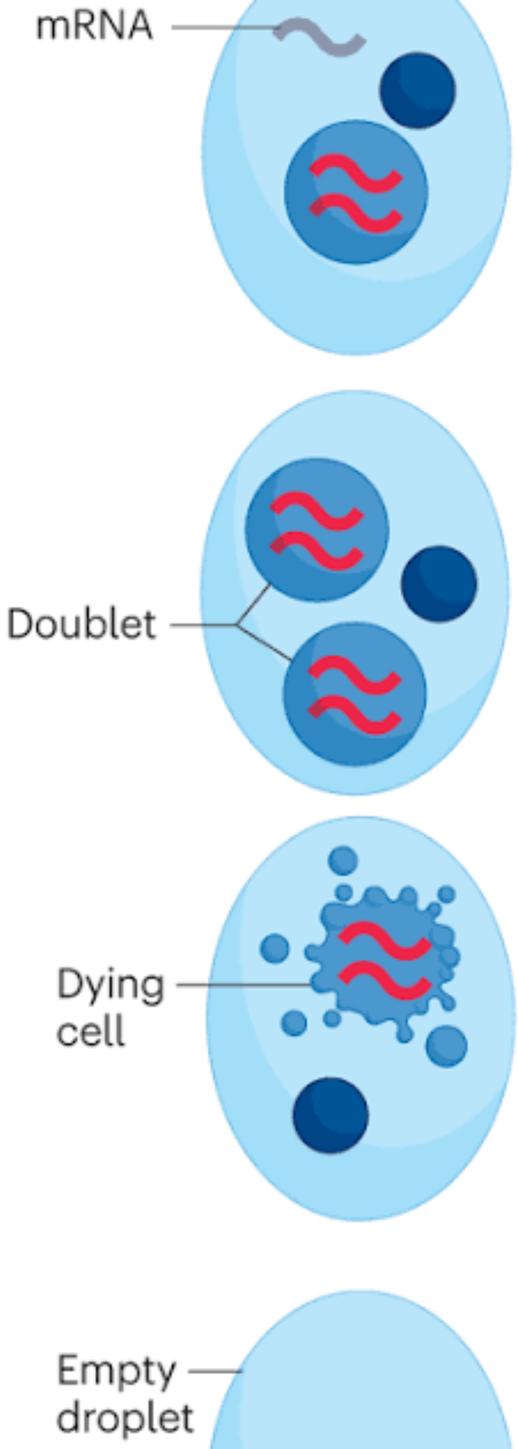
Leiden Clusterbildung Algorithm

1. Datenvorverarbeitung

Zellen von geringer Qualität oder leere Tröpfche weisen oft nur sehr wenige Gene auf.

Zell-Doubletten oder -Multipletts können eine ungewöhnlich hohe Genanzahl aufweisen.

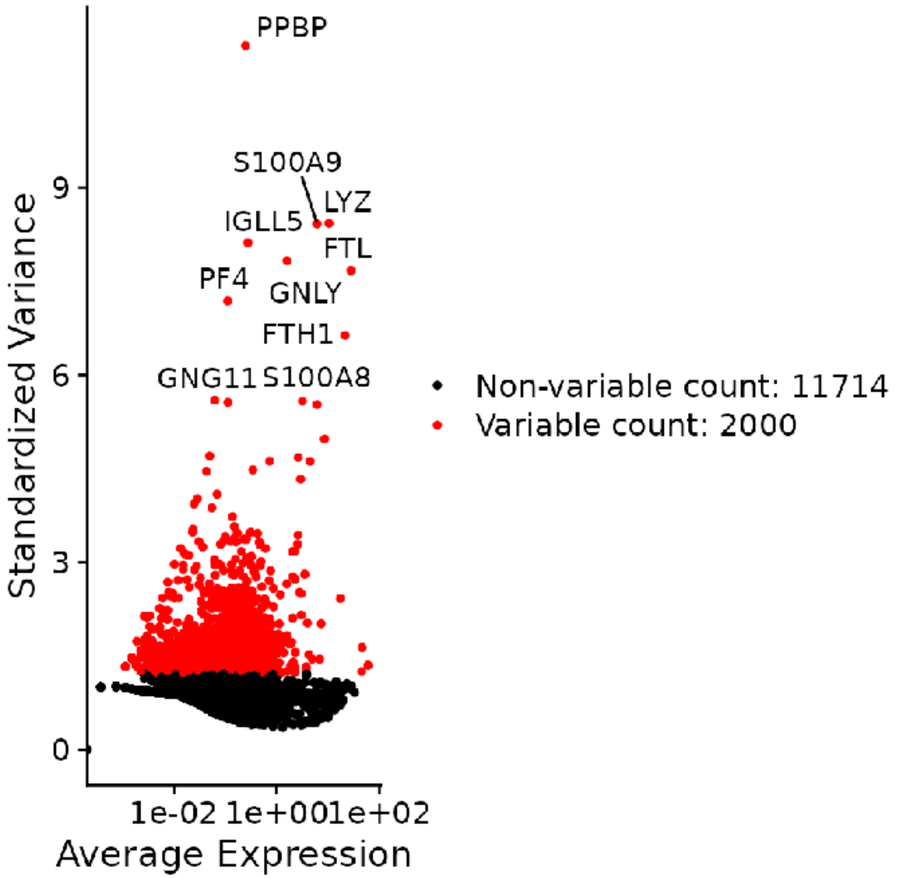
Zellen von geringer Qualität/sterbende Zellen weisen oft eine starke mitochondriale Kontamination auf.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

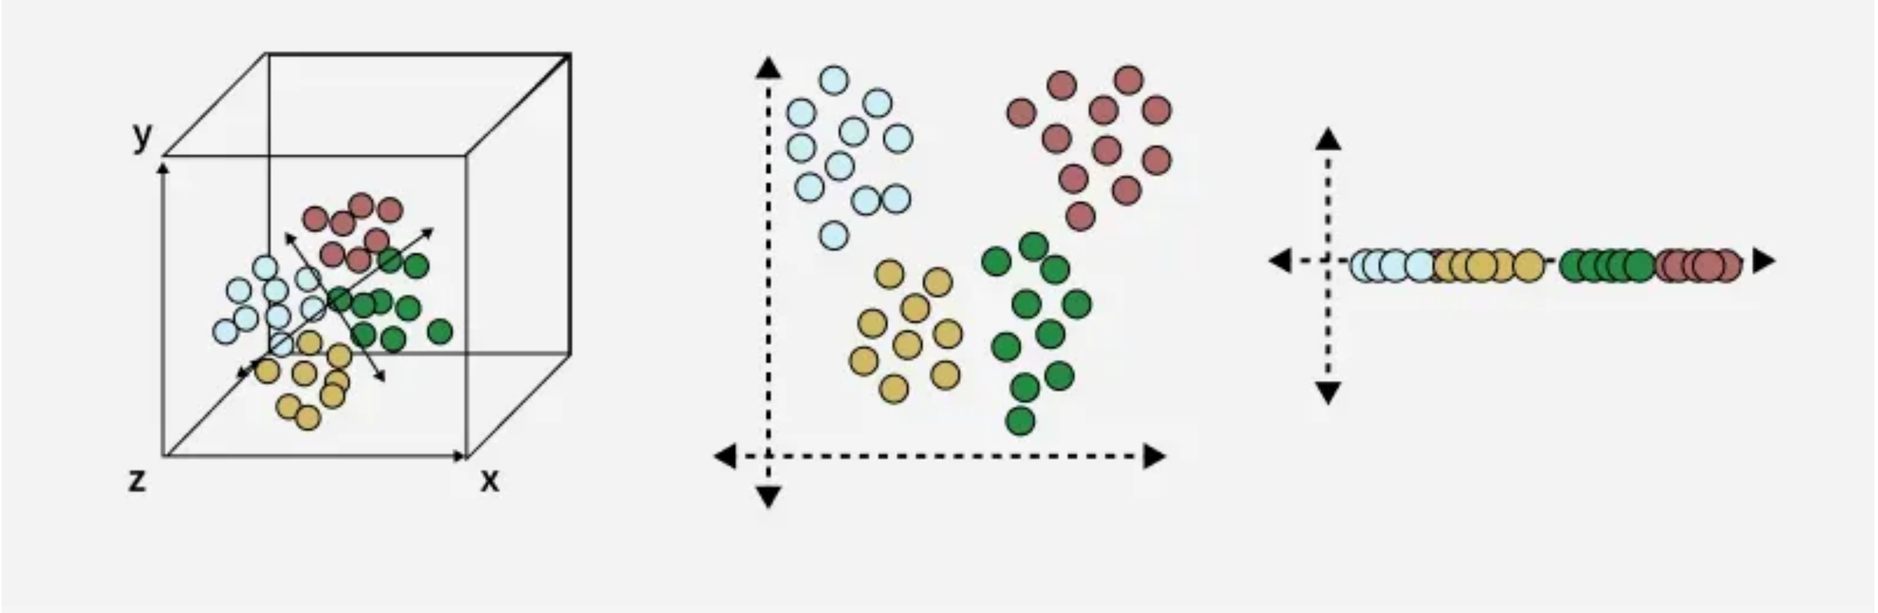
2. Dimensionsverringerung

Wir möchten Genexpressionen finden die die grösste Variation im Datensatz erfassen.



2. Dimensionsverringerung

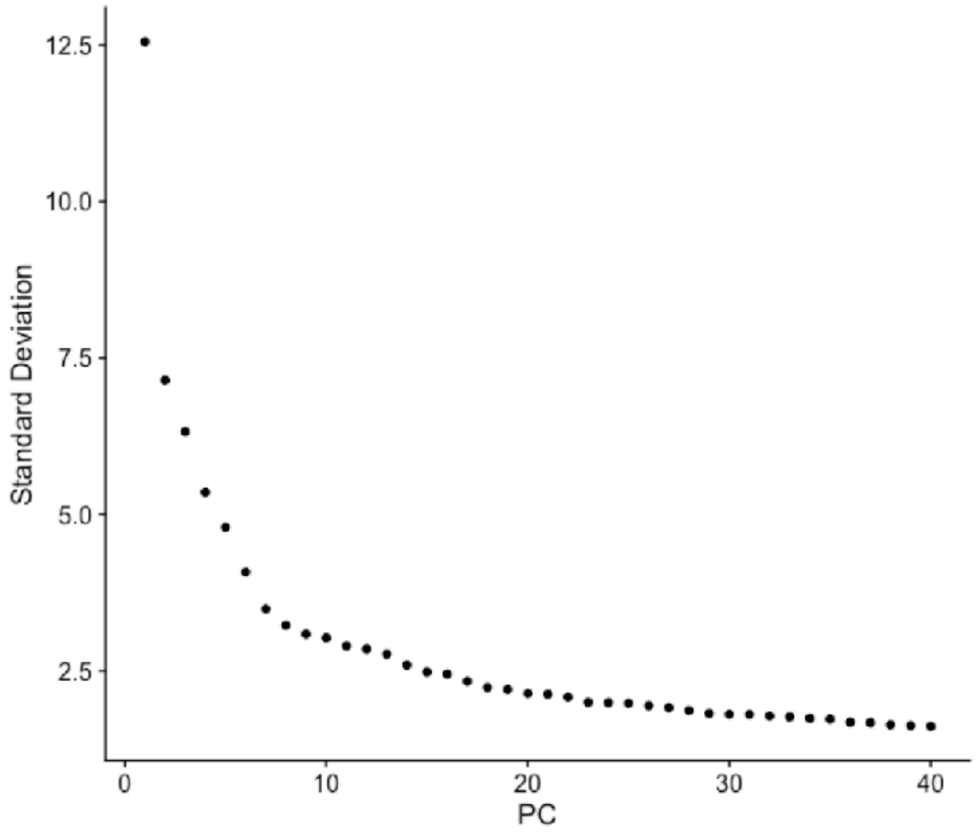
Wir führen dann eine PCA durch. Diese Methode reduziert die Dimensionalität der Daten, indem sie sie in einen Raum mit geringerer Dimension transformiert und dabei so viel Variation wie möglich beibehält. Sie sucht nach einer Kombination von höchst variierende Genexpressionen, den sogenannten Hauptkomponenten.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Wie viele Clusters?

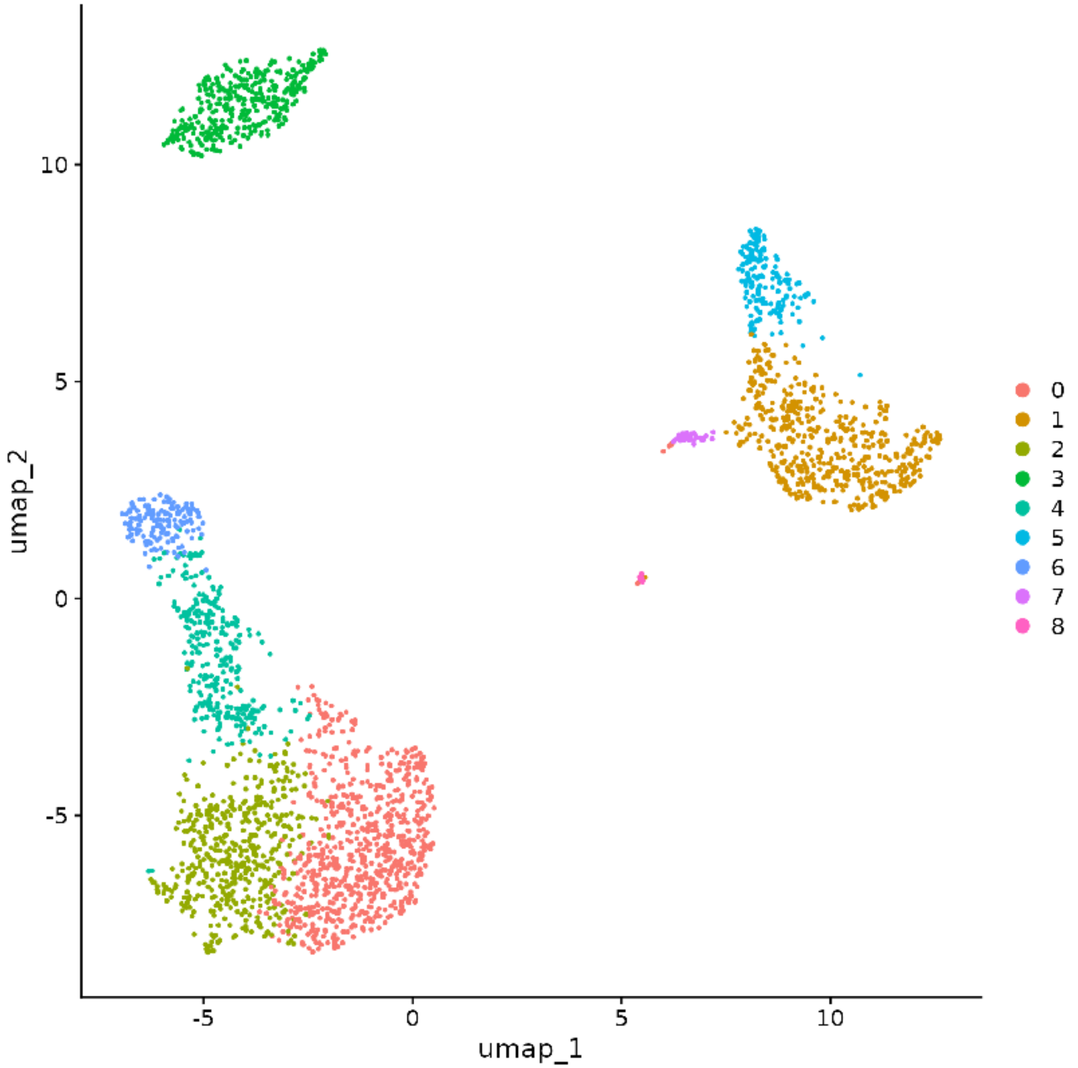
Dazu verwenden wir die Darstellung der Hauptkomponenten aus der PCA und deren jeweilige Erklärungskraft. Der Punkt, an dem wir den Knick sehen, ist der Cut-out-Wert. Es ist nicht notwendig, weitere Dimensionen zu berücksichtigen, da diese keinen wesentlichen Beitrag zur Erklärung der Daten mehr leisten.



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

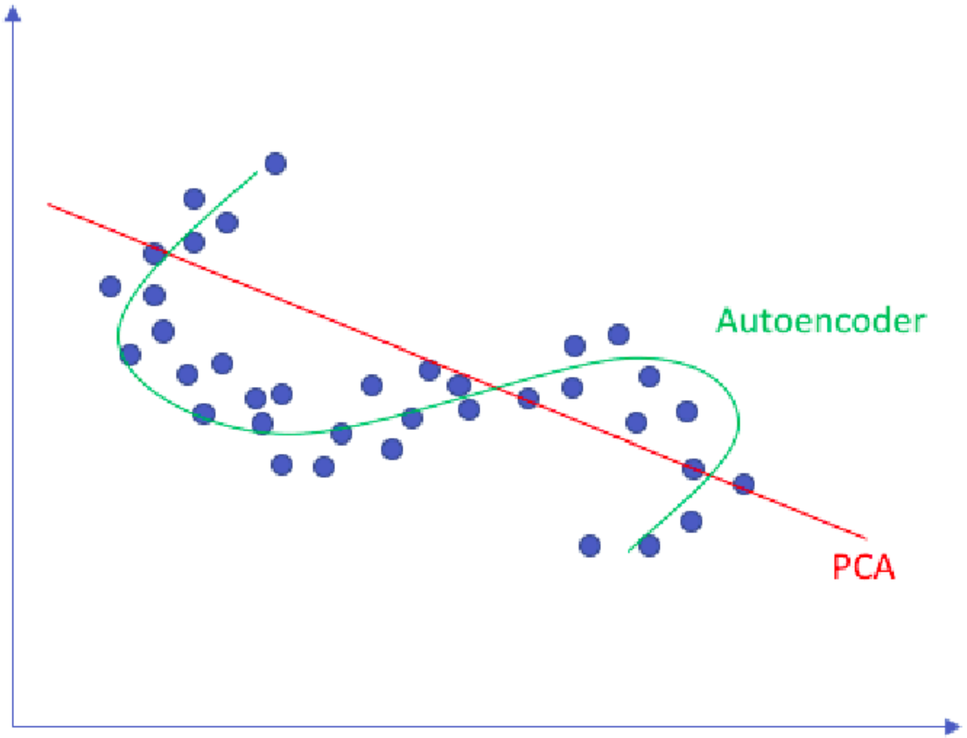
3. Clusterbildung von Zellen

Seurat führt zunächst eine graphbasierte Clusterbildung durch und führt anschliessend eine nichtlineare Dimensionsreduktion (UMAP/tSNE) durch. Dadurch werden ähnliche Zellen anhand ihrer Genexpression gruppiert, um Gruppen von Zellen zu finden, die häufiger miteinander in Verbindung stehen als andere.



linear vs nicht linear

Nichtlineare Methoden gehen davon aus, dass sich die Daten auf einer gekrümmten, nicht flachen Menge befinden.

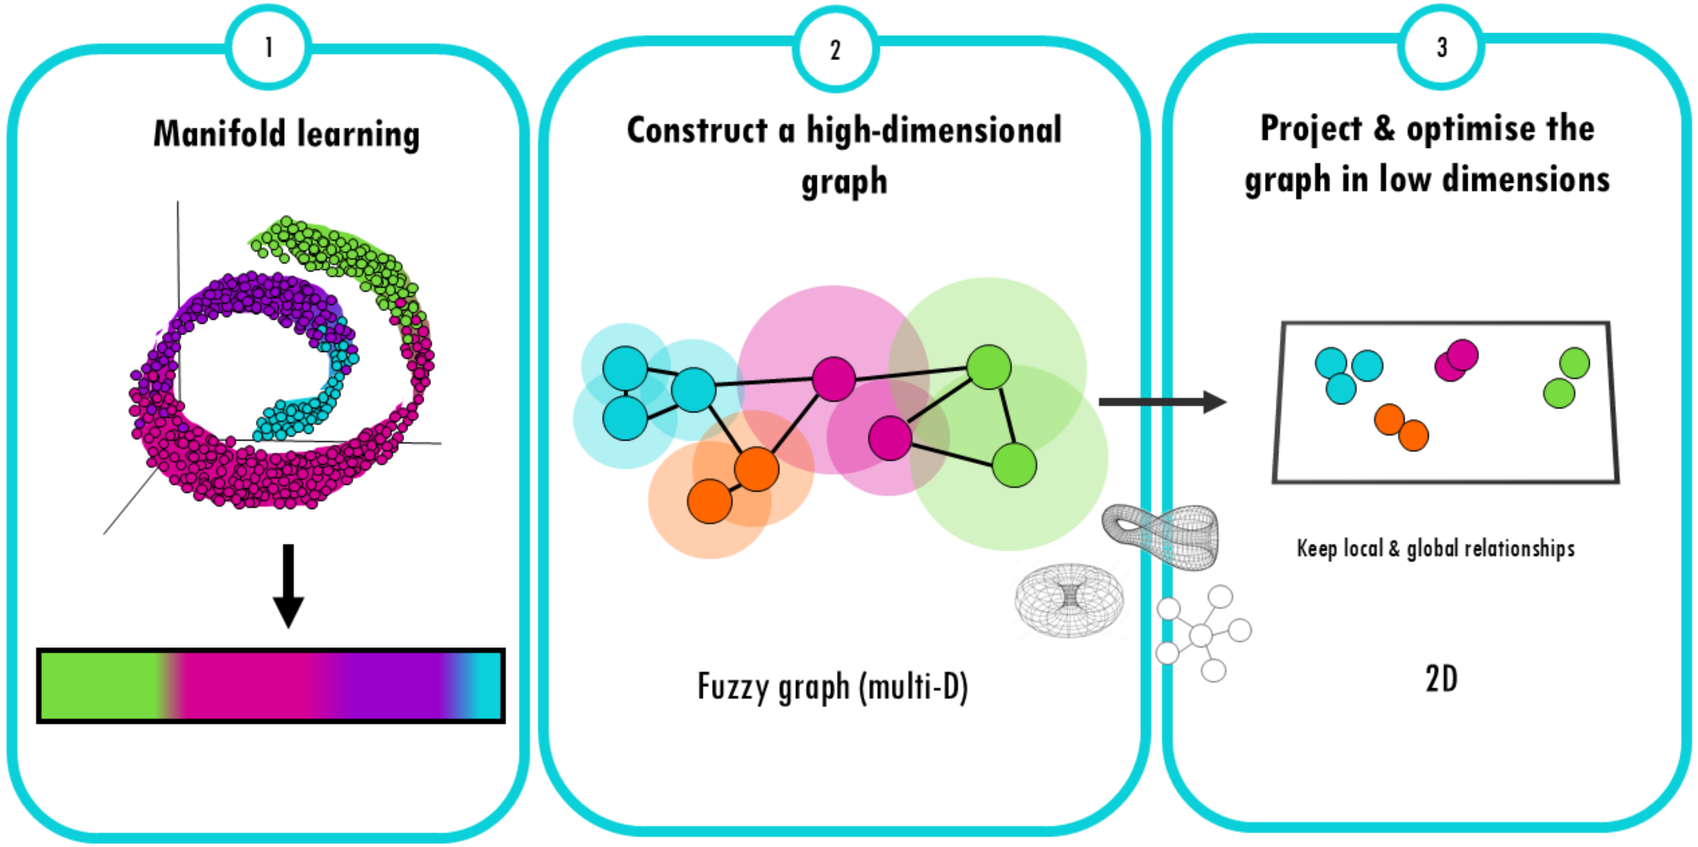


Wie UMAP bildet die Clusters

- erstreckt von jedem Punkt aus einen Radius nach aussen und verbindet Punkte, wenn sich diese Radien überschneiden.
- wählt den Radius auf der Grundlage der Entfernung zum n-ten nächsten Nachbarn jedes Punktes aus.
- macht UMAP den Graphen «unscharf», indem die Wahrscheinlichkeit einer Verbindung mit zunehmendem Radius verringert wird.



Wie UMAP bildet die Clusters



Clusterbildung

https://pair-code.github.io/understanding-umap/

Zwei Grössen für UMAP:

n_neighbors: Anzahl von Nachbarn

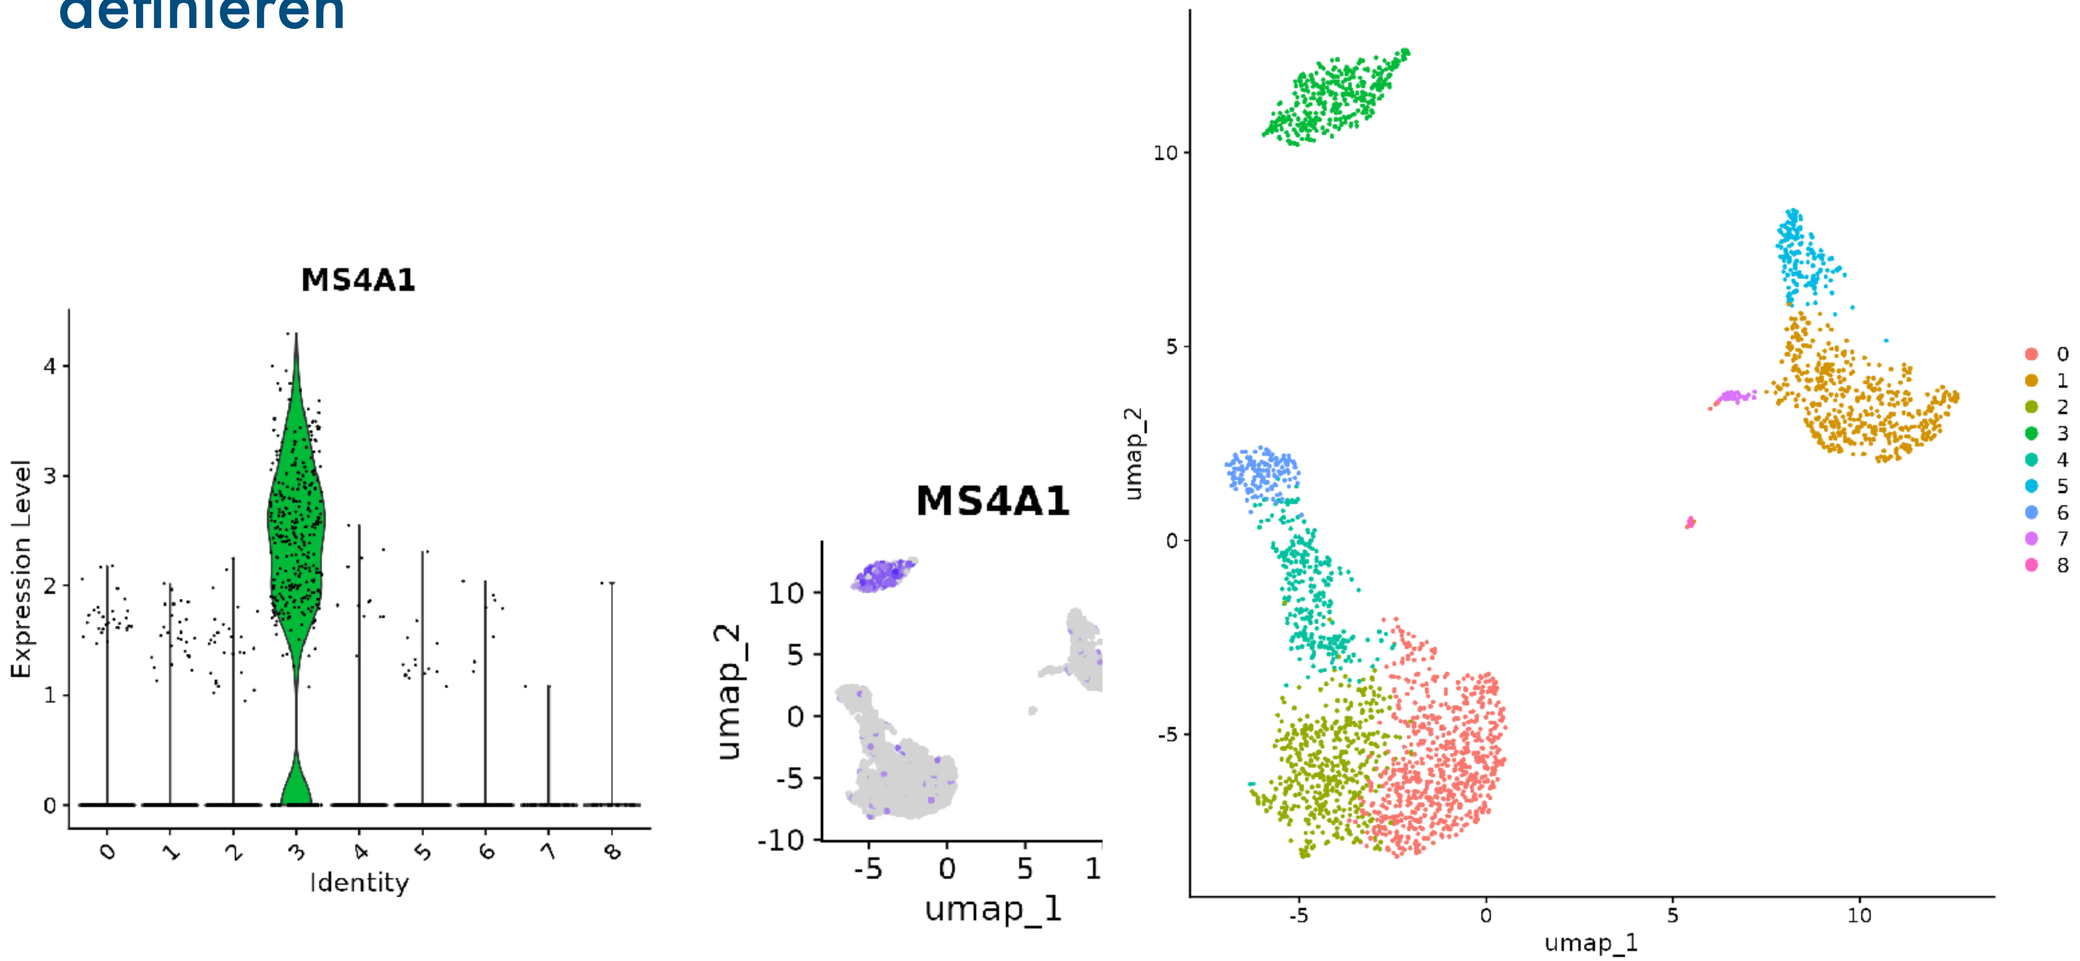
min_dist: minimale Distanz zwischen Nachbarn

Wie ändern diese Grössen das Resultat?

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

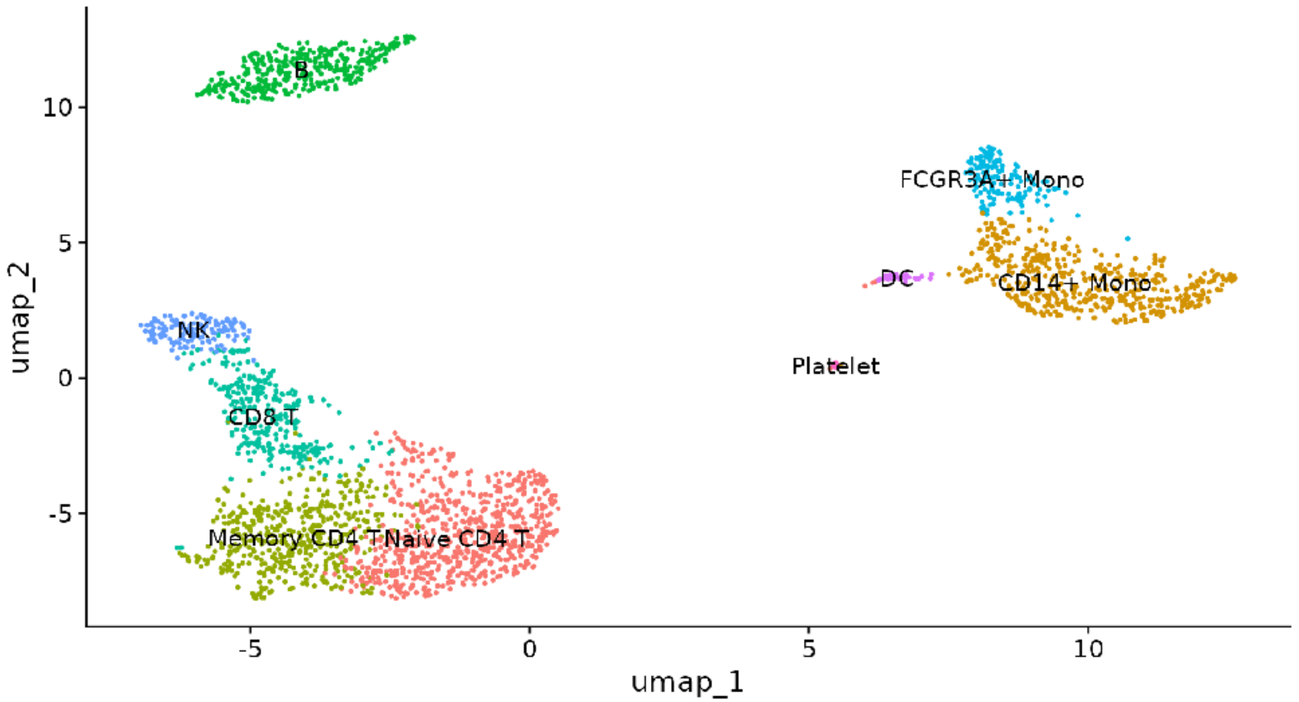
Downstream Analyse

Marker-Gene finden, die Cluster über differentielle Expression definieren



Marker-Gen Analyse

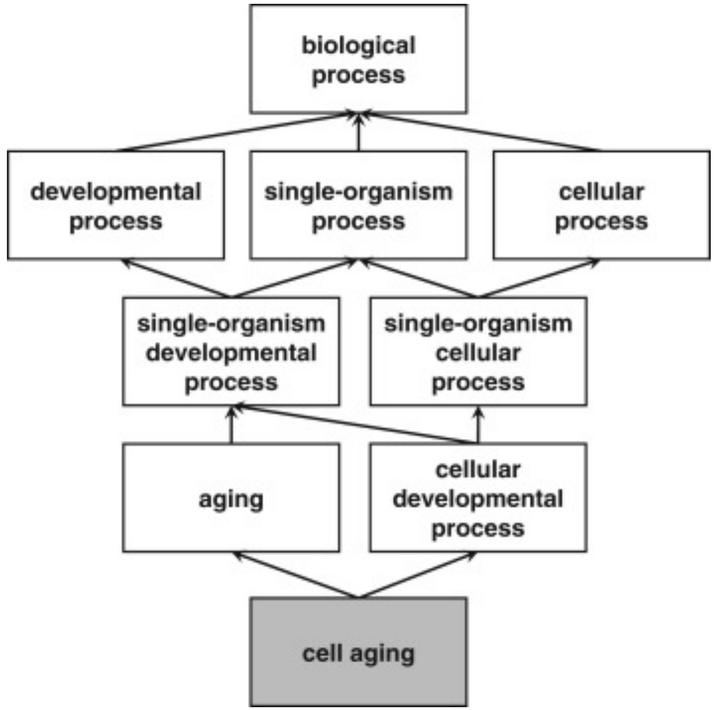
Zuweisung der Zelltyp-Identität zu Clustern auf Grundlage der Literatur: Erstellung einer Expressions-Heatmap für bestimmte Zellen und Merkmale für die wichtigsten Marker.



Cluster ID	Markers	Cell Type
0	IL7R, CCR7	Naive CD4+ T
1	CD14, LYZ	CD14+ Mono
2	IL7R, S100A4	Memory CD4+
3	MS4A1	B
4	CD8A	CD8+ T
5	FCGR3A, MS4A7	FCGR3A+ Mono
6	GNLY, NKG7	NK
7	FCER1A, CST3	DC
8	PPBP	Platelet

Gene Ontology und Pathway Enrichment Analyse

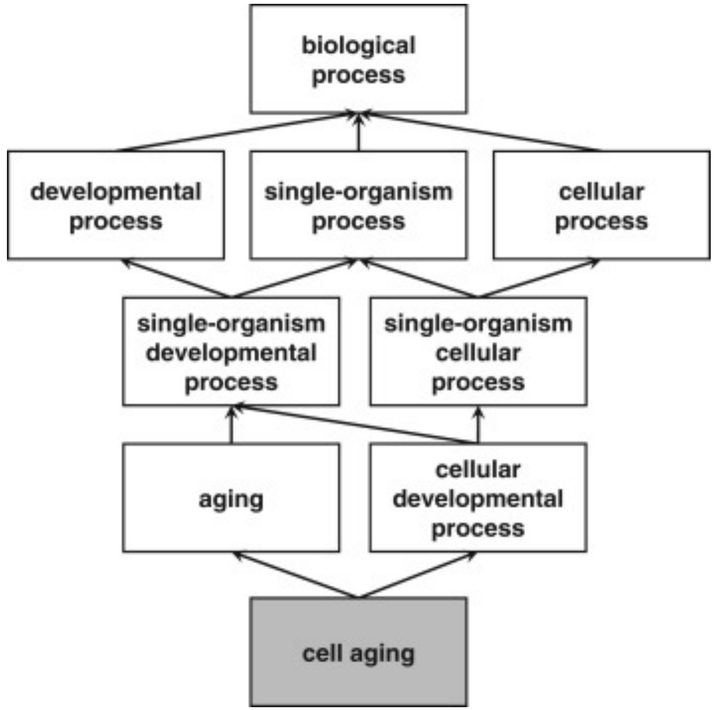
- eine rechnergestützte Methode, mit der ermittelt wird, ob eine vordefinierte Gruppe von Genen, beispielsweise solche in einem bestimmten biologischen Signalweg, in einer grösseren Genliste überrepräsentiert ist.
- wird zur Interpretation grosser Genexpressionsdatensätze verwendet



Gene Ontology und Pathway Enrichment Analyse

ermittelt,

welche biologischen Prozesse oder Signalwege signifikant mit einer bestimmten Erkrankung, einem bestimmten Phänotyp oder einem bestimmten Ansprechen auf eine Behandlung assoziiert sind,



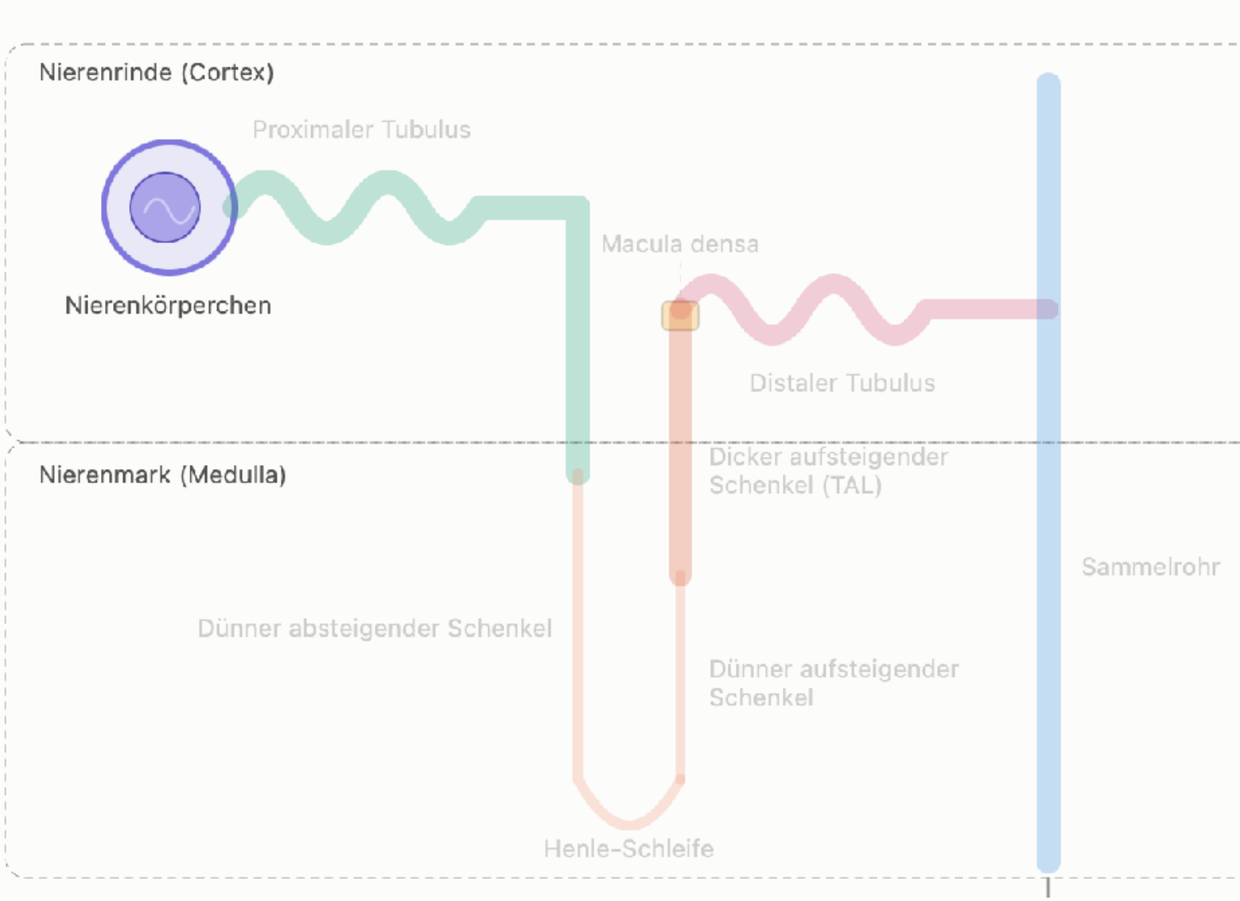
ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Nierenkörperchen (Glomerulus und Bowman-Kapsel)

Ultrafiltration des Blutes: Aus dem Plasma entsteht der Primärharn.

Beispiel-Markergene für scRNA-seq

Podozyten	NPHS1	NPHS2	PODXL	WT1
Glomeruläres Endothel	EMCN	EHD3	PLAT	
Mesangium	PDGFRB	ITGA8		
Parietalepithel	CLDN1	PAX8		
Juxtaglomeruläre Zellen	REN			



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

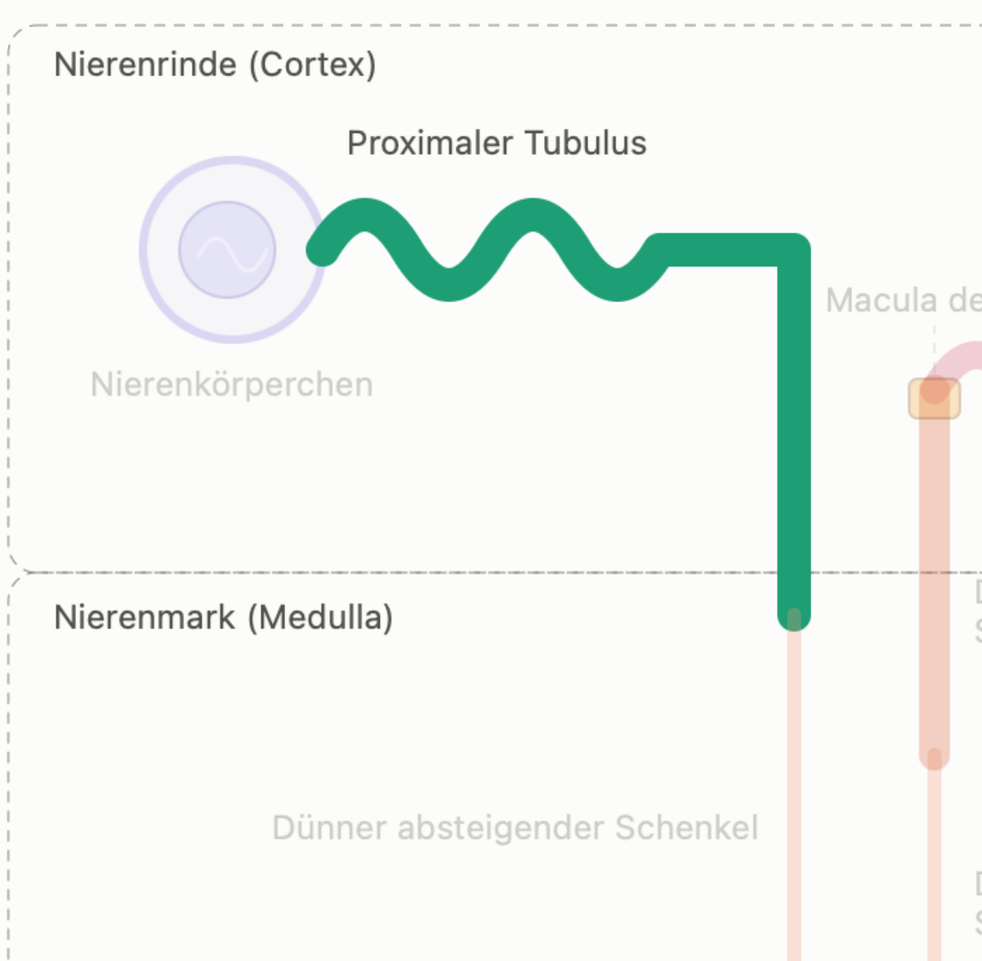
Proximaler Tubulus

Massenreabsorption: Etwa zwei Drittel von Na^+ und Wasser sowie fast die gesamte Glukose und alle Aminosäuren werden zurückgeholt.

Reninbildung
Na^+/K^+-ATPase Aktivität
Bicarbonate Reabsorption
Phosphat-Aufnahme
Sekretion organischer Anionen und Kationen
Ammoniagenese

Beispiel-Markergene für scRNA-seq

Proximaler Tubulus allgemein	LRP2	CUBN	SLC34A1	HNF4A
S1 und S2	SLC5A12	SLC5A2		
S3 (Pars recta)	SLC13A3	SLC22A7		



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

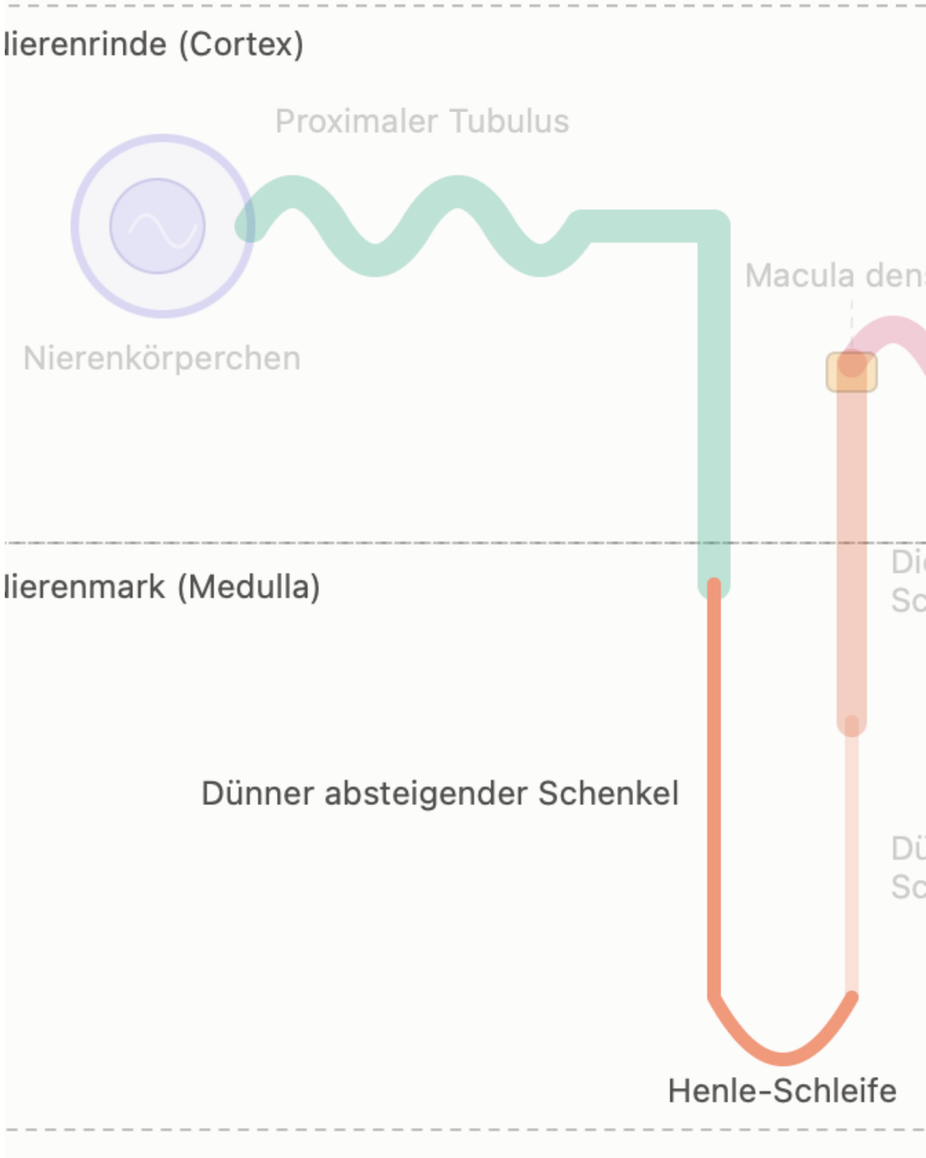
Henle-Schleife

passiver Wasserentzug:

keine Energie benötigt für den Wasserausstrom

Beispiel-Markergene für scRNA-seq

Wasser- und Harnstofftransport	AQP1	SLC14A2
Dünne Schenkel allgemein	TACSTD2	



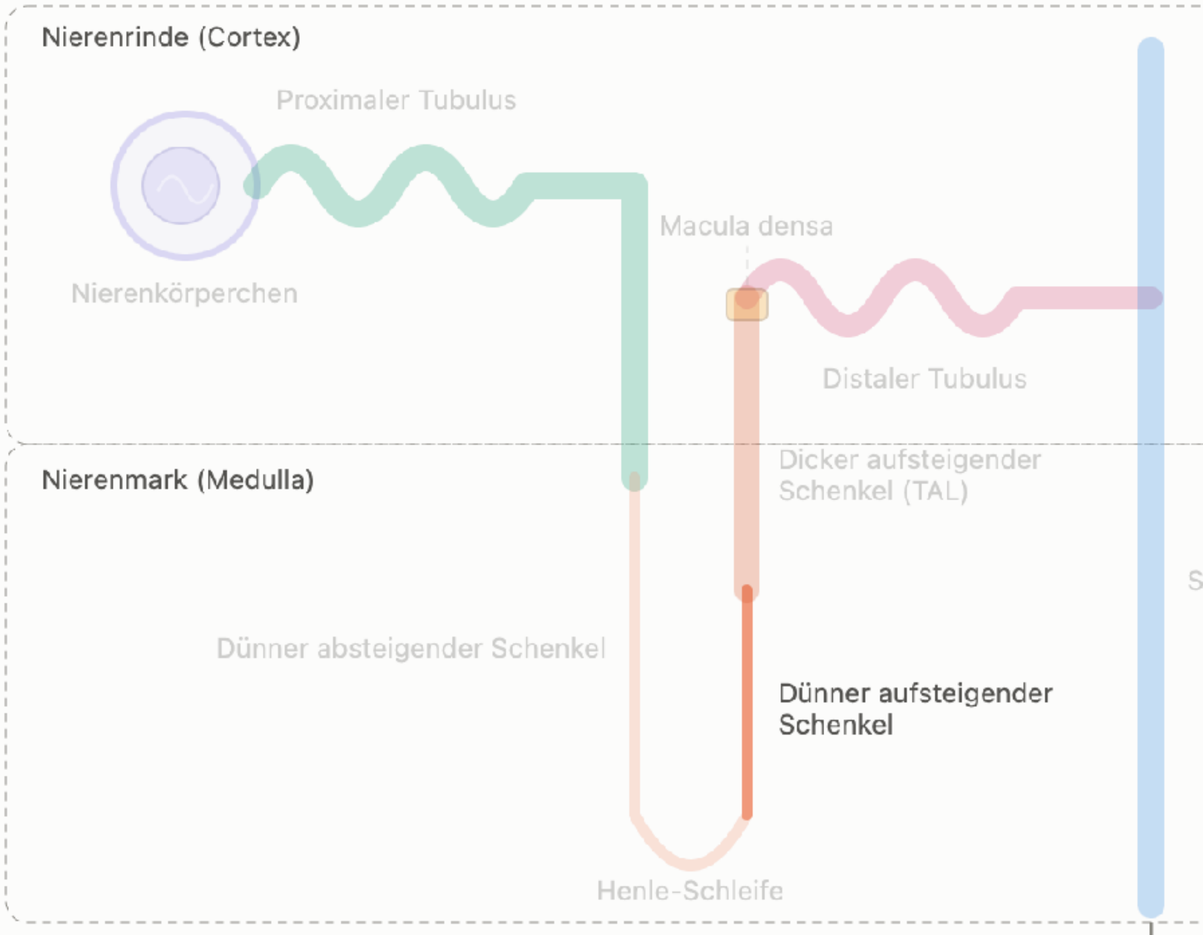
ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Dünner aufsteigender Schenkel

Wasserundurchlässig, aber salzdurchlässig: passiver Transport von Ionen.

Beispiel-Markergene für scRNA-seq

Chlorid-Transport	CLCNKA	CLCNKB	BSND
Dünne Schenkel allgemein	TACSTD2		



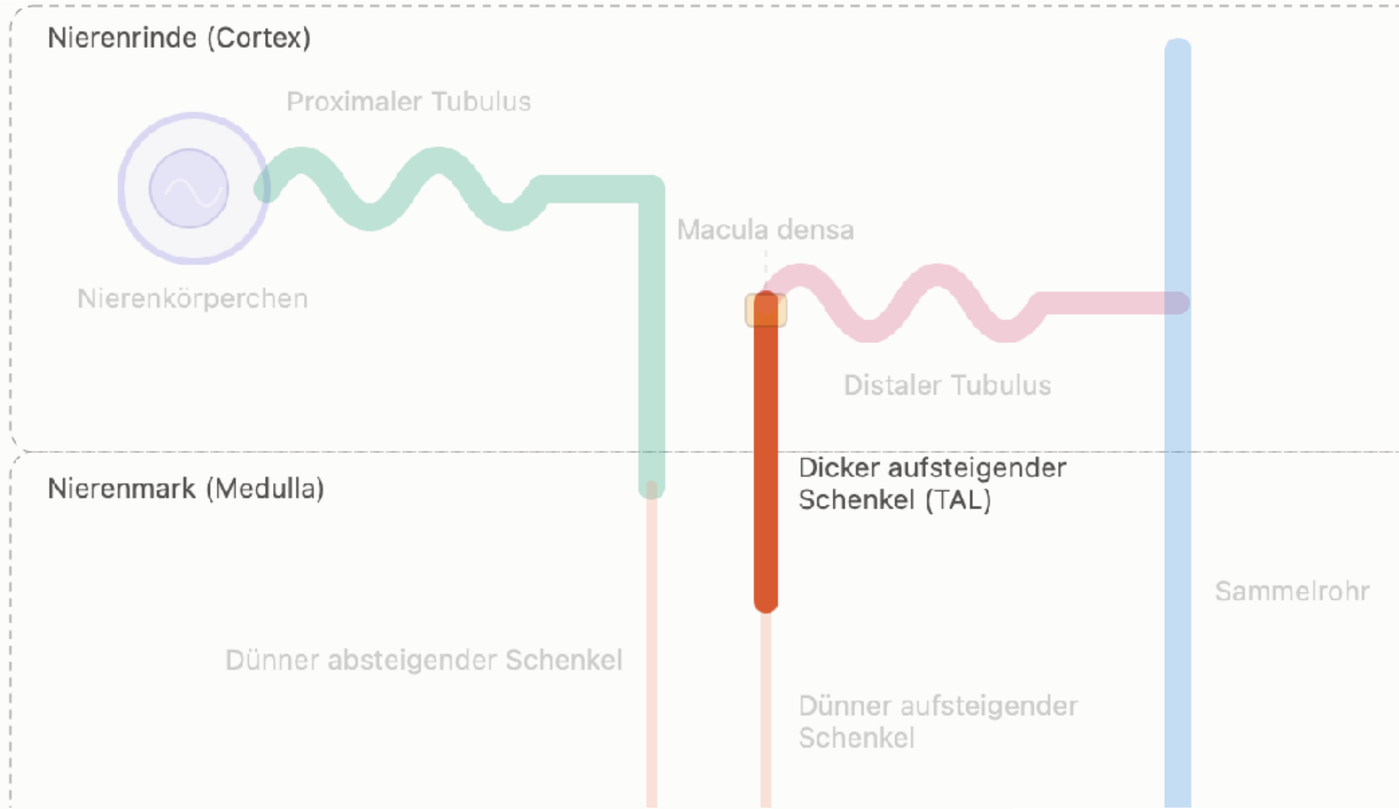
ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Dicker aufsteigender Schenkel (TAL)

Verdünnungssegment:

K^+-Rückfluss

Ca^{2+}- und Mg^{2+}-Reabsorption



Beispiel-Markergene für scRNA-seq

Dicker aufsteigender Schenkel	UMOD	SLC12A1	KCNJ1	CASR	CLDN16	EGF

ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Macula densa

Reninfreisetzung

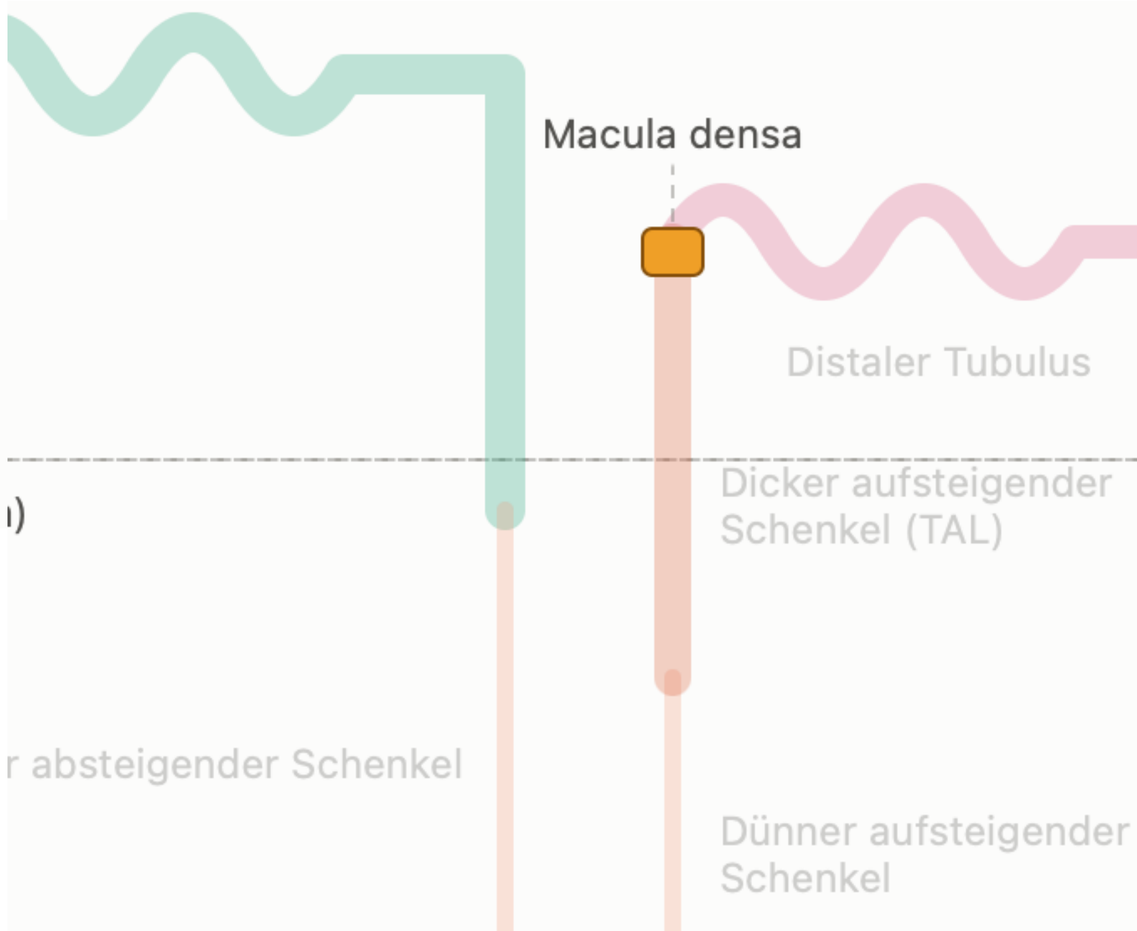
Adenosinmetabolism

ATP/energie/GFR Metabolism

Beispiel-Markergene für scRNA-seq

Macula densa `NOS1` `PTGS2` `SLC12A1`

Partner im Apparat `REN`



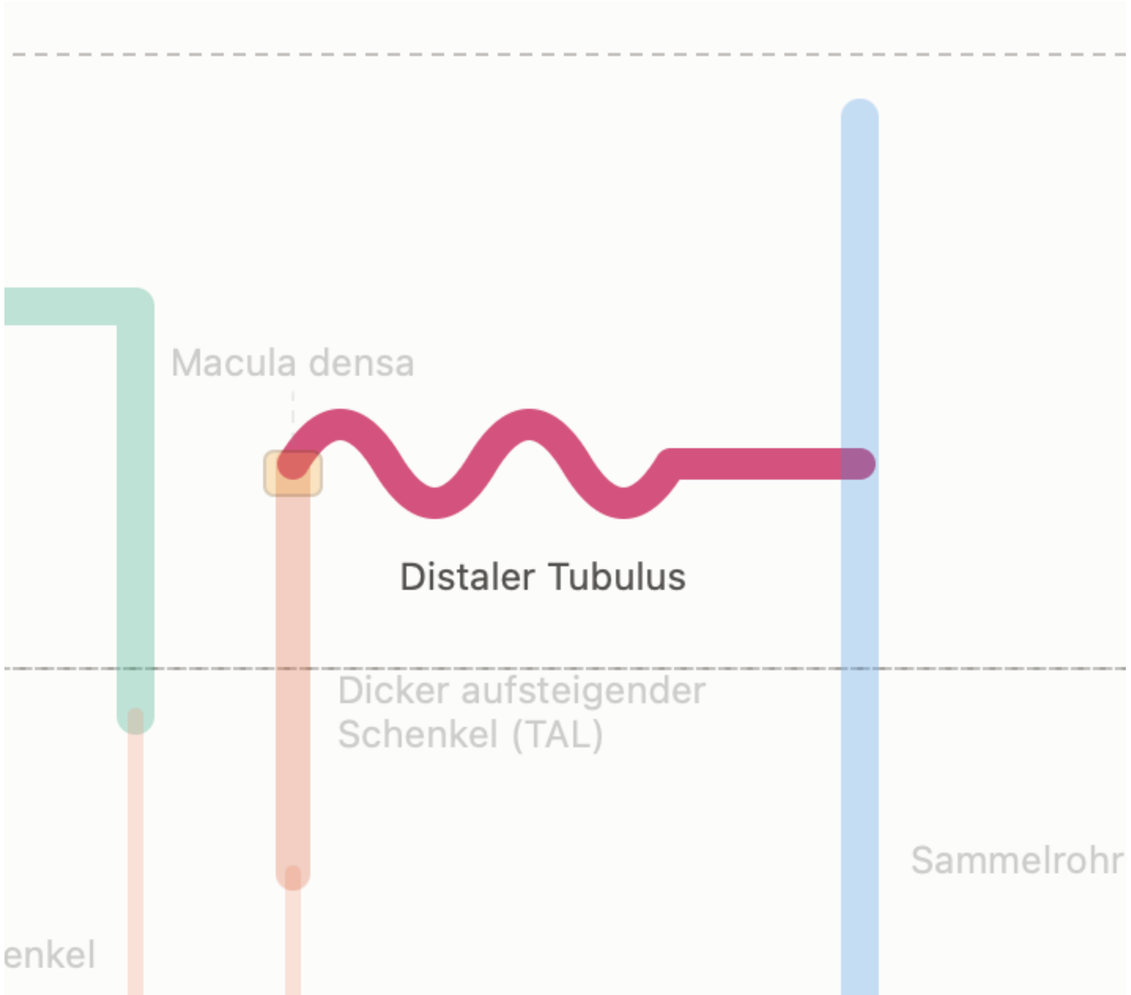
ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Distaler Tubulus (DCT)

Feinregulation der Elektrolyte: NaCl-Reabsorption, Ca^{2+}- und Mg^{2+}-Haushalt.

Beispiel-Markergene für scRNA-seq

Distaler Tubulus	SLC12A3	PVALB	TRPM6
Verbindungstubulus	SLC8A1	TRPV5	CALB1



ZHAW, Institute of Computational Life Sciences Dr. Tugce Bilgin Sonay

Sammelrohr

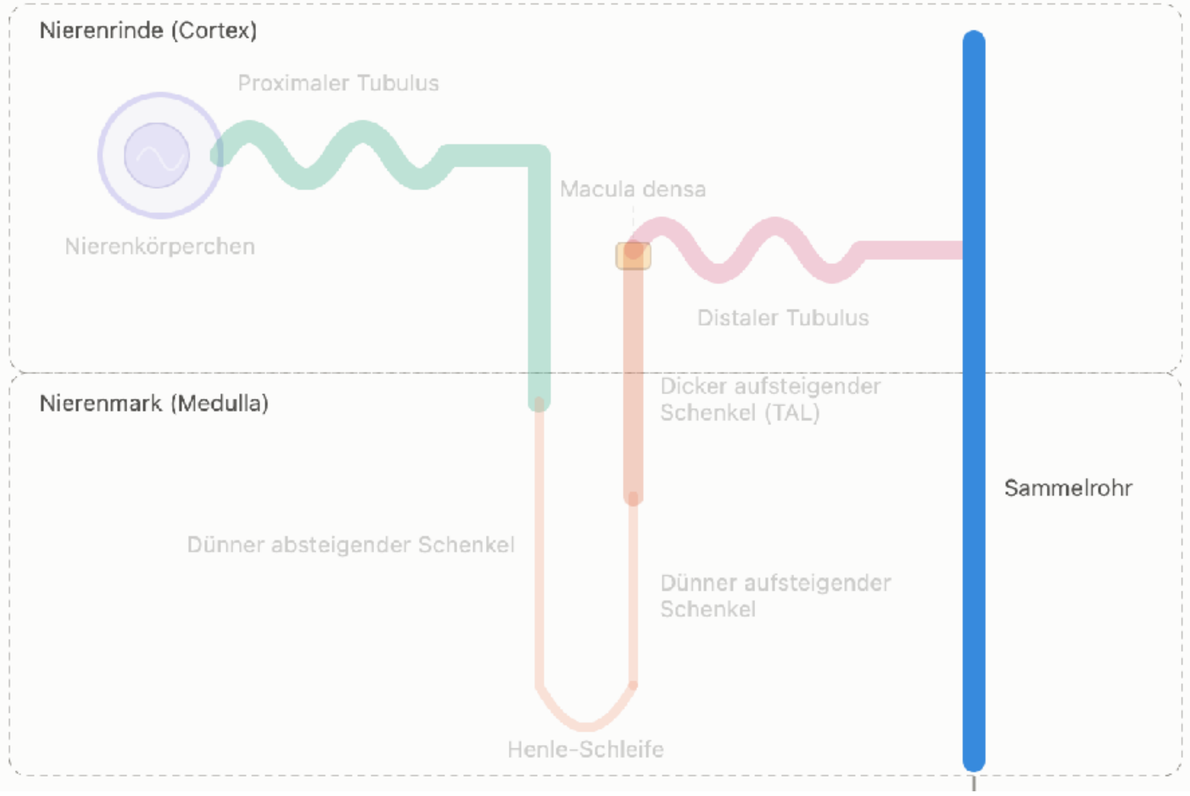
Letzte Anpassung von Urinvolumen, Konzentration und Säure-Basen-Haushalt. Hier wirken ADH und Aldosteron.

H^+-Sekretion mit ATPase

Bicarbonate-Rückgewinn

Beispiel-Markergene für scRNA-seq

Hauptzellen	AQP2	AQP3	AVPR2	SCNN1G
Schaltzellen allgemein	FOXI1			
Schaltzellen Typ A	ATP6V1G3	SLC4A1		
Schaltzellen Typ B	SLC26A4			



Challenge!

Gruppenarbeit: Identifiziere die Nierenteile!

- spiele mit Filtern

- spiele mit Anzahl von Gruppen

- Check die Markergene (Top3 ist genug?)

- Check die Funktionen dieser Gene. Benutze dafür die Info an Folien, die Excel Tabelle, Literatur, usw.

- Check die enriched Funktionen von Gruppen.

- Nach du mit Filtern und Cluster-Anzahl genug herumspielst, entscheide an deinen ausgewählten Set von Parametern, erkläre deine Gründe. Entscheide an Nierenteilen für jeden Cluster, befestige die Clusternamen an Plots. Ihr werdet eure Resultate präsentieren.